

MATHÉMATIQUES • TLE E

ORGANISATION ET GESTION DES DONNÉES

LEÇON 10

STATISTIQUES À DEUX VARIABLES

DURÉE CONSEILLÉE : 9 H

DANS CETTE LEÇON

Cette leçon introduit l'étude simultanée de deux caractères statistiques : représentation par nuage de points, ajustement affine (méthodes de Mayer et des moindres carrés), mesure de la corrélation et prévisions. Elle constitue un chapitre central de l'épreuve de mathématiques au Baccalauréat C, D, E et TI.

- À la fin de cette leçon, je sais construire et exploiter un tableau à double entrée et en déduire les séries marginales
- À la fin de cette leçon, je sais construire un nuage de points et placer le point moyen G
- À la fin de cette leçon, je sais déterminer une droite d'ajustement affine par la méthode de Mayer
- À la fin de cette leçon, je sais calculer la covariance de deux variables statistiques
- À la fin de cette leçon, je sais déterminer les droites de régression de y en x et de x en y par les moindres carrés
- À la fin de cette leçon, je sais calculer et interpréter le coefficient de corrélation linéaire



TÉLÉCHARGE ONBUCH

Gratuit • Google Play
Tuteur IA, annales,
concours, résultats



PASSE À ONBUCH+

Tous les cours signés, Tuteur IA illimité, fiches PDF — onglet OnBuch+ de l'app

CE COURS SIGNÉ CONTIENT

COURS

complet, illustré, pas à pas

MÉTHODES

et exercices résolus

EXERCICES

type examen + corrigés

FICHE BILAN

l'essentiel à retenir



Signé • OnBuch+

ÉQUIPE PÉDAGOGIQUE ONBUCH+
CONFORME AU PROGRAMME OFFICIEL MINESEC

OnBuch+

SOMMAIRE

- | | |
|--|----------------------------------|
| 1. Séries statistiques à deux caractères | grique |
| 2. Nuage de points et point moyen | 7. Activité d'intégration |
| 3. Ajustement affine par la méthode de Mayer | 8. Méthodes et exercices résolus |
| 4. Covariance et moindres carrés | 9. Exercices |
| 5. Coefficient de corrélation linéaire | 10. Corrigés des exercices |
| 6. Prévisions et synthèse méthodolo- | 11. Fiche bilan |

OBJECTIFS DE LA LEÇON

- À la fin de cette leçon, je sais construire et exploiter un tableau à double entrée et en déduire les séries marginales
- À la fin de cette leçon, je sais construire un nuage de points et placer le point moyen G
- À la fin de cette leçon, je sais déterminer une droite d'ajustement affine par la méthode de Mayer
- À la fin de cette leçon, je sais calculer la covariance de deux variables statistiques
- À la fin de cette leçon, je sais déterminer les droites de régression de y en x et de x en y par les moindres carrés
- À la fin de cette leçon, je sais calculer et interpréter le coefficient de corrélation linéaire
- À la fin de cette leçon, je sais juger de la qualité d'un ajustement affine
- À la fin de cette leçon, je sais utiliser un ajustement affine pour effectuer une prévision et en discuter la fiabilité

PRÉREQUIS

- Statistiques à une variable (Première) : moyenne, variance, écart-type, formules avec effectifs
- Équations de droites dans le plan : pente (coefficient directeur), point d'appartenance
- Repérage dans le plan et lecture graphique

- Résolution de systèmes de deux équations à deux inconnues
- Calculs avec le symbole somme Σ et manipulation de moyennes pondérées

1 SÉRIES STATISTIQUES À DEUX CARACTÈRES

Situation d'accroche. Mme Etoundi gère une station-service sur l'axe lourd Yaoundé-Soa. Chaque soir, elle note dans son cahier deux nombres : le nombre de véhicules comptés devant sa station dans la journée, et le volume de carburant vendu (en litres). Au bout de huit semaines, elle observe une chose frappante : les jours de fort trafic, les ventes grimpent ; les jours calmes, elles s'effondrent. Deux questions la taraudent alors : peut-on prévoir les ventes de la semaine prochaine à partir du trafic annoncé ? Et surtout : comment mesurer la force du lien entre ces deux quantités ? Dire « ça augmente ensemble » ne suffit pas à un banquier pour accorder un crédit de stock : il faut un nombre, un coefficient, une méthode. C'est précisément l'objet de cette leçon : la **statistique à deux variables**. Avant de prévoir (sections 3 à 6), il faut d'abord apprendre à organiser ces données doubles : c'est l'objet de cette première section.

1.1 Qu'est-ce qu'une série statistique à deux caractères ?

Intuition. En classe de Première, tu as étudié des séries statistiques à un caractère : la taille des élèves d'une classe, les notes à un devoir. Mais dans la vie réelle, on s'intéresse souvent à deux grandeurs mesurées sur les mêmes individus : le poids et la taille d'un nouveau-né à l'hôpital de Bafoussam, le revenu et la dépense téléphonique d'un ménage, l'âge d'un véhicule et sa consommation de carburant. La question n'est plus « comment se répartit telle grandeur ? » mais « ces deux grandeurs sont-elles liées, et comment ? ».

DÉFINITION Série statistique à deux caractères

Soit une population de N individus. On observe sur chaque individu deux caractères quantitatifs X et Y . L'ensemble des couples $(x_i ; y_i)$ obtenus s'appelle une **série statistique à deux caractères** (ou série double, ou série bivariable). L'entier N est l'**effectif total** de la série.

Deux présentations des données sont possibles, selon la taille de la population.

Première présentation : la liste de couples. Quand l'effectif est modeste (comme les huit semaines de Mme Etoundi), on donne simplement la liste des couples $(x_i ; y_i)$, souvent sous forme d'un tableau à deux lignes :

Semaine i	1	2	3	4	5	6	7	8
Trafic x_i (centaines de véhicules)	12	15	9	18	14	20	11	16
Ventes y_i (centaines de litres)	30	38	25	45	36	50	28	41

Chaque colonne est un couple $(x_i ; y_i)$: par exemple, la semaine 4 correspond au couple (18 ; 45).

Deuxième présentation : le tableau à double entrée. Quand l'effectif est grand et que les valeurs se répètent (ou sont regroupées en classes), on croise les valeurs de X (en lignes) et celles de Y (en colonnes) dans un tableau.

DÉFINITION Tableau à double entrée

On note $x_1, x_2, \dots, x_p$ les valeurs (ou classes) prises par X et $y_1, y_2, \dots, y_q$ celles prises par Y . Le **tableau à double entrée** donne, à l'intersection de la ligne i et de la colonne j , l'**effectif conjoint** n_{ij} : le nombre d'individus qui présentent à la fois la valeur x_i de X et la valeur y_j de Y .

ATTENTION Effectif conjoint $\neq$ effectifs marginaux

L'effectif n_{ij} compte les individus vérifiant simultanément les deux conditions ($X = x_i$ ET $Y = y_j$). Ne le confonds jamais avec $n_{i\cdot}$ (individus vérifiant $X = x_i$, quelle que soit la valeur de Y) ni avec $n_{\cdot j}$ (individus vérifiant $Y = y_j$, quelle que soit la valeur de X). Au Baccalauréat, cette confusion est la première cause de perte de points dans les tableaux à double entrée : vérifie toujours que la somme de tous les n_{ij} redonne l'effectif total N .

1.2 Un exemple complet : téléphonie mobile et revenu à Douala**EXEMPLE** Dépenses de téléphonie mobile selon le revenu

Une enquête porte sur $N = 50$ ménages d'un quartier de Douala. On relève pour chaque ménage son revenu mensuel X (en dizaines de milliers de FCFA, regroupé en classes) et sa dépense mensuelle de téléphonie mobile Y (en milliers de FCFA, regroupée en classes). Les résultats sont consignés dans le tableau à double entrée suivant :

$X \setminus Y$	[2 ; 5[	[5 ; 8[	[8 ; 11[	Total ligne
[10 ; 20[	8	4	1	13
[20 ; 30[	5	9	3	17
[30 ; 40[	2	6	5	13
[40 ; 50[	0	3	4	7
Total colonne	15	22	13	50

Lecture du tableau. La case située à l'intersection de la ligne [20 ; 30[et de la colonne [5 ; 8[contient $n_{22} = 9$: cela signifie que 9 ménages ont un revenu compris entre 200000 et 300000 FCFA et une dépense téléphonique comprise entre 5000 et 8000 FCFA. De même, $n_{43} = 4$: quatre ménages gagnent entre 400000 et 500000 FCFA et dépensent entre 8000 et 11000 FCFA en téléphonie.

Vérification de l'effectif total. Additionnons tous les effectifs conjoints :

$$\sum_{i=1}^4 \sum_{j=1}^3 n_{ij} = (8 + 4 + 1) + (5 + 9 + 3) + (2 + 6 + 5) + (0 + 3 + 4) = 13 + 17 + 13 + 7 = 50.$$

On retrouve bien $N = 50$: le tableau est cohérent. Cette vérification doit devenir un réflexe systématique.

1.3 Séries marginales et moyennes marginales

Intuition. Le tableau à double entrée contient trop d'information si l'on veut étudier un seul caractère à la fois. Pour retrouver la série « classique » du caractère X seul, il suffit d'« écraser » le tableau horizontalement : pour chaque ligne, on additionne tous les effectifs de la ligne. On obtient les effectifs marginaux, placés dans les marges du tableau — d'où leur nom.

DÉFINITION Effectifs marginaux et séries marginales

- L'**effectif marginal** de la valeur x_i est la somme des effectifs de la ligne i :

$$n_{i\cdot} = \sum_{j=1}^q n_{ij} = n_{i1} + n_{i2} + \dots + n_{iq}.$$

La série $(x_i; n_{i\cdot})$ est la **série marginale de X** .

- L'**effectif marginal** de la valeur y_j est la somme des effectifs de la colonne j :

$$n_{\cdot j} = \sum_{i=1}^p n_{ij} = n_{1j} + n_{2j} + \dots + n_{pj}.$$

La série $(y_j; n_{\cdot j})$ est la **série marginale de Y** .

On a toujours : $\sum_{i=1}^p n_{i\cdot} = \sum_{j=1}^q n_{\cdot j} = \sum_{i,j} n_{ij} = N.$

DÉFINITION Moyennes marginales

Les **moyennes marginales** sont les moyennes des séries marginales :

$$\bar{x} = \frac{1}{N} \sum_{i=1}^p n_{i\cdot} x_i \quad \text{et} \quad \bar{y} = \frac{1}{N} \sum_{j=1}^q n_{\cdot j} y_j.$$

MÉTHODE Extraire les séries marginales d'un tableau à double entrée

1. Calculer les totaux de lignes : pour chaque ligne i , additionner les n_{ij} ; écrire le résultat $n_{i\cdot}$ dans une colonne « Total » à droite.

2. Calculer les totaux de colonnes : pour chaque colonne j , additionner les n_{ij} ; écrire le résultat $n_{.j}$ dans une ligne « Total » en bas.
3. Contrôler : la somme des totaux de lignes et la somme des totaux de colonnes doivent toutes deux valoir N .
4. Écrire les séries marginales sous forme de tableaux à une variable : $(x_i ; n_{i.})$ pour X et $(y_j ; n_{.j})$ pour Y .
5. Calculer les moyennes marginales $\bar{x}$ et $\bar{y}$ avec les formules habituelles de la moyenne pondérée (en utilisant les centres de classes si les données sont regroupées).

EXERCICE RÉSOLU 1 Séries marginales de l'enquête de Douala

À partir du tableau des 50 ménages de Douala : (1) déterminer les deux séries marginales ; (2) calculer les moyennes marginales $\bar{x}$ et $\bar{y}$.

SOLUTION

1. Séries marginales. Les totaux de lignes donnent la série marginale de X :

Classe de X	[10; 20[	[20; 30[	[30; 40[	[40; 50[
Effectif $n_{i.}$	13	17	13	7

Les totaux de colonnes donnent la série marginale de Y :

Classe de Y	[2; 5[	[5; 8[	[8; 11[
Effectif $n_{.j}$	15	22	13

Contrôle : $13 + 17 + 13 + 7 = 50$ et $15 + 22 + 13 = 50$. ✓

2. Moyennes marginales. Les données étant regroupées en classes, on utilise les centres de classes : 15, 25, 35, 45 pour X et 3,5 ; 6,5 ; 9,5 pour Y .

$$\bar{x} = \frac{13 \times 15 + 17 \times 25 + 13 \times 35 + 7 \times 45}{50} = \frac{195 + 425 + 455 + 315}{50} = \frac{1390}{50} = 27,8;$$

$$\bar{y} = \frac{15 \times 3,5 + 22 \times 6,5 + 13 \times 9,5}{50} = \frac{52,5 + 143 + 123,5}{50} = \frac{319}{50} = 6,38.$$

Interprétation. Le revenu mensuel moyen des ménages enquêtés est d'environ 278000 FCFA, et leur dépense téléphonique moyenne d'environ 6380 FCFA par mois.

1.4 Le tableau à double entrée annoté

La figure ci-dessous résume l'architecture d'un tableau à double entrée : repère bien la place des effectifs conjoints n_{ij} (au cœur du tableau), des effectifs marginaux $n_{i.}$ (marge droite) et $n_{.j}$ (marge inférieure), et de l'effectif total N (coin inférieur droit).

$X \backslash Y$	y_1	y_2	y_3	Total
x_1	n_{11}	n_{12}	n_{13}	$n_{1\cdot}$
x_2	n_{21}	n_{22}	n_{23}	$n_{2\cdot}$
x_3	n_{31}	n_{32}	n_{33}	$n_{3\cdot}$
Total	$n_{\cdot 1}$	$n_{\cdot 2}$	$n_{\cdot 3}$	N

effectifs conjoints

effectifs marginaux de X

effectifs marginaux de Y

Structure d'un tableau à double entrée : en bleu les effectifs conjoints n_{ij} , en orange les totaux de lignes $n_{i\cdot}$, en vert les totaux de colonnes $n_{\cdot j}$, en violet l'effectif total N .

1.5 Données regroupées en classes et retour à la liste de couples

Centres de classes. Lorsque les valeurs de X ou de Y sont regroupées en classes (comme dans l'enquête de Douala), on ne connaît plus les valeurs exactes : on remplace chaque classe par son **centre**. Pour une classe $[a; b[$, le centre est $c = \frac{a+b}{2}$. Ainsi la classe $[20; 30[$ est représentée par le centre 25. Tous les calculs ultérieurs (moyennes, covariance, coefficient de corrélation) se feront sur les centres : c'est une approximation, mais c'est la convention officielle du programme.

Du tableau à la liste de couples. Pour les calculs des sections suivantes (point moyen, covariance, droites d'ajustement), il est souvent plus pratique de revenir à une liste de couples. Le principe : chaque case $(i; j)$ du tableau fournit le couple $(x_i; y_j)$ compté n_{ij} fois. Par exemple, dans l'enquête de Douala, la case $n_{22} = 9$ fournit neuf fois le couple $(25; 6,5)$. On obtient ainsi une série de 50 couples (avec répétitions), sur laquelle toutes les formules des séries à une variable pondérées s'appliquent.

À RETENIR L'essentiel de la section

- Une **série statistique à deux caractères** associe à chaque individu d'une population un couple $(x_i; y_i)$.
- Le **tableau à double entrée** croise les valeurs de X et de Y ; n_{ij} est l'effectif conjoint.
- Les **effectifs marginaux** s'obtiennent en sommant lignes ($n_{i\cdot}$) et colonnes ($n_{\cdot j}$); leur somme commune est N .
- Les **moyennes marginales** $\bar{x}$ et $\bar{y}$ sont les moyennes des séries marginales (avec les centres de classes si les données sont groupées).
- Réflexe de contrôle : $\sum n_{ij} = \sum n_{i\cdot} = \sum n_{\cdot j} = N$.

EXERCICE 1 Consommation selon l'âge du conducteur

Un assureur de Bafoussam étudie, sur 40 conducteurs, l'âge X (en années) et la consommation mensuelle de carburant Y (en litres). Le tableau à double entrée donne : $n_{11} = 6$, $n_{12} = 2$, $n_{13} = 1$ (ligne $[20; 30[$) ; $n_{21} = 5$, $n_{22} = 8$, $n_{23} = 3$ (ligne $[30; 40[$) ; $n_{31} = 2$, $n_{32} = 7$, $n_{33} = 6$ (ligne $[40; 50[$), les colonnes étant $[40; 70[$, $[70; 100[$ et $[100; 130[$.

1. Construire le tableau complet avec les effectifs marginaux et vérifier que $N = 40$.
2. Déterminer les séries marginales de X et de Y .
3. Calculer $\bar{x}$ et $\bar{y}$ à l'aide des centres de classes.

CORRIGÉ Exercice 1

1. Totaux de lignes : $n_{1.} = 6 + 2 + 1 = 9$; $n_{2.} = 5 + 8 + 3 = 16$; $n_{3.} = 2 + 7 + 6 = 15$. Totaux de colonnes : $n_{.1} = 6 + 5 + 2 = 13$; $n_{.2} = 2 + 8 + 7 = 17$; $n_{.3} = 1 + 3 + 6 = 10$. Contrôle : $9 + 16 + 15 = 40$ et $13 + 17 + 10 = 40$. ✓
2. Série marginale de X : $([20; 30[; 9)$, $([30; 40[; 16)$, $([40; 50[; 15)$. Série marginale de Y : $([40; 70[; 13)$, $([70; 100[; 17)$, $([100; 130[; 10)$.
3. Centres de X : 25, 35, 45 ; centres de Y : 55, 85, 115.

$$\bar{x} = \frac{9 \times 25 + 16 \times 35 + 15 \times 45}{40} = \frac{225 + 560 + 675}{40} = \frac{1460}{40} = 36,5 \text{ ans;}$$

$$\bar{y} = \frac{13 \times 55 + 17 \times 85 + 10 \times 115}{40} = \frac{715 + 1445 + 1150}{40} = \frac{3310}{40} = 82,75 \text{ litres.}$$

LESAVAIS-TU ? Pourquoi « marginal » ?

Le mot marginal vient tout simplement de la marge du tableau : les totaux $n_{i.}$ et $n_{.j}$ s'écrivent traditionnellement dans les bords droit et inférieur. La notation avec le point ($n_{i.}$) signifie « on a sommé sur l'indice remplacé par le point » : $n_{i.}$ est la somme sur toutes les valeurs de j . Ces séries marginales sont exactement les séries à une variable que tu as étudiées en Première : la statistique à deux variables les englobe et les relie. Dans la prochaine section, nous donnerons une image géométrique de ces données : le nuage de points, première étape vers la prévision des ventes de Mme Etoundi.

2 NUAGE DE POINTS ET POINT MOYEN

Dans la section précédente, nous avons appris à organiser les données d'une série statistique à deux caractères : tableau à double entrée, effectifs marginaux, lectures croisées. Mais un ta-

bleau de nombres, aussi bien présenté soit-il, ne parle pas immédiatement à l'œil. Or, en statistiques comme en géométrie, **voir** c'est déjà comprendre à moitié. Lorsqu'un gérant de station-service à Bonabéri observe ses ventes d'essence semaine après semaine, il ne veut pas seulement des chiffres : il veut deviner une tendance. C'est exactement le rôle du **nuage de points** : transformer un tableau de couples $(x_i ; y_i)$ en une image, puis résumer cette image par un point unique, le **point moyen**, qui en sera le « centre de gravité ».

2.1 Le nuage de points : donner une image aux données

Intuition. Chaque couple $(x_i ; y_i)$ de la série statistique est formé de deux nombres. Or deux nombres, c'est exactement ce qu'il faut pour placer un point dans un repère du plan : l'un en abscisse, l'autre en ordonnée. En plaçant ainsi tous les couples observés, on obtient un ensemble de points que l'on appelle, très naturellement, un nuage.

DÉFINITION Nuage de points

Soit une série statistique à deux variables constituée de n couples $(x_i ; y_i)$, i allant de 1 à n . Dans un repère orthogonal $(O ; \vec{i}, \vec{j})$ du plan, on appelle **nuage de points** associé à cette série l'ensemble des points M_i de coordonnées $(x_i ; y_i)$:

$$N = \{ M_i (x_i ; y_i) \mid i \in \{1, 2, \dots, n\} \}.$$

ATTENTION Deux variables, deux rôles

Par convention, la variable x (dite variable explicative) est portée en abscisse et la variable y (dite variable expliquée) en ordonnée. Au Baccalauréat, l'énoncé précise toujours lequel des deux caractères joue le rôle de x . Intervertir les axes change complètement l'allure du nuage et fausse toute la suite de l'exercice.

2.2 Construire un nuage lisible : le choix des échelles

Un nuage de points n'est utile que s'il est lisible. Un mauvais choix d'unités peut écraser le nuage sur une ligne ou le diluer dans une feuille entière. Voici la démarche professionnelle.

MÉTHODE Construire un nuage de points lisible

1. Repérer les plages de valeurs : noter les valeurs minimales et maximales de x et de y dans le tableau de données.
2. Choisir les unités graphiques de sorte que le nuage occupe une grande partie de la feuille (typiquement 10 à 15 cm dans chaque direction), sans être coupé. Les unités peuvent être différentes sur les deux axes : le repère est orthogonal, pas nécessairement orthonormé.

3. Décaler l'origine si nécessaire : si les valeurs de x sont toutes comprises entre 40 et 50, il est inutile de graduer l'axe depuis 0. On fait commencer l'axe à 40 (on dit qu'on effectue un zoom sur la zone utile), et on le signale proprement sur la copie.
4. Graduer régulièrement chaque axe et indiquer clairement les unités choisies (par exemple : « 1 cm représente 2 unités en abscisse »).
5. Placer les points $M_i(x_i; y_i)$ avec soin, en les marquant par des croix ou des petits points bien visibles. On ne relie jamais les points entre eux : un nuage n'est pas une courbe.

ATTENTION Pièges de construction

- Ne jamais relier les points du nuage : il n'y a aucune raison que la « courbe » passant par les points ait un sens, les observations étant dispersées.
- Ne pas oublier d'écrire les unités choisies sur la copie : au Baccalauréat, l'absence d'unités graphiques coûte des points de présentation.
- Un décalage d'origine doit être visible : on peut marquer une cassure sur l'axe ou écrire explicitement « l'axe des abscisses commence à 40 ».

2.3 Le point moyen : le centre de gravité du nuage

Intuition. Imagine que chaque point du nuage soit une petite bille de masse identique posée sur une plaque. La plaque resterait en équilibre si on la posait sur une pointe placée exactement sous le centre de gravité des billes. Ce centre de gravité, en statistiques, s'appelle le **point moyen** : ses coordonnées sont tout simplement les moyennes des coordonnées des points du nuage.

DÉFINITION Point moyen

Soit un nuage de n points $M_i(x_i; y_i)$. On appelle **point moyen** du nuage le point G de coordonnées $(\bar{x}; \bar{y})$, où :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{et} \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

Autrement dit : l'abscisse de G est la moyenne des x_i , et son ordonnée est la moyenne des y_i .

PROPRIÉTÉ Point moyen d'une série avec effectifs

Si la série est donnée par un tableau d'effectifs (chaque couple $(x_i; y_i)$ étant observé n_i fois, avec $n = \sum n_i$), alors :

$$\bar{x} = \frac{1}{n} \sum_i n_i x_i \quad \text{et} \quad \bar{y} = \frac{1}{n} \sum_i n_i y_i.$$

Le point moyen est alors le barycentre des points M_i affectés des coefficients n_i .

À RETENIR Ce qu'il faut retenir du point moyen

- G se calcule séparément sur chaque variable : moyenne des x , moyenne des y . C'est un calcul de moyenne de Première, appliqué deux fois.
- G résume la position du nuage, mais pas sa forme.
- Propriété fondamentale pour la suite de la leçon : la droite des moindres carrés (section 4) passe toujours par le point moyen G . C'est pourquoi on le calcule presque systématiquement.

ATTENTION Le point moyen n'est généralement pas un point du nuage

C'est l'erreur classique du candidat pressé : chercher G parmi les points M_i . Le point moyen est un point calculé, pas un point observé. Il peut tomber au milieu du nuage, dans une zone vide où aucune observation ne se trouve. De même, la moyenne des notes d'une classe n'est la note d'aucun élève en particulier. Sur la figure, on marque G d'un symbole différent (couleur, croix épaisse) pour bien le distinguer des points du nuage.

2.4 Exemple chiffré : les ventes de la station-service

Reprenons la situation qui nous servira de fil rouge dans toute la leçon. Le gérant d'une station-service de Douala a relevé, pendant 8 semaines, le prix de vente du litre d'essence (en centaines de FCFA au-dessus d'un prix de référence) et la quantité vendue (en milliers de litres).

Semaine i	1	2	3	4	5	6	7	8
x_i (prix, centaines F)	1	2	2	3	4	5	5	6
y_i (ventes, milliers L)	42	40	38	35	33	30	28	26


EXEMPLE Calcul du point moyen

Calculons les coordonnées de G :

$$\bar{x} = \frac{1+2+2+3+4+5+5+6}{8} = \frac{28}{8} = 3,5$$

$$\bar{y} = \frac{42+40+38+35+33+30+28+26}{8} = \frac{272}{8} = 34$$

Le point moyen est donc $G(3,5; 34)$. On remarque qu'aucune semaine ne correspond au couple $(3,5; 34)$: G n'est pas un point du nuage, conformément à la mise en garde précédente.



Nuage de points des ventes de la station-service (8 semaines).
Le point moyen G , marqué en rouge, n'est pas un point du nuage.

Sur cette figure, le nuage est visiblement allongé autour d'une direction descendante : quand le prix augmente, les ventes diminuent, et ce de façon assez régulière. C'est exactement le type de lecture que nous allons maintenant apprendre à formaliser.


2.5 Lecture qualitative d'un nuage : pressentir la corrélation

Avant tout calcul, un bon statisticien regarde son nuage. Trois questions suffisent :


1. **Le nuage est-il allongé ?** Si les points se regroupent autour d'une direction privilégiée, les deux variables semblent liées. Si le nuage est rond ou informe, les variables semblent indépendantes.
2. **Quelle est l'orientation ?** Si le nuage « monte » de gauche à droite, y a tendance à augmenter quand x augmente : on pressent une **corrélation positive**. S'il « descend », on pressent une **corrélation négative**.
3. **Quelle est la forme de l'allongement ?** Si le nuage s'allonge autour d'une droite, un ajustement affine (sections 3 et 4) est pertinent. S'il s'allonge autour d'une courbe (parabole,

exponentielle...), il faudra autre chose.


Corrélation positive forte



Corrélation négative



Absence de corrélation



Trois formes typiques de nuages : à gauche, un nuage allongé montant (corrélation positive forte); au centre, un nuage allongé descendant (corrélation négative); à droite, un nuage sans direction privilégiée (pas de corrélation linéaire).

À RETENIR
Vocabulaire de la lecture d'un nuage

- Nuage allongé autour d'une droite montante : corrélation linéaire positive pressentie.
- Nuage allongé autour d'une droite descendante : corrélation linéaire négative pressentie.
- Nuage arrondi, sans direction : pas de corrélation linéaire ; un ajustement affine n'a pas de sens.
- Nuage allongé autour d'une courbe : il existe une liaison, mais non linéaire ; l'ajustement affine direct est inadapté.

Cette lecture sera confirmée et mesurée par le coefficient de corrélation (section 5) : l'œil propose, le calcul dispose.

2.6 Et si le nuage n'est pas rectiligne ? (complément utile au Bac)

Il arrive — et le Baccalauréat aime cette situation — que le nuage soit nettement allongé mais courbé : croissance de plus en plus rapide (allure exponentielle), ou au contraire qui s'aplanit (allure logarithmique). Dans ce cas, chercher une droite d'ajustement sur $(x; y)$ serait une erreur.

MÉTHODE
Changement de variable (signalé comme complément au programme)

Lorsque le nuage des points $(x_i; y_i)$ n'est pas rectiligne, l'énoncé du Baccalauréat propose un **changement de variable** pour se ramener à un nuage rectiligne :

1. On pose une nouvelle variable, par exemple $z_i = \ln(y_i)$, ou $z_i = \sqrt{y_i}$, ou $z_i = \frac{1}{x_i}$ (c'est toujours l'énoncé qui le précise).
2. On dresse le nouveau tableau des couples $(x_i; z_i)$ et on construit le nouveau nuage.
3. Si ce nouveau nuage est rectiligne, on effectue l'ajustement affine de z en x : $z = ax + b$.
4. On revient à la variable initiale : par exemple, si $\ln y = ax + b$, alors $y = e^{ax+b} = e^b e^{ax}$: l'ajustement de y en x est exponentiel.

ATTENTION Ne pas oublier le retour à la variable initiale

L'erreur fatale : donner comme réponse finale $z = ax + b$ alors que la question porte sur y . Le changement de variable n'est qu'un détour de calcul ; la réponse doit toujours être exprimée avec les variables de départ, celles du contexte concret (prix, ventes, effectifs...).

EXERCICE RÉSOLU 2 Nuage, point moyen et lecture qualitative

Une agence MTN de Yaoundé étudie le lien entre le nombre x de spots publicitaires diffusés dans la semaine et le nombre y de nouvelles SIM activées (en centaines) :

x_i (spots)	2	4	5	7	8	10
y_i (centaines de SIM)	3	5	6	8	9	11

1. Calculer les coordonnées du point moyen G .
2. Le point G est-il un point du nuage ? Justifier.
3. Décrire qualitativement le nuage et dire si un ajustement affine semble pertinent.

SOLUTION

Solution détaillée.

1. On calcule séparément les deux moyennes :

$$\bar{x} = \frac{2+4+5+7+8+10}{6} = \frac{36}{6} = 6 \quad ; \quad \bar{y} = \frac{3+5+6+8+9+11}{6} = \frac{42}{6} = 7.$$

Donc $G(6; 7)$.

2. Le couple $(6; 7)$ ne figure pas dans le tableau : aucune semaine n'a donné 6 spots pour 700 SIM. Le point moyen n'est donc pas un point du nuage : c'est un point calculé, centre de gravité du nuage.
3. En plaçant les points, on observe qu'ils sont presque alignés autour d'une direction montante : quand le nombre de spots augmente, les activations augmentent de fa-

çon régulière. Le nuage est allongé et rectiligne, à corrélation positive forte : un ajustement affine est tout à fait pertinent. C'est ce que nous construirons dans les sections 3 et 4.

LESAVAIS-TU ? D'où vient le mot « régression » ?

Le terme régression, que nous rencontrerons dans la section 4 avec les « droites de régression », a une origine surprenante. En 1885, le savant britannique Francis Galton (cousin de Darwin) étudia la transmission de la taille entre pères et fils. Il constata que les fils des pères très grands étaient grands, mais moins que leurs pères, et que les fils des pères très petits étaient petits, mais moins que leurs pères : les tailles semblaient « revenir » vers la moyenne. Galton parla de régression vers la médiocrité. Le mot est resté, même si aujourd'hui il désigne simplement l'ensemble des méthodes d'ajustement. C'est en traçant des nuages de points de tailles (père, fils) et en cherchant leur point moyen que Galton a fondé la statistique à deux variables... exactement ce que tu viens d'apprendre à faire.

EXERCICE 2 À toi de jouer

Un coopérative agricole de l'Ouest a relevé, pour 6 exploitations, la surface x plantée en maïs (en hectares) et la récolte y (en tonnes) : (2 ; 5), (3 ; 7), (4 ; 9), (5 ; 10), (7 ; 15), (9 ; 18).

1. Construire le nuage de points (on choisira des unités adaptées et on les précisera).
2. Calculer les coordonnées du point moyen G et le placer sur la figure.
3. Un ajustement affine semble-t-il justifié ? Justifier par une lecture qualitative du nuage.

CORRIGÉ Exercice

1. Les valeurs de x vont de 2 à 9, celles de y de 5 à 18 : on peut prendre 1 cm pour 1 hectare en abscisse et 1 cm pour 2 tonnes en ordonnée, sans décalage d'origine. On place les six points, sans les relier.
2. $\bar{x} = \frac{2+3+4+5+7+9}{6} = \frac{30}{6} = 5$ et $\bar{y} = \frac{5+7+9+10+15+18}{6} = \frac{64}{6} \approx 10,67$. Donc $G(5; \frac{32}{3})$, soit environ $G(5; 10,67)$. On le marque d'un symbole distinct.
3. Le nuage est nettement allongé autour d'une direction montante : la récolte croît régulièrement avec la surface. La corrélation linéaire positive est forte : un ajustement affine est justifié.

Nous savons désormais voir une série à deux variables et la résumer par son point moyen. Mais regarder ne suffit pas : il faut maintenant tracer la droite qui résume le mieux le nuage. La section suivante présente une première méthode, simple et rapide, fondée précisément sur le point moyen : la **méthode de Mayer**.

3 AJUSTEMENT AFFINE PAR LA MÉTHODE DE MAYER

Dans la section précédente, nous avons appris à représenter une série statistique à deux variables par un **nuage de points** et à calculer son **point moyen** G . Nous avons aussi observé que, lorsque le nuage s'allonge autour d'une direction privilégiée, il est naturel de chercher une droite qui le « résume ». Mais comment choisir cette droite de manière objective, sans la tracer « au jugé » ? La **méthode de Mayer** est la première réponse rigoureuse à cette question : c'est une méthode simple, rapide, qui ne demande que des calculs de moyennes. Elle porte le nom de l'astronome allemand Tobias Mayer, qui l'utilisait au XVIII^e siècle pour ajuster ses observations de la Lune.

3.1 Principe de la méthode : partager le nuage en deux

Une idée toute simple.

Imagine un commerçant de Douala qui note chaque mois le prix du sac d'oignons et la quantité vendue. Les points obtenus s'alignent à peu près. Pour tracer une droite « au milieu » du nuage, l'idée de Mayer est la suivante : au lieu de chercher une droite qui passe « au milieu de tous les points » (problème difficile), on partage le nuage en **deux groupes** de même effectif, on calcule le point moyen de chaque groupe, et l'on trace la droite qui relie ces deux points moyens. Chaque point moyen « représente » fidèlement son groupe : la droite qui les joint passe donc naturellement au cœur du nuage.

DÉFINITION Partage du nuage selon Mayer

Soit un nuage de n points $M_i(x_i; y_i)$ d'une série statistique à deux variables. On ordonne les points par abscisses croissantes, puis on partage le nuage en deux sous-nuages de même effectif (ou d'effectifs différant d'une unité) :

- le premier sous-nuage contient les points de plus petites abscisses ;
- le second sous-nuage contient les points de plus grandes abscisses.

On note G_1 le point moyen du premier sous-nuage et G_2 celui du second.

DÉFINITION Droite de Mayer

On appelle **droite de Mayer** (ou droite d'ajustement affine par la méthode de Mayer) la droite (G_1G_2) passant par les points moyens des deux sous-nuages.

ATTENTION Classer avant de partager !

Le partage se fait impérativement après avoir rangé les points par abscisses croissantes, et non dans l'ordre du tableau de données. Si le tableau n'est pas trié, les deux groupes ne correspondent plus aux « petites » et « grandes » valeurs de x , et la droite obtenue peut être complètement fautive. C'est l'erreur la plus fréquente au Baccalauréat : vérifie toujours l'ordre des x_i avant de couper le nuage en deux.

3.2 Calcul des points moyens G_1 et G_2

Rappelons la formule du point moyen vue dans la section précédente : le point moyen d'un nuage de points $(x_i; y_i)$ a pour coordonnées les moyennes arithmétiques des coordonnées. On l'applique ici séparément à chaque sous-nuage.

PROPRIÉTÉ Coordonnées de G_1 et G_2

Si le premier sous-nuage contient les points $(x_1; y_1), \dots, (x_p; y_p)$ et le second les points $(x_{p+1}; y_{p+1}), \dots, (x_n; y_n)$, alors :

$$G_1 \left(\bar{x}_1 = \frac{x_1 + \dots + x_p}{p}; \bar{y}_1 = \frac{y_1 + \dots + y_p}{p} \right) \quad \text{et} \quad G_2 \left(\bar{x}_2 = \frac{x_{p+1} + \dots + x_n}{n - p}; \bar{y}_2 = \frac{y_{p+1} + \dots + y_n}{n - p} \right).$$

PROPRIÉTÉ La droite de Mayer équilibre les deux sous-nuages (admise)

La droite de Mayer ($G_1 G_2$) passe par deux points qui sont les « centres de gravité » respectifs de la moitié gauche et de la moitié droite du nuage. Elle réalise ainsi un équilibre : les écarts des points du premier groupe se compensent autour de G_1 , ceux du second groupe autour de G_2 .

EXPÉRIENCE Justification intuitive du partage

Pourquoi ce partage en deux donne-t-il une droite raisonnable ? Raisonnons pas à pas.

1. Le point moyen d'un nuage est son barycentre : la somme des écarts $\sum (y_i - \bar{y}) y$ est nulle. Autrement dit, G_1 est le point qui « résume » le mieux le premier groupe, et G_2 celui qui résume le mieux le second.
2. Une droite est entièrement déterminée par deux points. En imposant à la droite de passer par G_1 et G_2 , on la force à passer par les deux « centres » du nuage.
3. Comme G_1 est à gauche (petites valeurs de x) et G_2 à droite (grandes valeurs de x), la

droite (G_1G_2) traverse le nuage dans sa longueur, en suivant sa direction naturelle.

- De plus, on peut montrer que le point moyen global G du nuage complet est le barycentre de G_1 et G_2 affectés des effectifs des deux groupes ; il appartient donc à la droite (G_1G_2) : la droite de Mayer passe toujours par le point moyen G (lorsque les deux groupes ont le même effectif, G est même le milieu de $[G_1G_2]$).

Cette justification n'est pas exigible au Baccalauréat, mais elle éclaire pourquoi la méthode fonctionne.

À RETENIR Point moyen et droite de Mayer

La droite de Mayer passe par le **point moyen** G du nuage complet. C'est un excellent moyen de vérification : après avoir tracé la droite, contrôle qu'elle passe bien par $G(\bar{x} ; \bar{y})$.

3.3 Équation réduite de la droite de Mayer

Une fois $G_1(x_{G_1} ; y_{G_1})$ et $G_2(x_{G_2} ; y_{G_2})$ calculés, il reste à déterminer l'équation réduite $y = ax + b$ de la droite (G_1G_2) . C'est un calcul classique de Première.

PROPRIÉTÉ Équation de la droite (G_1G_2)

Comme $x_{G_1} \neq x_{G_2}$ (les deux groupes portent sur des plages distinctes de valeurs de x), la droite (G_1G_2) n'est pas verticale et admet une équation réduite $y = ax + b$ avec :

$$a = \frac{y_{G_2} - y_{G_1}}{x_{G_2} - x_{G_1}} \quad \text{et} \quad b = y_{G_1} - a x_{G_1}.$$

MÉTHODE Déterminer une droite d'ajustement par la méthode de Mayer

- Ordonner les points du nuage par abscisses croissantes.
- Partager le nuage en deux sous-nuages de même effectif (ou quasi si n est impair).
- Calculer les coordonnées des points moyens G_1 et G_2 de chaque sous-nuage (moyennes des abscisses, moyennes des ordonnées).
- Calculer le coefficient directeur $a = \frac{y_{G_2} - y_{G_1}}{x_{G_2} - x_{G_1}}$.
- Calculer l'ordonnée à l'origine $b = y_{G_1} - a x_{G_1}$ (on peut aussi utiliser G_2 : le résultat doit être identique, c'est une vérification).

6. Écrire l'équation $y = ax + b$ et tracer la droite sur le nuage, en vérifiant qu'elle passe par le point moyen G .

3.4 Exemple complet : les ventes de carburant

EXEMPLE Ventes de carburant à la station d'Ebolowa

Une station-service d'Ebolowa relève, pendant 8 semaines, le prix de vente du litre d'essence x_i (en centaines de FCFA au-dessus d'un prix de référence) et le volume hebdomadaire vendu y_i (en milliers de litres). Les données, déjà rangées par abscisses croissantes, sont :

Semaine	1	2	3	4	5	6	7	8
x_i	1	2	3	4	5	6	7	8
y_i	2	3	4	4,6	5	6,4	7	8

Étape 1 et 2 : partage. L'effectif est $n = 8$, pair : on partage en deux groupes de 4 points.

Groupe 1 : (1; 2), (2; 3), (3; 4), (4; 4,6) Groupe 2 : (5; 5), (6; 6,4), (7; 7), (8; 8).

Étape 3 : points moyens.

$$G_1 : \bar{x}_1 = \frac{1+2+3+4}{4} = \frac{10}{4} = 2,5$$

$$\bar{y}_1 = \frac{2+3+4+4,6}{4} = \frac{13,6}{4} = 3,4$$

$$G_2 : \bar{x}_2 = \frac{5+6+7+8}{4} = \frac{26}{4} = 6,5$$

$$\bar{y}_2 = \frac{5+6,4+7+8}{4} = \frac{26,4}{4} = 6,6$$

Donc $G_1(2,5; 3,4)$ et $G_2(6,5; 6,6)$.

Étapes 4 et 5 : équation.


$$a = \frac{6,6 - 3,4}{6,5 - 2,5} = \frac{3,2}{4} = 0,8 \quad b = 3,4 - 0,8 \times 2,5 = 3,4 - 2 = 1,4.$$

Vérification avec G_2 : $b = 6,6 - 0,8 \times 6,5 = 6,6 - 5,2 = 1,4$. Cohérent.

Étape 6 : conclusion. La droite de Mayer a pour équation :

$$y = 0,8x + 1,4$$

Vérification par le point moyen global : $\bar{x} = \frac{1+2+\dots+8}{8} = 4,5$ et $\bar{y} = \frac{40}{8} = 5$. Or $0,8 \times 4,5 + 1,4 = 3,6 + 1,4 = 5 = \bar{y}$: le point $G(4,5; 5)$ est bien sur la droite.



Nuage des ventes de carburant partagé en deux sous-nuages (bleu et orange), points moyens G_1 et G_2 , et droite de Mayer passant par le point moyen global G .

Lecture graphique.

Sur la figure, on observe que la droite de Mayer traverse le nuage dans sa longueur : les points bleus (petites valeurs de x) gravitent autour de G_1 , les points orange autour de G_2 , et la droite passe bien par le point moyen G . C'est la **vérification graphique** à effectuer systématiquement : si ta droite semble « à côté » du nuage, il y a une erreur de calcul ou de partage.

3.5 Cas d'un nombre impair de points

Lorsque n est impair, on ne peut pas partager le nuage en deux groupes de même effectif. Deux conventions sont admises ; l'énoncé du Baccalauréat précise toujours laquelle utiliser.

À RETENIR Conventions pour n impair

Si le nuage comporte $n = 2p + 1$ points, le point médian (celui de rang $p + 1$) peut être :

- exclu du calcul : les deux groupes ont alors chacun p points ;
- affecté aux deux groupes : chaque groupe contient alors $p + 1$ points, le point médian comptant deux fois.

Les deux conventions donnent des droites légèrement différentes : applique strictement celle indiquée dans l'énoncé.

EXERCICE RÉSOLU 3 Nuage de 7 points : dépenses de connexion Internet

Une cybercaféteria de Bafoussam relève pendant 7 jours le nombre de clients x_i et la re-

cette y_i (en milliers de FCFA). Les données sont déjà triées :

x_i	10	15	20	25	30	35	40
y_i	5	7	9	10	13	14	17

Déterminer l'équation de la droite de Mayer en excluant le point médian.

SOLUTION

Solution. L'effectif est $n = 7$: le point médian est le 4^e point (25 ; 10), que l'on exclut. Les deux groupes sont :

Groupe 1 : (10 ; 5), (15 ; 7), (20 ; 9) Groupe 2 : (30 ; 13), (35 ; 14), (40 ; 17).

Points moyens :

$$G_1\left(\frac{10+15+20}{3}; \frac{5+7+9}{3}\right) = G_1(15; 7), \quad G_2\left(\frac{30+35+40}{3}; \frac{13+14+17}{3}\right) = G_2\left(35; \frac{44}{3}\right).$$

Coefficient directeur :

$$a = \frac{\frac{44}{3} - 7}{35 - 15} = \frac{\frac{44-21}{3}}{20} = \frac{23}{60} \approx 0,383.$$

Ordonnée à l'origine : $b = 7 - \frac{23}{60} \times 15 = 7 - \frac{23}{4} = \frac{5}{4} = 1,25$. La droite de Mayer a donc pour équation $y = \frac{23}{60}x + \frac{5}{4}$, soit approximativement $y \approx 0,38x + 1,25$.

3.6 Limites de la méthode de Mayer

La méthode de Mayer est séduisante par sa simplicité : quelques moyennes et une équation de droite suffisent. Mais il faut connaître ses faiblesses pour l'utiliser à bon escient.

ATTENTION Limites de la méthode de Mayer

- **Dépendance au découpage.** Le résultat dépend de la façon dont on partage le nuage (surtout pour n impair). Deux découpages différents donnent deux droites différentes : la méthode ne fournit pas une droite « unique et optimale ».
- **Perte d'information.** Seules les moyennes des deux groupes interviennent : deux nuages très différents peuvent avoir les mêmes G_1 et G_2 , donc la même droite de Mayer.
- **Sensibilité aux points extrêmes.** Un point aberrant (erreur de saisie, événement exceptionnel) déplace fortement le point moyen de son groupe, donc la droite entière.
- **Moins précise que les moindres carrés.** La méthode des moindres carrés, que nous étudierons dans la section suivante, utilise tous les points et minimise globalement les écarts : elle fournit un ajustement mathématiquement optimal, au prix de calculs plus

lourds.

En résumé : la méthode de Mayer est rapide et suffisante pour une première estimation, mais la droite des moindres carrés lui est généralement préférée dès qu'on dispose d'une calculatrice.

LESAVAIS-TU ? Tobias Mayer, astronome cartographe

Tobias Mayer (1723–1762) était astronome à l'observatoire de Göttingen. Pour cartographier la surface de la Lune avec une précision inédite, il devait combiner de nombreuses observations entachées d'erreurs : c'est ainsi qu'il eut l'idée de regrouper ses mesures et de moyenner les groupes, ancêtre de notre méthode. Ses cartes lunaires sont restées des références pendant des décennies. Aujourd'hui encore, au Cameroun, les techniciens de CAMTEL ou les météorologues qui ajustent des relevés dispersés utilisent, sans le savoir, l'héritage de cette idée : résumer des groupes de données par leurs moyennes avant d'ajuster un modèle.

EXERCICE 3 À toi de jouer : livraisons d'une brasserie

Une brasserie de Yaoundé note, sur 6 livraisons, la distance parcourue x_i (en dizaines de km) et la consommation de gasoil y_i (en litres) :

x_i	1	2	3	4	5	6
y_i	9	12	14	17	20	22

1. Déterminer les points moyens G_1 et G_2 des deux sous-nuages.
2. En déduire l'équation de la droite de Mayer.
3. Vérifier qu'elle passe par le point moyen G du nuage.

CORRIGÉ Exercice : livraisons d'une brasserie

1. Groupe 1 : $(1; 9), (2; 12), (3; 14)$, donc $G_1(2; \frac{35}{3})$ soit environ $G_1(2; 11,67)$. Groupe 2 : $(4; 17), (5; 20), (6; 22)$, donc $G_2(5; \frac{59}{3})$ soit environ $G_2(5; 19,67)$.
2. $a = \frac{\frac{59}{3} - \frac{35}{3}}{5 - 2} = \frac{8}{3} \approx 2,67$ et $b = \frac{35}{3} - \frac{8}{3} \times 2 = \frac{19}{3} \approx 6,33$. D'où $y = \frac{8}{3}x + \frac{19}{3}$.
3. $\bar{x} = 3,5$ et $\bar{y} = \frac{94}{6} = \frac{47}{3}$. Or $\frac{8}{3} \times 3,5 + \frac{19}{3} = \frac{28}{3} + \frac{19}{3} = \frac{47}{3} = \bar{y}$: G est bien sur la droite.

4 COVARIANCE ET MOINDRES CARRÉS

4.1 Pourquoi dépasser la méthode de Mayer ?

Dans la section précédente, tu as appris à ajuster un nuage de points par la **méthode de Mayer** : on partage le nuage en deux sous-nuages, on calcule leurs points moyens G_1 et G_2 , et l'on trace la droite (G_1G_2) . Cette méthode est rapide et donne souvent un résultat correct. Mais elle souffre de deux défauts majeurs :

- le résultat dépend du découpage choisi : deux élèves qui regroupent différemment les points obtiennent deux droites différentes ;
- aucun critère ne garantit que la droite obtenue est la « meilleure possible » : elle passe par deux points moyens, certes, mais rien ne dit qu'elle minimise l'erreur commise en remplaçant le nuage par une droite.

Les mathématiciens Legendre et Gauss, au tout début du XIX^e siècle, ont posé la bonne question : quelle droite rend la plus petite possible l'erreur globale d'ajustement ? Leur réponse, la méthode des **moindres carrés**, repose sur un outil nouveau qui mesure la façon dont deux caractères varient ensemble : la **covariance**. C'est l'objet de cette section, au cœur du programme de Terminale et très fréquente au Baccalauréat.

4.2 La covariance : mesurer la variation conjointe de deux caractères

Intuition. Reprenons notre station-service de la route Yaoundé-Douala. On note X le nombre de véhicules passant devant la station chaque jour et Y le volume de carburant vendu (en hectolitres). Les jours où le trafic X est au-dessus de sa moyenne, les ventes Y sont-elles plutôt au-dessus ou en dessous de leur moyenne ? Pour le savoir, l'idée naturelle est de regarder, pour chaque jour i , le produit des écarts aux moyennes :

$$(x_i - \bar{x})(y_i - \bar{y}).$$

Si x_i et y_i sont tous deux au-dessus (ou tous deux en dessous) de leur moyenne, ce produit est **positif**. Si l'un est au-dessus et l'autre en dessous, il est **négatif**. En faisant la moyenne de tous ces produits, on obtient un nombre qui résume le sens de la variation conjointe des deux caractères : c'est la covariance.

DÉFINITION Covariance de deux variables statistiques

Soit une série statistique double $(x_i ; y_i)_{1 \leq i \leq n}$ d'effectif total N , de moyennes $\bar{x}$ et $\bar{y}$. On appelle **covariance** du couple $(X ; Y)$ le nombre réel noté $\text{cov}(X, Y)$ défini par :

$$\text{cov}(X, Y) = \frac{1}{N} \sum_{i=1}^n n_i (x_i - \bar{x})(y_i - \bar{y}).$$

En développant le produit et en utilisant $\frac{1}{N} \sum n_i x_i = \bar{x}$ et $\frac{1}{N} \sum n_i y_i = \bar{y}$, on obtient la forme

développée, beaucoup plus pratique pour les calculs :

$$\text{cov}(X, Y) = \frac{1}{N} \sum_{i=1}^n n_i x_i y_i - \bar{x} \bar{y}$$

Autrement dit : moyenne des produits moins produit des moyennes.

À RETENIR Signe de la covariance

- Si $\text{cov}(X, Y) > 0$: les deux caractères ont tendance à varier dans le même sens (quand l'un augmente, l'autre augmente globalement). Le nuage « monte ».
- Si $\text{cov}(X, Y) < 0$: les deux caractères ont tendance à varier en sens contraires. Le nuage « descend ».
- Si $\text{cov}(X, Y) \approx 0$: il n'y a pas de tendance linéaire globale entre les deux caractères.

Lien avec la variance. Tu connais déjà la variance d'une série simple : $V(X) = \frac{1}{N} \sum n_i (x_i - \bar{x})^2$. Or $(x_i - \bar{x})^2 = (x_i - \bar{x})(x_i - \bar{x})$, donc la variance n'est rien d'autre qu'une covariance particulière :

$$V(X) = \text{cov}(X, X) \quad \text{et} \quad V(Y) = \text{cov}(Y, Y).$$

La covariance généralise donc la variance : au lieu de mesurer comment un caractère varie par rapport à lui-même, elle mesure comment deux caractères varient l'un par rapport à l'autre.

ATTENTION La covariance dépend des unités

Contrairement au coefficient de corrélation que tu verras dans la section suivante, la covariance dépend des unités choisies : exprimer les ventes en litres plutôt qu'en hectolitres multiplie la covariance par 100%. On ne peut donc pas comparer directement deux covariances issues de séries différentes, ni conclure à une corrélation « forte » ou « faible » à partir de sa seule valeur. Son signe, en revanche, est toujours interprétable.

4.3 Le principe des moindres carrés

Intuition. Cherchons une droite d'équation $y = ax + b$ qui « colle » au mieux au nuage. Pour chaque point $M_i(x_i; y_i)$, la droite prédit la valeur $ax_i + b$, alors que la valeur réellement observée est y_i . L'écart vertical (ou **résidu**) est :


$$e_i = y_i - (ax_i + b).$$

On veut rendre tous ces écarts petits simultanément. On ne peut pas simplement additionner les e_i , car les écarts positifs et négatifs se compenseraient. L'idée de Gauss : élever chaque

écart au carré (ce qui les rend tous positifs et pénalise fortement les gros écarts), puis chercher a et b qui **minimisent** la somme :

$$S(a,b) = \sum_{i=1}^n n_i (y_i - ax_i - b)^2.$$

D'où le nom : méthode des moindres carrés.



La droite des moindres carrés minimise la somme des carrés des segments verticaux (résidus e_i) figurés en orange. Elle passe par le point moyen G .

PROPRIÉTÉ Droite de régression de y en x — démonstration exigible

Soit une série double de covariance $\text{cov}(X,Y)$, avec $V(X) \neq 0$. Il existe une unique droite qui minimise $S(a,b)$: c'est la **droite de régression de y en x** , notée $D_{y/x}$, d'équation :

$$y - \bar{y} = \frac{\text{cov}(X,Y)}{V(X)} (x - \bar{x})$$

Son coefficient directeur $a = \frac{\text{cov}(X,Y)}{V(X)}$ a donc le signe de la covariance.

EXPÉRIENCE Démonstration guidée du théorème des moindres carrés

On cherche a et b minimisant $S(a,b) = \sum n_i (y_i - ax_i - b)^2$. On procède en deux étapes, en étudiant le trinôme du second degré obtenu (ou en annulant la dérivée).

Étape 1 : choix optimal de b , à a fixé. Écrivons $y_i - ax_i - b = [(y_i - ax_i) - b]$ et posons $z_i = y_i - ax_i$. Alors $S = \sum n_i (z_i - b)^2$. Développons :

$$S = \sum n_i z_i^2 - 2b \sum n_i z_i + Nb^2.$$

À a fixé, c'est un trinôme du second degré en b , de coefficient dominant $N > 0$: il est minimal lorsque sa dérivée s'annule, c'est-à-dire $-2 \sum n_i z_i + 2Nb = 0$, soit :

$$b = \frac{1}{N} \sum n_i z_i = \frac{1}{N} \sum n_i (y_i - ax_i) = \bar{y} - a\bar{x}.$$

Ainsi, quel que soit a , le meilleur b vérifie $\bar{y} = a\bar{x} + b$: la droite optimale passe forcément par le point moyen $G(\bar{x}; \bar{y})$.

Étape 2 : choix optimal de a . Reportons $b = \bar{y} - a\bar{x}$ dans S :

$$S(a) = \sum n_i [(y_i - \bar{y}) - a(x_i - \bar{x})]^2.$$

En développant (les sommes portent sur i , pondérées par n_i , et l'on divise par N pour faire apparaître les quantités connues) :

$$\frac{S(a)}{N} = V(Y) - 2a \operatorname{cov}(X, Y) + a^2 V(X).$$

C'est un trinôme du second degré en a , de coefficient dominant $V(X) > 0$: il atteint son minimum en

$$a = -\frac{-2 \operatorname{cov}(X, Y)}{2V(X)} = \frac{\operatorname{cov}(X, Y)}{V(X)}.$$

Conclusion. La droite minimisant la somme des carrés des écarts a pour coefficient directeur $a = \frac{\operatorname{cov}(X, Y)}{V(X)}$ et passe par G : son équation est bien $y - \bar{y} = \frac{\operatorname{cov}(X, Y)}{V(X)}(x - \bar{x})$. ■

PROPRIÉTÉ Propriété fondamentale : passage par le point moyen

La droite de régression de y en x passe par le point moyen $G(\bar{x}; \bar{y})$. C'est une conséquence directe de la forme de son équation : pour $x = \bar{x}$, on obtient $y = \bar{y}$. On verra ci-dessous que la droite de régression de x en y passe elle aussi par G .

4.4 La droite de régression de x en y

Jusqu'ici, nous avons cherché à prédire y à partir de x en minimisant les écarts **verticaux**. Mais on peut vouloir faire l'inverse : prédire x à partir de y (par exemple, estimer le trafic à partir des ventes observées). On minimise alors la somme des carrés des écarts **horizontaux** $\sum n_i (x_i - a'y_i - b')^2$. Le calcul est rigoureusement le même, en échangeant les rôles de x et y :

PROPRIÉTÉ Droite de régression de x en y

La **droite de régression de x en y** , notée $D_{x/y}$, a pour équation :

$$x - \bar{x} = \frac{\text{cov}(X,Y)}{V(Y)} (y - \bar{y})$$

Elle passe également par le point moyen G .


Comparaison des deux droites. Les deux droites $D_{y/x}$ et $D_{x/y}$ passent toutes deux par G : elles sont donc **sécantes en G** , sauf cas exceptionnel. Sont-elles confondues ? Rapportées au même repère, leurs coefficients directeurs respectifs sont :

$$a = \frac{\text{cov}(X,Y)}{V(X)} \quad \text{et} \quad \frac{1}{a'} = \frac{V(Y)}{\text{cov}(X,Y)}.$$

Elles sont confondues si et seulement si $a = \frac{1}{a'}$, c'est-à-dire $[\text{cov}(X,Y)]^2 = V(X)V(Y)$. On démontrera dans la section suivante que cela n'arrive que lorsque les points sont **parfaitement alignés** (corrélation parfaite). Plus le nuage est resserré autour d'une droite, plus les deux droites de régression sont proches l'une de l'autre ; plus le nuage est dispersé, plus l'angle entre elles est grand.

ATTENTION Les deux droites ne sont pas réciproques l'une de l'autre

Erreur classique au Baccalauréat : croire que $D_{x/y}$ s'obtient en « isolant x » dans l'équation de $D_{y/x}$. C'est faux ! Si l'on isole x dans $y - \bar{y} = a(x - \bar{x})$, on obtient $x - \bar{x} = \frac{1}{a}(y - \bar{y})$ avec $\frac{1}{a} = \frac{V(X)}{\text{cov}(X,Y)}$, alors que le vrai coefficient de $D_{x/y}$ est $\frac{\text{cov}(X,Y)}{V(Y)}$. Ces deux coefficients ne sont égaux que si la corrélation est parfaite. Chaque droite répond à une question différente : $D_{y/x}$ sert à prédire y connaissant x , $D_{x/y}$ sert à prédire x connaissant y .



Les deux droites de régression sont sécantes au point moyen G .
Elles ne sont confondues que si les points sont parfaitement alignés.

4.5 Organisation des calculs et exemple complet

Les formules font intervenir $\bar{x}$, $\bar{y}$, $\sum n_i x_i^2$, $\sum n_i y_i^2$ et $\sum n_i x_i y_i$. Pour éviter toute erreur, on rassemble tout dans un tableau à cinq colonnes.

MÉTHODE Organiser les calculs en tableau

1. Construire un tableau à colonnes x_i , y_i , x_i^2 , y_i^2 , $x_i y_i$ (avec pondération par les effectifs n_i si la série est groupée), puis une ligne « Totaux » contenant $\sum n_i x_i$, $\sum n_i y_i$, $\sum n_i x_i^2$, $\sum n_i y_i^2$, $\sum n_i x_i y_i$.
2. Calculer les moyennes : $\bar{x} = \frac{\sum n_i x_i}{N}$ et $\bar{y} = \frac{\sum n_i y_i}{N}$.
3. Calculer les variances par la formule de König-Huygens : $V(X) = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$ et $V(Y) = \frac{\sum n_i y_i^2}{N} - \bar{y}^2$.
4. Calculer la covariance : $\text{cov}(X, Y) = \frac{\sum n_i x_i y_i}{N} - \bar{x} \bar{y}$.
5. En déduire les équations : $y - \bar{y} = \frac{\text{cov}(X, Y)}{V(X)}(x - \bar{x})$ et $x - \bar{x} = \frac{\text{cov}(X, Y)}{V(Y)}(y - \bar{y})$.
6. Vérification rapide : le point $G(\bar{x}; \bar{y})$ doit appartenir aux deux droites obtenues.

EXERCICE RÉSOLU 4 Ventes de carburant à la station Total de Mbankomo

Le gérant d'une station-service relève, pendant 6 jours, le nombre x_i de véhicules (en dizaines) passant devant la station et le volume y_i de carburant vendu (en hectolitres) :

Jour	1	2	3	4	5	6
x_i (dizaines de véhicules)	8	10	12	14	16	18
y_i (hL)	12	15	16	20	21	26

1. Calculer $\text{cov}(X,Y)$ et interpréter son signe.
2. Déterminer l'équation de la droite de régression de y en x .
3. Déterminer l'équation de la droite de régression de x en y .

SOLUTION

Solution détaillée. On complète le tableau de calcul :

x_i	y_i	x_i^2	y_i^2	$x_i y_i$
8	12	64	144	96
10	15	100	225	150
12	16	144	256	192
14	20	196	400	280
16	21	256	441	336
18	26	324	676	468
Totaux ($\sum x_i = 78$)	$\sum y_i = 110$	$\sum x_i^2 = 1084$	$\sum y_i^2 = 2142$	$\sum x_i y_i = 1522$

avec $N = 6$.

1. Moyennes, variances et covariance.

$$\bar{x} = \frac{78}{6} = 13 \quad ; \quad \bar{y} = \frac{110}{6} = \frac{55}{3} \approx 18,33.$$

$$V(X) = \frac{1084}{6} - 13^2 = \frac{1084}{6} - 169 = \frac{1084 - 1014}{6} = \frac{70}{6} = \frac{35}{3} \approx 11,67.$$

$$V(Y) = \frac{2142}{6} - \left(\frac{55}{3}\right)^2 = 357 - \frac{3025}{9} = \frac{3213 - 3025}{9} = \frac{188}{9} \approx 20,89.$$

$$\text{cov}(X,Y) = \frac{1522}{6} - 13 \times \frac{55}{3} = \frac{1522}{6} - \frac{715}{3} = \frac{1522 - 1430}{6} = \frac{92}{6} = \frac{46}{3} \approx 15,33.$$

La covariance est positive : trafic et ventes varient dans le même sens, ce qui confirme l'intuition du gérant — plus il passe de véhicules, plus on vend de carburant.

2. Droite de régression de y en x .

$$a = \frac{\text{cov}(X,Y)}{V(X)} = \frac{46/3}{35/3} = \frac{46}{35} \approx 1,314.$$

L'équation est $y - \frac{55}{3} = \frac{46}{35}(x - 13)$, soit en forme réduite :

$$y = \frac{46}{35}x + \frac{55}{3} - \frac{46 \times 13}{35} = \frac{46}{35}x + \frac{1925 - 1794}{105} = \frac{46}{35}x + \frac{131}{105} \approx 1,31x + 1,25.$$

Vérification : pour $x = \bar{x} = 13$, $y = \frac{46}{35} \times 13 + \frac{131}{105} = \frac{1794}{105} + \frac{131}{105} = \frac{1925}{105} = \frac{55}{3} = \bar{y}$. La droite passe bien par G.

3. Droite de régression de x en y .

$$a' = \frac{\text{cov}(X,Y)}{V(Y)} = \frac{46/3}{188/9} = \frac{46}{3} \times \frac{9}{188} = \frac{414}{564} = \frac{69}{94} \approx 0,734.$$

L'équation est $x - 13 = \frac{69}{94}\left(y - \frac{55}{3}\right)$, soit $x = \frac{69}{94}y + \frac{21}{94} \approx 0,73y + 0,22$. On remarque que $\frac{1}{a} = \frac{35}{46} \approx 0,76 \neq a' \approx 0,73$: les deux droites sont bien distinctes, comme prévu.

EXERCICE 4 À toi de jouer

Une coopérative de planteurs de la région de l'Ouest relève, pour 5 exploitations, la surface x_i plantée en cacao (en ha) et la récolte y_i (en tonnes) : (2 ; 1,4), (3 ; 2,1), (5 ; 3,0), (6 ; 3,8), (9 ; 5,7).

1. Calculer $\bar{x}$, $\bar{y}$, $V(X)$, $V(Y)$ et $\text{cov}(X,Y)$.
2. Déterminer l'équation réduite de la droite de régression de y en x .
3. Vérifier que G appartient à cette droite.

CORRIGÉ Exercice : coopérative de planteurs

1. Tableau de calculs :

x_i	y_i	x_i^2	y_i^2	$x_i y_i$
2	1,4	4	1,96	2,8
3	2,1	9	4,41	6,3
5	3,0	25	9,00	15,0
6	3,8	36	14,44	22,8
9	5,7	81	32,49	51,3
Totaux	16,0	155	62,30	98,2

$$\sum x_i = 25, N = 5.$$

$$\bar{x} = \frac{25}{5} = 5 \quad ; \quad \bar{y} = \frac{16,0}{5} = 3,2$$

$$V(X) = \frac{155}{5} - 5^2 = 31 - 25 = 6$$

$$V(Y) = \frac{62,30}{5} - 3,2^2 = 12,46 - 10,24 = 2,22$$

$$\text{cov}(X, Y) = \frac{98,2}{5} - 5 \times 3,2 = 19,64 - 16 = 3,64$$

$$2. a = \frac{\text{cov}(X, Y)}{V(X)} = \frac{3,64}{6} = \frac{91}{150} \approx 0,6067. b = \bar{y} - a\bar{x} = 3,2 - \frac{91}{150} \times 5 = 3,2 - \frac{91}{30} = \frac{96 - 91}{30} = \frac{5}{30} = \frac{1}{6} \approx 0,1667. \text{ D'où } D_{y/x} : y = \frac{91}{150}x + \frac{1}{6} \approx 0,607x + 0,167.$$

3. Pour $x = 5 : y = \frac{91}{150} \times 5 + \frac{1}{6} = \frac{91}{30} + \frac{5}{30} = \frac{96}{30} = 3,2 = \bar{y}$. Le point $G(5; 3,2)$ appartient bien à la droite.

LES AVAIS-TU ? Gauss, Legendre et l'astéroïde Cérès

La méthode des moindres carrés est née d'une querelle de priorité entre deux géants : Adrien-Marie Legendre la publie en 1805, mais Carl Friedrich Gauss affirme l'utiliser depuis 1795. C'est Gauss qui lui doit sa consécration spectaculaire : en 1801, l'astéroïde Cérès, aperçu puis « perdu » par les astronomes, fut retrouvé exactement là où Gauss l'avait prédit grâce à un ajustement par moindres carrés des rares observations disponibles. Aujourd'hui, cette méthode est partout : prévisions de consommation d'électricité à ENEO, estimation du trafic par les opérateurs MTN et Orange, modèles agricoles de l'IRAD... Chaque fois qu'on prédit une grandeur à partir d'une autre, Gauss est dans la place.

À RETENIR L'essentiel de la section

- $\text{cov}(X, Y) = \frac{1}{N} \sum n_i x_i y_i - \bar{x} \bar{y}$; son signe indique le sens de la variation conjointe.
- $V(X) = \text{cov}(X, X)$ et $V(Y) = \text{cov}(Y, Y)$.
- Droite de régression de y en x : $y - \bar{y} = \frac{\text{cov}(X, Y)}{V(X)}(x - \bar{x})$.
- Droite de régression de x en y : $x - \bar{x} = \frac{\text{cov}(X, Y)}{V(Y)}(y - \bar{y})$.
- Les deux droites passent par $G(\bar{x}; \bar{y})$ et ne sont confondues que si les points sont parfaitement alignés.
- Les calculs s'organisent toujours dans un tableau à colonnes $x_i, y_i, x_i^2, y_i^2, x_i y_i$.

Reste une question en suspens : nous savons désormais construire la meilleure droite, mais comment juger si cet ajustement est de bonne qualité, et s'il autorise des prévisions fiables ? C'est

précisément le rôle du coefficient de corrélation linéaire, que nous étudions dans la section suivante.

5 COEFFICIENT DE CORRÉLATION LINÉAIRE

Dans la section précédente, nous avons appris à construire les droites de régression par la méthode des moindres carrés : la droite de régression de y en x , d'équation $y = ax + b$ avec $a = \frac{\text{cov}(X,Y)}{V(X)}$, et la droite de régression de x en y , d'équation $x = a'y + b'$ avec $a' = \frac{\text{cov}(X,Y)}{V(Y)}$. Mais une question fondamentale reste en suspens : **ces droites ont-elles un sens ?** Après tout, on peut calculer une droite des moindres carrés pour n'importe quel nuage de points, même un nuage complètement dispersé qui ne ressemble à rien ! Il nous faut donc un **indicateur numérique** capable de mesurer la qualité de l'alignement des points, avant de se lancer dans un ajustement et des prévisions. Cet indicateur, c'est le **coefficient de corrélation linéaire**, noté r . C'est lui qui dira : « oui, un ajustement affine est justifié » ou « non, méfie-toi, ces points ne suivent pas une tendance linéaire ».

5.1 Définition et premières propriétés

Intuition.

La covariance $\text{cov}(X,Y)$ mesure déjà le sens de la relation entre X et Y : positive si les deux variables varient dans le même sens, négative sinon. Mais elle possède un défaut majeur : elle dépend des unités. Une covariance de 12 entre une taille en centimètres et une masse en kilogrammes ne veut rien dire en soi ; la même covariance vaudrait 0,12 si les tailles étaient exprimées en mètres. Pour comparer des situations différentes, il faut « normaliser » la covariance en la divisant par les écarts types des deux variables. On obtient alors un nombre sans unité, toujours compris entre -1 et 1 : c'est le coefficient de corrélation linéaire.

DÉFINITION Coefficient de corrélation linéaire

Soit (X, Y) une série statistique double dont les variances $V(X)$ et $V(Y)$ sont non nulles. Le **coefficient de corrélation linéaire** de X et Y est le nombre réel noté r défini par :

$$r = \frac{\text{cov}(X,Y)}{\sqrt{V(X)V(Y)}} = \frac{\text{cov}(X,Y)}{\sigma_X \cdot \sigma_Y}$$

où $\sigma_X = \sqrt{V(X)}$ et $\sigma_Y = \sqrt{V(Y)}$ sont les écarts types de X et de Y .

PROPRIÉTÉ Encadrement de r — admis

Pour toute série statistique double (X,Y) de variances non nulles :

$$-1 \leq r \leq 1.$$

Ce résultat est une conséquence de l'**inégalité de Cauchy-Schwarz**, qui affirme que $(\text{cov}(X, Y))^2 \leq V(X)V(Y)$. Cette inégalité est admise en Terminale.

De plus, on a les cas limites suivants :

- $r = 1$ si et seulement si tous les points du nuage sont alignés sur une droite de coefficient directeur strictement positif ;
- $r = -1$ si et seulement si tous les points du nuage sont alignés sur une droite de coefficient directeur strictement négatif.

EXPÉRIENCE Pourquoi $r = \pm 1$ signifie que les points sont alignés

Cette démonstration guidée est formatrice : elle utilise la somme des carrés des écarts, déjà rencontrée avec les moindres carrés. On considère les variables centrées $u_i = x_i - \bar{x}$ et $v_i = y_i - \bar{y}$.

Étape 1. Pour tout réel t , considérons la somme des carrés :

$$S(t) = \sum_{i=1}^n (v_i - t u_i)^2.$$

C'est une somme de carrés, donc $S(t) \geq 0$ pour tout t .

Étape 2. Développons :

$$S(t) = \sum v_i^2 - 2t \sum u_i v_i + t^2 \sum u_i^2 = n V(Y) - 2t n \text{cov}(X, Y) + t^2 n V(X).$$

C'est un trinôme du second degré en t , toujours positif ou nul. Son discriminant est donc négatif ou nul :

$$\Delta = 4n^2 (\text{cov}(X, Y))^2 - 4n^2 V(X)V(Y) \leq 0,$$

ce qui redonne $(\text{cov}(X, Y))^2 \leq V(X)V(Y)$, c'est-à-dire $r^2 \leq 1$, donc $-1 \leq r \leq 1$.

Étape 3. Supposons maintenant $r^2 = 1$. Alors $\Delta = 0$: le trinôme $S(t)$ admet une racine double $t_0 = \frac{\text{cov}(X, Y)}{V(X)}$, et $S(t_0) = 0$. Or une somme de carrés nulle impose que chaque carré soit nul :

$$v_i = t_0 u_i \quad \text{pour tout } i, \quad \text{c'est-à-dire} \quad y_i - \bar{y} = t_0 (x_i - \bar{x}).$$


Tous les points $M_i(x_i; y_i)$ sont donc alignés sur la droite passant par le point moyen G , de coefficient directeur t_0 . Comme t_0 a le signe de $\text{cov}(X, Y)$, on obtient $t_0 > 0$ si $r = 1$ et $t_0 < 0$ si $r = -1$.

Étape 4 (réciproque). Si tous les points sont alignés sur une droite de pente non nulle, alors $y_i = \alpha x_i + \beta$ pour tout i , et un calcul direct donne $\text{cov}(X, Y) = \alpha V(X)$ et $V(Y) = \alpha^2 V(X)$, d'où $r = \frac{\alpha V(X)}{|\alpha| V(X)} = \pm 1$ selon le signe de α . ■

5.2 Interprétation du coefficient de corrélation

Le signe et la valeur absolue de r se lisent directement sur la forme du nuage de points :

- r **proche de 1** : les points sont presque alignés sur une droite « montante ». On dit qu'il y a une **forte corrélation linéaire positive** : quand X augmente, Y augmente.
- r **proche de -1** : les points sont presque alignés sur une droite « descendante ». **Forte corrélation linéaire négative** : quand X augmente, Y diminue.
- r **proche de 0** : il n'y a **pas de corrélation linéaire** entre X et Y . Attention : cela ne signifie pas qu'il n'y a aucune relation (voir le piège plus bas).



ATTENTION Un r proche de 0 ne veut pas dire « pas de relation »

Le coefficient r ne mesure que la dépendance linéaire. Si les points suivent une parabole, une courbe exponentielle ou toute autre relation non linéaire, on peut obtenir $r \approx 0$ alors

que X et Y sont parfaitement liées (voir le quatrième nuage de la galerie ci-dessus). Réflexe de survie au Bac : toujours regarder le nuage de points avant de conclure ! Si le nuage suggère une courbe, un ajustement affine n'est pas adapté, quelle que soit la valeur de r .

5.3 Lien avec les droites de régression

Rappelons les coefficients directeurs des deux droites de régression obtenues par les moindres carrés :

$$a = \frac{\text{cov}(X,Y)}{V(X)} \quad \text{et} \quad a' = \frac{\text{cov}(X,Y)}{V(Y)}.$$

PROPRIÉTÉ $r^2 = a \times a'$

En notant a le coefficient directeur de la droite de régression de y en x et a' celui de la droite de régression de x en y , on a :

$$a \times a' = \frac{\text{cov}(X,Y)}{V(X)} \times \frac{\text{cov}(X,Y)}{V(Y)} = \frac{(\text{cov}(X,Y))^2}{V(X)V(Y)} = r^2.$$

Cette formule est très riche en conséquences pratiques :

- Comme $r^2 = a a' \geq 0$, les deux pentes a et a' ont **toujours le même signe** : les deux droites de régression « montent » ensemble ou « descendent » ensemble.
- r a le même signe que $\text{cov}(X,Y)$, donc le même signe que a et a' . Connaissant a et a' , on retrouve r : $r = \pm\sqrt{a a'}$, avec le signe de a .
- $r = \pm 1$ équivaut à $a \times a' = 1$: les deux droites de régression sont alors **confondues** (les points sont alignés). Plus $|r|$ est proche de 1, plus les deux droites sont proches l'une de l'autre.

EXEMPLE Retrouver r à partir des pentes

Pour une série double, on a trouvé les droites de régression $y = 0,8x + 2$ et $x = 0,45y + 1$. Alors :

$$r^2 = a \times a' = 0,8 \times 0,45 = 0,36 \quad \text{donc} \quad r = \sqrt{0,36} = 0,6$$

(le signe est positif car $a > 0$). La corrélation linéaire est moyenne.

5.4 Qualité d'un ajustement affine : le critère de décision

MÉTHODE Interpréter r et juger la qualité d'un ajustement affine

Face à une série statistique double, voici la démarche complète à rédiger au Bac :

1. Observer le nuage de points : une forme allongée autour d'une droite est un bon signe ; une forme courbe ou écartée est un mauvais signe.
2. Calculer le coefficient de corrélation $r = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y}$.
3. Appliquer le critère usuel :
 - si $|r| \geq 0,75$ (c'est-à-dire $r^2 \geq 0,5625$, en pratique on exige souvent r^2 proche de 1) : la corrélation linéaire est forte, un ajustement affine est justifié ;
 - si $|r| < 0,75$: la corrélation linéaire est faible, un ajustement affine est peu pertinent (ou à proscrire si le nuage est courbe).
4. Conclure par une phrase : « Comme $r \approx \dots$ avec $|r| \geq 0,75$, la corrélation linéaire entre X et Y est forte : l'ajustement affine est justifié, et les prévisions issues de cette droite seront fiables. »

EXERCICE RÉSOLU 5 Réseau mobile et couverture d'arrondissement

Une société de téléphonie mobile étudie, dans 6 arrondissements, le lien entre le nombre x_i d'antennes relais installées et le pourcentage y_i de la population couverte par le réseau 4G.

x_i (antennes)	2	4	5	8	10	12
y_i (couverture en %)	35	48	55	70	79	88

On donne : $\bar{x} = \frac{41}{6} \approx 6,83$; $\bar{y} = 62,5$; $V(X) = \frac{437}{36} \approx 12,14$; $V(Y) = \frac{12009}{36} \approx 333,58$; $\text{cov}(X,Y) = \frac{2283}{36} \approx 63,42$.

1. Calculer le coefficient de corrélation linéaire r (arrondir à 10^{-3}).
2. Un ajustement affine est-il justifié ?
3. Sachant que la droite de régression de y en x a pour coefficient directeur $a = \frac{2283}{437} \approx 5,22$, retrouver le coefficient directeur a' de la droite de régression de x en y .

SOLUTION

1. Appliquons la définition :

$$r = \frac{\text{cov}(X,Y)}{\sqrt{V(X)V(Y)}} = \frac{2283/36}{\sqrt{(437/36) \times (12009/36)}} = \frac{2283}{\sqrt{437 \times 12009}} \approx \frac{2283}{2290,84} \approx 0,997.$$

2. On a $|r| \approx 0,997 \geq 0,75$: le coefficient est très proche de 1. La corrélation linéaire entre

le nombre d'antennes et la couverture 4G est très forte et positive. Un ajustement affine est donc parfaitement justifié, et les prévisions faites à partir de la droite de régression seront fiables.

3. On utilise la propriété $r^2 = a \times a'$:

$$a' = \frac{r^2}{a} = \frac{(0,997)^2}{5,22} \approx \frac{0,994}{5,22} \approx 0,190.$$

La droite de régression de x en y a pour coefficient directeur $a' \approx 0,190$. Vérification : a et a' sont bien de même signe (positifs), conformément à la théorie.

ATTENTION Pièges fréquents sur le coefficient de corrélation

- Ne pas confondre r et r^2 : le critère porte sur $|r| \geq 0,75$. Un élève qui compare $r = 0,6$ à $0,75$ en oubliant la valeur absolue, ou qui conclut avec $r^2 = 0,6$ en le comparant à $0,75$, fait une erreur de jugement.
- Le signe de r : en extrayant la racine carrée de $r^2 = a a'$, n'oublie pas de choisir le signe de $\text{cov}(X,Y)$ (celui de a). Écrire $r = 0,6$ quand les pentes sont négatives est faux : c'est $r = -0,6$.
- Divisions : r se calcule avec le produit $\sigma_X \sigma_Y$ au dénominateur, pas avec la somme ni avec les variances non racinées.
- Conclusion obligatoire : au Bac, calculer r sans phrase d'interprétation fait perdre des points. Toujours conclure sur la justification de l'ajustement affine.

LESAVAIS-TU ? Corrélation n'est pas causalité !

Une corrélation forte entre deux phénomènes ne prouve jamais que l'un est la cause de l'autre. Exemple classique : sur une année, les ventes de glaces et le nombre de noyades sont fortement corrélés (r proche de 1). Faut-il interdire les glaces pour sauver des vies ? Bien sûr que non : les deux phénomènes dépendent d'une troisième variable cachée, la chaleur estivale, qui pousse à la fois à manger des glaces et à se baigner. On parle de **variable confondante**.

D'autres corrélations fallacieuses célèbres : le nombre de cigognes et le taux de natalité dans certaines régions d'Europe, ou encore, chez nous, on pourrait observer une corrélation entre les ventes d'ombrelles et les dégâts de pluie sur les routes de Yaoundé — ce n'est évidemment pas l'ombrelle qui abîme la route ! En statistiques, r mesure une association, jamais un lien de cause à effet. Seule une étude approfondie (expérience contrôlée, analyse du contexte) peut établir une causalité. Retiens la formule des statisticiens : « Correlation is not causation ».

EXERCICE 5 À toi de jouer

Le tableau suivant donne, pour 7 élèves de Terminale C, le nombre d'heures x_i de révision hebdomadaire et la moyenne y_i obtenue en mathématiques.

x_i (heures)	2	4	5	7	9	11	12
y_i (moyenne)	8	9	11	12	14	15	16

On donne : $V(X) = \frac{580}{49} \approx 11,84$; $V(Y) = \frac{384}{49} \approx 7,84$; $\text{cov}(X,Y) = \frac{468}{49} \approx 9,55$.

1. Calculer le coefficient de corrélation linéaire r , arrondi à 10^{-3} .
2. Un ajustement affine du nuage est-il justifié ? Justifier soigneusement.
3. La droite de régression de y en x a pour équation $y = 0,76x + 6,67$. Déterminer le coefficient directeur de la droite de régression de x en y .

CORRIGÉ Exercice : révisions et moyennes

$$1. r = \frac{468/49}{\sqrt{(580/49) \times (384/49)}} = \frac{468}{\sqrt{580 \times 384}} = \frac{468}{\sqrt{222720}} \approx \frac{468}{471,93} \approx 0,992.$$

2. $|r| \approx 0,992 \geq 0,75$: la corrélation linéaire est très forte et positive. L'ajustement affine est justifié.

$$3. a' = \frac{r^2}{a} = \frac{0,992^2}{0,76} \approx \frac{0,984}{0,76} \approx 1,29.$$

À RETENIR L'essentiel sur le coefficient de corrélation linéaire

- $r = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y}$, et l'on a toujours $-1 \leq r \leq 1$.
- $r = \pm 1$ si et seulement si les points du nuage sont parfaitement alignés (pente positive pour $r = 1$, négative pour $r = -1$).
- $r^2 = a \times a'$ (produit des coefficients directeurs des deux droites de régression) ; r a le signe de $\text{cov}(X,Y)$.
- Critère de qualité : $|r| \geq 0,75 \Rightarrow$ corrélation linéaire forte, ajustement affine justifié.
- $r \approx 0$ n'exclut pas une relation non linéaire : toujours examiner le nuage.
- Une corrélation, même forte, ne prouve jamais une relation de cause à effet.

6 PRÉVISIONS ET SYNTHÈSE MÉTHODOLOGIQUE

Dans la section précédente, nous avons appris à mesurer la **qualité** d'un ajustement affine grâce au **coefficient de corrélation linéaire** r . Nous savons donc désormais construire un nuage de points, placer le point moyen G , tracer une droite d'ajustement (Mayer ou moindres carrés) et juger si cet ajustement est pertinent. Il reste à répondre à la question qui motive toute cette leçon : à quoi sert une droite d'ajustement ? Réponse : à **prévoir**. Le gérant d'une station-service de Yaoundé qui connaît la relation entre le trafic routier et ses ventes de carburant veut anticiper ses commandes ; l'INS veut projeter la population du Cameroun en 2035 ; un médecin veut estimer la dose d'un médicament adaptée à la masse d'un patient. Dans tous ces cas, on substitue une valeur dans l'équation de la droite. Cette dernière section te donne la méthode complète, ses limites, et un complément précieux pour le Bac : les ajustements non affines par changement de variable.

6.1 Principe de la prévision

Intuition. Une droite d'ajustement $y = ax + b$ résume la tendance globale du nuage par une relation fonctionnelle : à chaque valeur de x correspond une valeur estimée de y . Prévoir, c'est simplement **lire cette relation** pour une valeur de x qui n'a pas (encore) été observée.

DÉFINITION Prévision à l'aide d'un ajustement affine

Soit une série statistique à deux variables $(x; y)$ ajustée par une droite. Effectuer une **prévision** consiste à :

- estimer y pour une valeur x_0 donnée en calculant $\hat{y}_0 = ax_0 + b$ à l'aide de la **droite de régression de y en x** ;
- estimer x pour une valeur y_0 donnée en calculant $\hat{x}_0 = a'y_0 + b'$ à l'aide de la **droite de régression de x en y** .

ATTENTION La bonne droite pour la bonne question

Les deux droites de régression ne sont pas interchangeables ! Elles minimisent des écarts différents (verticaux pour y en x , horizontaux pour x en y) et ne coïncident que si $|r| = 1$. Retiens :

- pour estimer y connaissant x : droite de régression de y en x , $y = ax + b$;
- pour estimer x connaissant y : droite de régression de x en y , $x = a'y + b'$.

Erreur classique au Bac : isoler x dans l'équation $y = ax + b$ pour estimer x connaissant y . C'est mathématiquement possible, mais ce n'est pas la droite de régression de x en y , et l'examineur le sanctionne.

6.2 Interpolation, extrapolation et condition de fiabilité

DÉFINITION Interpolation et extrapolation

Soit $[x_{\min}; x_{\max}]$ la plage des valeurs observées de x .

- Une prévision est une **interpolation** si $x_0 \in [x_{\min}; x_{\max}]$: on estime à l'intérieur de la zone où le modèle a été « calibré ».
- C'est une **extrapolation** si $x_0 \notin [x_{\min}; x_{\max}]$: on prolonge la tendance au-delà des observations.


PROPRIÉTÉ Conditions de fiabilité d'une prévision

Une prévision par ajustement affine n'est raisonnable que si :

1. la corrélation est forte, en pratique $|r| \geq 0,87$ (au minimum 0,75 pour une estimation grossière);
2. la prévision est une interpolation, ou une extrapolation proche de la plage observée;
3. le phénomène étudié n'a pas subi de changement de contexte (crise, nouvelle technologie, saturation...).

ATTENTION Le piège de l'extrapolation lointaine

Une extrapolation lointaine des données est toujours risquée, même avec un excellent r . Le coefficient r mesure la linéarité du nuage observé, il ne dit rien du comportement du phénomène en dehors. Exemple : la taille d'un enfant entre 4 et 10 ans croît presque linéairement ($r \approx 0,99$); extrapoler cette droite prédirait un adulte de 3 m à 30 ans! Toute croissance réelle finit par saturer. Au Bac, signale toujours la prudence quand la valeur demandée sort de la plage observée : c'est un réflexe qui rapporte des points.



Zone verte : interpolation à l'intérieur des données observées. Zone orange : extrapolation, où la droite prolongée en pointillés n'est qu'une hypothèse. La droite tracée correspond à la régression des moindres carrés recalculée exactement depuis le tableau.

6.3 Méthode complète et exemple chiffré

MÉTHODE

Effectuer une prévision à l'aide d'un ajustement affine

1. Identifier la variable à estimer : si l'on cherche y connaissant x_0 , on utilise la droite de régression de y en x ; si l'on cherche x connaissant y_0 , on utilise la droite de régression de x en y .
2. Vérifier la qualité de l'ajustement : calculer r et s'assurer que $|r|$ est proche de 1 (au moins 0,87).
3. Situer la valeur : comparer x_0 à la plage $[x_{\min}; x_{\max}]$ pour distinguer interpolation et extrapolation.
4. Substituer : calculer $\hat{y}_0 = ax_0 + b$ (ou $\hat{x}_0 = a'y_0 + b'$).
5. Conclure en rédigeant : donner la valeur estimée, son unité, et commenter sa fiabilité (interpolation/extrapolation, valeur de r).

EXERCICE RÉSOLU 6

Prévision des ventes de carburant

Une station-service de la nationale N1 observe, pendant 9 jours, le trafic x (en centaines de véhicules) et les ventes y (en centaines de litres) :

x	2	3	4	5	6	7	8	9	10
y	3,1	4,2	4,6	5,9	6,4	7,6	8,1	9,3	9,8

On calcule : $\bar{x} = 6$, $\bar{y} = \frac{59}{9} \approx 6,56$, $V(x) = \frac{60}{9} \approx 6,67$, $\text{cov}(x,y) = \frac{50,8}{9} \approx 5,64$, $r \approx 0,994$.

1. Déterminer la droite de régression de y en x (moindres carrés) et la droite de Mayer. Estimer les ventes pour un trafic de 1200 véhicules avec les deux droites. Comparer.
2. Discuter la fiabilité de cette prévision.

SOLUTION

1. Droite des moindres carrés (régression de y en x).

$$a = \frac{\text{cov}(x,y)}{V(x)} = \frac{50,8/9}{60/9} = \frac{50,8}{60} \approx 0,847, \quad b = \bar{y} - a\bar{x} \approx 6,56 - 0,847 \times 6 \approx 1,48.$$

Droite : $y = 0,847x + 1,48$.

Droite de Mayer. On partage la série en deux groupes de même effectif (ou presque) autour de la médiane de x (ici $x = 6$). Groupe 1 ($x \leq 6$) : 5 points. $G_1(\bar{x}_1; \bar{y}_1) = (4; \frac{3,1+4,2+4,6+5,9+6,4}{5}) = (4; 4,84)$. Groupe 2 ($x > 6$) : 4 points. $G_2(\bar{x}_2; \bar{y}_2) = (8,5; \frac{7,6+8,1+9,3+9,8}{4}) = (8,5; 8,7)$.

$$a_M = \frac{8,7 - 4,84}{8,5 - 4} = \frac{3,86}{4,5} \approx 0,858, \quad b_M = 4,84 - 0,858 \times 4 \approx 1,41.$$

Droite : $y = 0,858x + 1,41$.

Prévision pour $x_0 = 12$ (soit 1200 véhicules).

Moindres carrés : $\hat{y}_0 = 0,847 \times 12 + 1,48 \approx 11,64$ (soit 1164 litres),

Mayer : $\hat{y}_0 = 0,858 \times 12 + 1,41 \approx 11,71$ (soit 1171 litres).

Les deux méthodes donnent des prévisions très proches (écart $< 1\%$), ce qui conforte la robustesse de l'estimation.

2. Fiabilité : $r \approx 0,994$, corrélation quasi parfaite, donc l'ajustement affine est excellent sur la zone observée. En revanche $x_0 = 12$ est hors de la plage observée $[2; 10]$: c'est une extrapolation. Elle reste proche des données (2 centaines au-delà), donc acceptable, mais le gérant commandera avec une marge de sécurité.

6.4 Complément Bac : ajustements non affines par changement de variable

Certains nuages ont une allure visiblement courbe (croissance exponentielle d'une population, décroissance radioactive, saturation...). L'idée, classique au Bac, est de **linéariser** : poser une nouvelle variable qui rend le nuage affine, ajuster, puis revenir à la variable initiale.

MÉTHODE Linéarisation par changement de variable


1. Observer l'allure du nuage : croissance de plus en plus rapide $\Rightarrow$ modèle exponentiel $y = k e^{cx}$, on pose $z = \ln y$; nuage en « racine » $\Rightarrow z = \sqrt{y}$; hyperbole $\Rightarrow z = \frac{1}{x}$.
2. Construire la série $(x_i; z_i)$ et vérifier que son nuage est affine (calculer le nouveau r).
3. Ajuster z en x par les moindres carrés : $z = ax + b$.
4. Revenir à y : par exemple, si $z = \ln y$, alors $\ln y = ax + b$ donne $y = e^b e^{ax}$.
5. Utiliser ce modèle pour la prévision demandée.

EXEMPLE Ajustement exponentiel d'une population bactérienne

Une culture compte y bactéries (en milliers) après x heures : $(0; 5), (1; 8), (2; 13), (3; 21), (4; 34)$. Le nuage n'est pas affine. On pose $z = \ln y$: la série $(x; z)$ donne $z \approx 0,48x + 1,60$ avec $r \approx 0,999$. Le modèle est donc $y = e^{1,60} e^{0,48x} \approx 4,95 e^{0,48x}$. Prévision à 6 heures : $y \approx 4,95 e^{2,88} \approx 88$ milliers de bactéries.

6.5 Synthèse : l'étude complète d'une série à deux variables**À RETENIR** Fiche-méthode : du tableau à la prévision

1. Nuage de points : représenter les points $M_i(x_i; y_i)$, observer l'allure (affine? croissante?).
2. Point moyen : calculer $G(\bar{x}; \bar{y})$ et le placer.
3. Covariance : $\text{cov}(x, y) = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$; son signe donne le sens de la relation.
4. Droite d'ajustement : moindres carrés $a = \frac{\text{cov}(x, y)}{V(x)}$, $b = \bar{y} - a\bar{x}$ (ou Mayer si l'énoncé l'impose); vérifier que G appartient à la droite.
5. Coefficient de corrélation : $r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$; valider l'ajustement si $|r| \geq 0,87$.
6. Prévision : substituer dans la bonne droite, puis commenter (interpolation ou extrapolation, fiabilité).



Organigramme de synthèse : les étapes de l'étude complète d'une série statistique à deux variables.

LESAVAIS-TU ? Des régressions qui façonnent le pays

Les prévisions météorologiques qui guident les semis des agriculteurs de l'Adamaoua reposent sur des modèles de régression alimentés par des décennies d'observations. De même, l'Institut National de la Statistique (INS) du Cameroun produit des projections de population — essentielles pour planifier écoles, hôpitaux et électrification rurale — en ajustant des modèles de croissance sur les recensements passés. La droite des moindres carrés, publiée par Legendre en 1805, reste l'un des outils mathématiques les plus utilisés au monde : économie, médecine, sport, télécommunications... Tu viens d'en acquérir la maîtrise complète !

EXERCICE 6 Pour s'entraîner

Une entreprise de distribution d'eau relève la consommation y (en m^3) d'un quartier en fonction du nombre x de foyers raccordés, pour x variant de 20 à 100. On obtient $\bar{x} = 60$, $\bar{y} = 480$, $\text{cov}(x, y) = 3900$, $V(x) = 500$, $\sigma_y = 200$.

1. Déterminer la droite de régression de y en x .
2. Calculer r et juger la qualité de l'ajustement.
3. Estimer la consommation pour 130 foyers raccordés. Cette prévision est-elle fiable ?

CORRIGÉ Exercice 1

1. $a = \frac{3900}{500} = 7,8$ et $b = 480 - 7,8 \times 60 = 12$. La droite est $y = 7,8x + 12$. 2. $\sigma_x = \sqrt{500} \approx 22,36$, d'où $r = \frac{3900}{22,36 \times 200} = \frac{3900}{4472} \approx 0,872$. L'ajustement est acceptable ($|r| \geq 0,87$). 3. $\hat{y} = 7,8 \times 130 + 12 = 1026 \text{ m}^3$. Mais $x = 130$ est hors de la plage $[20 ; 100]$: extrapolation, à annoncer avec prudence.

7 ACTIVITÉ D'INTÉGRATION

7.1 Objectifs de l'activité

À l'issue de cette activité d'intégration, tu seras capable de mobiliser, dans une situation authentique et non guidée pas à pas, l'ensemble de la chaîne statistique étudiée dans cette leçon :

- représenter une série statistique à deux variables par un **nuage de points** et y placer le **point moyen** ;
- déterminer une droite d'ajustement par la **méthode de Mayer** ;
- calculer une **covariance**, des **variances** et la **droite de régression** de y en x par la méthode des moindres carrés ;
- calculer et interpréter le **coefficient de corrélation linéaire** ;
- utiliser un ajustement affine pour effectuer une **prévision**, comparer deux méthodes et rédiger une conclusion argumentée à destination d'un décideur.

Au-delà des calculs, cette activité développe des savoir-être essentiels : la rigueur dans la tenue d'un tableau de calcul, l'esprit critique face à une prévision chiffrée, et la capacité à communiquer un résultat mathématique en langage courant.

7.2 Situation

La CAMWATER, société en charge de la production et de la distribution de l'eau potable au Cameroun, doit anticiper la demande du quartier Tougang, à Bafoussam (région de l'Ouest). L'expérience montre que la consommation d'eau augmente avec la chaleur : les gestionnaires souhaitent donc exploiter les relevés de l'année écoulée pour prévoir la consommation en fonction de la température.

Le chef de centre CAMWATER de Bafoussam a relevé, pendant dix mois consécutifs, la température moyenne mensuelle x_i (en degrés Celsius) et la consommation totale d'eau du quartier y_i (en milliers de m^3) :

Mois	1	2	3	4	5	6	7	8	9	10
x_i (°C)	24	25	26	27	28	26	25	27	28	29
y_i (milliers de m^3)	18	19	20	22	23	21	19	22	24	25

Les services météorologiques annoncent pour le mois prochain une température moyenne de 29 °C. Le chef de centre se pose la question suivante : peut-on prévoir raisonnablement la consommation du quartier le mois prochain, et cette prévision est-elle assez fiable pour dimensionner le nouveau château d'eau ?

Par groupes de quatre élèves, vous êtes les experts-statisticiens missionnés pour répondre à cette question et rédiger une note de synthèse.

7.3 Consignes

1. **Observation graphique.** Construire le nuage de points $M_i(x_i; y_i)$ dans un repère orthogonal bien choisi (unités adaptées aux données). Calculer les coordonnées du point moyen G et le placer sur le graphique. Le nuage suggère-t-il un ajustement affine ? Justifier.
2. **Méthode de Mayer.** Partager le nuage en deux sous-nuages de cinq points (les cinq premiers mois, puis les cinq derniers). Déterminer les points moyens G_1 et G_2 , puis l'équation réduite de la droite de Mayer (G_1G_2).
3. **Méthode des moindres carrés.** À l'aide d'un tableau à cinq colonnes ($x_i - \bar{x}$, $(y_i - \bar{y})$, $(x_i - \bar{x})(y_i - \bar{y})$, $(x_i - \bar{x})^2$, $(y_i - \bar{y})^2$, calculer $\text{cov}(X, Y)$, $V(X)$ et $V(Y)$. En déduire l'équation de la droite de régression de y en x . Vérifier que cette droite passe par G .
4. **Qualité de l'ajustement.** Calculer le coefficient de corrélation linéaire r (arrondi à 10^{-3}). L'ajustement affine est-il justifié ?
5. **Prévision.** En utilisant chacune des deux droites obtenues, prévoir la consommation d'eau pour une température moyenne de 29°C . Comparer les deux prévisions et commenter l'écart observé.
6. **Note de synthèse.** Rédiger en cinq à huit lignes une note à l'intention du chef de centre CAMWATER : donner la prévision retenue, préciser le degré de confiance accordé au modèle, et indiquer s'il est raisonnable de dimensionner le château d'eau sur cette seule prévision (penser aux limites du modèle : marge de sécurité, croissance démographique du quartier, fuites du réseau).

7.4 Ressources à mobiliser

À RETENIR

Boîte à outils de la leçon

- Point moyen : $G(\bar{x}; \bar{y})$ avec $\bar{x} = \frac{1}{n} \sum x_i$ et $\bar{y} = \frac{1}{n} \sum y_i$.
- Méthode de Mayer : partager le nuage en deux sous-nuages de même effectif (ou presque), calculer G_1 et G_2 ; la droite (G_1G_2) est la droite d'ajustement.
- Covariance et variance : $\text{cov}(X, Y) = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$ et $V(X) = \frac{1}{n} \sum (x_i - \bar{x})^2$.
- Droite de régression de y en x : $y = ax + b$ avec $a = \frac{\text{cov}(X, Y)}{V(X)}$ et $b = \bar{y} - a\bar{x}$. Elle passe toujours par G .
- Coefficient de corrélation : $r = \frac{\text{cov}(X, Y)}{\sqrt{V(X)V(Y)}}$, avec $-1 \leq r \leq 1$. L'ajustement affine est jugé pertinent lorsque $|r|$ est proche de 1 (en pratique $|r| \geq 0,87$ environ).
- Prévision : on remplace x par la valeur annoncée dans l'équation de la droite d'ajustement, en restant vigilant si cette valeur sort de la plage des données (extrapolation risquée).

7.5 Démarche et corrigé commenté

EXERCICE RÉSOLU 7 Corrigé complet de l'activité

Prévoir la consommation d'eau du quartier Tougang à partir des dix relevés CAMWATER, par la méthode de Mayer puis par les moindres carrés, juger la qualité de l'ajustement et prévoir la consommation pour 29 °C.

SOLUTION

Étape 1 : nuage de points et point moyen.

On calcule les moyennes :

$$\bar{x} = \frac{24 + 25 + 26 + 27 + 28 + 26 + 25 + 27 + 28 + 29}{10} = \frac{265}{10} = 26,5$$

$$\bar{y} = \frac{18 + 19 + 20 + 22 + 23 + 21 + 19 + 22 + 24 + 25}{10} = \frac{213}{10} = 21,3$$

Le point moyen est $G(26,5; 21,3)$. Sur le graphique (abscisses de 23 à 30, ordonnées de 17 à 26), les points sont sensiblement alignés le long d'une direction montante : un ajustement affine semble pertinent, ce que confirmera le calcul de r .

Étape 2 : droite de Mayer.

Sous-nuage 1 (mois 1 à 5) :

$$\bar{x}_1 = \frac{24 + 25 + 26 + 27 + 28}{5} = 26 \quad ; \quad \bar{y}_1 = \frac{18 + 19 + 20 + 22 + 23}{5} = 20,4$$

donc $G_1(26; 20,4)$. Sous-nuage 2 (mois 6 à 10) :

$$\bar{x}_2 = \frac{26 + 25 + 27 + 28 + 29}{5} = 27 \quad ; \quad \bar{y}_2 = \frac{21 + 19 + 22 + 24 + 25}{5} = 22,2$$

donc $G_2(27; 22,2)$. Le coefficient directeur de (G_1G_2) est :

$$a_M = \frac{22,2 - 20,4}{27 - 26} = 1,8$$

L'équation s'écrit $y - 20,4 = 1,8(x - 26)$, soit :

$$y = 1,8x - 26,4$$

Étape 3 : moindres carrés.

On complète le tableau à cinq colonnes (les écarts sont calculés par rapport à $\bar{x} = 26,5$ et $\bar{y} = 21,3$) :

$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
-2,5	-3,3	8,25	6,25	10,89
-1,5	-2,3	3,45	2,25	5,29
-0,5	-1,3	0,65	0,25	1,69
0,5	0,7	0,35	0,25	0,49
1,5	1,7	2,55	2,25	2,89
-0,5	-0,3	0,15	0,25	0,09
-1,5	-2,3	3,45	2,25	5,29
0,5	0,7	0,35	0,25	0,49
1,5	2,7	4,05	2,25	7,29
2,5	3,7	9,25	6,25	13,69
Sommes		32,5	22,5	48,1

On en déduit :

$$\text{cov}(X,Y) = \frac{32,5}{10} = 3,25 \quad ; \quad V(X) = \frac{22,5}{10} = 2,25 \quad ; \quad V(Y) = \frac{48,1}{10} = 4,81$$

Coefficient directeur de la droite de régression de y en x :

$$a = \frac{\text{cov}(X,Y)}{V(X)} = \frac{3,25}{2,25} = \frac{13}{9} \approx 1,444$$

puis $b = \bar{y} - a\bar{x} = 21,3 - \frac{13}{9} \times 26,5 \approx 21,3 - 38,278 = -16,978$. D'où :

$$y \approx 1,444x - 16,978$$

Vérification : pour $x = \bar{x} = 26,5$, on obtient $y \approx 1,444 \times 26,5 - 16,978 \approx 21,3 = \bar{y}$: la droite passe bien par G .

Étape 4 : coefficient de corrélation.

$$r = \frac{\text{cov}(X,Y)}{\sqrt{V(X)V(Y)}} = \frac{3,25}{\sqrt{2,25 \times 4,81}} = \frac{3,25}{\sqrt{10,8225}} \approx \frac{3,25}{3,290} \approx 0,988$$

$r \approx 0,988$ est très proche de 1 : la corrélation linéaire est excellente, l'ajustement affine est pleinement justifié, et la relation est croissante ($r > 0$) : plus il fait chaud, plus le quartier consomme d'eau.

Étape 5 : prévisions pour $x = 29^\circ\text{C}$.

Avec la droite de Mayer : $y = 1,8 \times 29 - 26,4 = 25,8$ milliers de m^3 .

Avec la droite des moindres carrés : $y \approx 1,444 \times 29 - 16,978 \approx 24,91$ milliers de m^3 .

Les deux prévisions (25,8 et 24,91 milliers de m^3) sont proches, à environ 0,9 millier de m^3 près, ce qui renforce la confiance dans l'ordre de grandeur : environ 25 000 m^3 . On retient la prévision des moindres carrés, méthode qui minimise globalement les écarts sur l'ensemble des points.

Étape 6 : note au chef de centre (exemple de rédaction).

« Monsieur le Chef de centre, l'étude statistique des dix derniers mois montre une très forte corrélation linéaire ($r \approx 0,99$) entre la température moyenne et la consommation d'eau du quartier Tougang. Pour une température annoncée de $29\text{ }^{\circ}\text{C}$, notre modèle prévoit une consommation d'environ $25\,000\text{ m}^3$ (entre $24\,900$ et $25\,800\text{ m}^3$ selon la méthode). Cette prévision est fiable car $29\text{ }^{\circ}\text{C}$ reste dans la plage des températures observées. Toutefois, nous recommandons de dimensionner le château d'eau avec une marge de sécurité d'au moins 10 à 15 %, afin de tenir compte de la croissance démographique du quartier, des fuites du réseau et des écarts naturels autour de la droite d'ajustement.

»

7.6 Bilan de l'activité

Cette activité a permis de mettre en évidence plusieurs idées essentielles de la leçon :

- **La démarche statistique est une chaîne complète** : on ne calcule pas une droite de régression « à l'aveugle » ; on commence toujours par observer le nuage de points, et on termine par juger la qualité de l'ajustement grâce à r avant toute prévision.
- **Les deux méthodes d'ajustement se complètent** : la méthode de Mayer est rapide et géométrique, celle des moindres carrés est plus fine car elle utilise toutes les données ; quand leurs prévisions sont proches, la conclusion est renforcée.
- **Le coefficient de corrélation est un juge de paix** : $r \approx 0,988$ autorise la prévision, alors qu'un $|r|$ faible l'aurait interdite, même si l'on peut toujours calculer mécaniquement une droite.
- **Une prévision reste une estimation** : le statisticien honnête communique un ordre de grandeur et une marge de prudence, jamais une certitude. C'est cette honnêteté intellectuelle, autant que les formules, qui fait la valeur d'une étude statistique pour un décideur comme le chef de centre CAMWATER.

ATTENTION Ce qu'il fallait éviter

Oublier de vérifier que la droite des moindres carrés passe par G (excellent réflexe de contrôle) ; confondre $\text{cov}(X,Y)$ et $V(X)$ dans le calcul de a ; conclure à une « cause » entre température et consommation alors que la statistique ne met en évidence qu'une corrélation ; enfin, extrapoler sans précaution à des températures très éloignées de la plage observée.

8 MÉTHODES ET EXERCICES RÉSOLUS

9 STATISTIQUES À DEUX VARIABLES

9.1 Séries statistiques à deux caractères : tableau à double entrée et séries marginales

DÉFINITION Série statistique à deux caractères

On appelle **série statistique à deux caractères** (ou série double) une série où chaque individu de la population est caractérisé par deux variables X et Y . On note $(x_i ; y_i)_{1 \leq i \leq n}$ les n couples de valeurs observées.

DÉFINITION Tableau à double entrée et séries marginales

Lorsque les effectifs sont importants, on regroupe les données dans un **tableau à double entrée** (ou tableau de contingence pour des caractères qualitatifs, tableau de effectifs pour des caractères quantitatifs groupés en classes). Les **séries marginales** sont les séries statistiques de chaque variable prise séparément : on obtient leurs effectifs (ou fréquences) en sommant les lignes et les colonnes du tableau.

MÉTHODE Construire les séries marginales à partir d'un tableau à double entrée

1. Repérer les modalités (ou classes) de X en en-tête de colonnes et celles de Y en en-tête de lignes.
2. Les effectifs marginaux de X (dernière ligne du tableau) s'obtiennent en sommant les effectifs de chaque colonne.
3. Les effectifs marginaux de Y (dernière colonne du tableau) s'obtiennent en sommant les effectifs de chaque ligne.
4. La somme des effectifs marginaux de X (ou de Y) donne l'effectif total n .

EXEMPLE Ventes de téléphones (MTN/Orange) à Yaoundé

Un magasin a relevé les ventes hebdomadaires selon le modèle (lignes) et la marque (co-

lonnes) :

Y (Modèle) \ X (Marque)	X (Marque)			Total Y
	MTN	Orange	Autres	
Entrée de gamme	12	18	5	35
Milieu de gamme	20	25	10	55
Haut de gamme	8	12	5	25
Total X	40	55	20	115

Les séries marginales sont :

- Pour la marque X : (40 ; 55 ; 20) effectif total 115.
- Pour le modèle Y : (35 ; 55 ; 25) effectif total 115.

9.2 Nuage de points et point moyen

MÉTHODE Nuage de points et point moyen

Pour représenter une série statistique double $(x_i ; y_i)$ et situer son point moyen :

1. Choisir deux axes gradués adaptés aux valeurs de x et de y (on peut commencer les graduations ailleurs qu'en 0 si les valeurs sont concentrées ; indiquer alors une **rupture d'échelle**).
2. Placer chaque point $M_i(x_i ; y_i)$: l'ensemble forme le **nuage de points**.
3. Calculer les moyennes marginales :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{et} \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

4. Le **point moyen** est $G(\bar{x} ; \bar{y})$: le placer sur le graphique (souvent d'une couleur différente).
5. Observer la forme du nuage : s'il est allongé autour d'une direction, un **ajustement affine** est envisageable.

Réflexe Bac : vérifier que G est bien « au centre » du nuage ; une erreur de calcul de $\bar{x}$ ou $\bar{y}$ se voit immédiatement sur le graphique.

EXERCICE RÉSOLU 8 Récolte de maïs à Bafoussam

Un agronome a relevé, pour cinq exploitations de la région de l'Ouest, la surface cultivée


x_i (en hectares) et la récolte de maïs y_i (en tonnes) :

Surface x_i (ha)	2	4	6	8	10
Récolte y_i (t)	3	5	7	8	10

1. Représenter le nuage de points associé à cette série.
2. Déterminer les coordonnées du point moyen G et le placer sur le graphique.

SOLUTION

1. Nuage de points. On place les points $M_1(2; 3)$, $M_2(4; 5)$, $M_3(6; 7)$, $M_4(8; 8)$, $M_5(10; 10)$.



Nuage de points et point moyen G

2. Point moyen. On calcule les moyennes marginales :

$$\bar{x} = \frac{2 + 4 + 6 + 8 + 10}{5} = \frac{30}{5} = 6 \quad ; \quad \bar{y} = \frac{3 + 5 + 7 + 8 + 10}{5} = \frac{33}{5} = 6,6.$$

Le point moyen est donc $G(6; 6,6)$. Il est bien situé au centre du nuage, qui apparaît allongé selon une direction montante : un ajustement affine est justifié visuellement.

9.3 Ajustement affine par la méthode de Mayer

MÉTHODE Méthode de Mayer (double moyenne)

1. Trier les points par abscisses croissantes (indispensable!).
2. Partager le nuage en deux sous-nuages de effectifs égaux (ou différant de 1 si n est impair).
3. Calculer les points moyens $G_1(x_1; y_1)$ et $G_2(x_2; y_2)$ de chaque sous-nuage.
4. La **droite de Mayer** est la droite (G_1G_2) . Son équation s'obtient par :

$$a = \frac{y_2 - y_1}{x_2 - x_1}, \quad \text{puis} \quad y = ax + b \text{ avec } b = y_1 - ax_1.$$

5. Vérifier que la droite passe « au milieu » du nuage sur le graphique.

Réflexe : la droite de Mayer passe aussi par le point moyen global G quand les deux sous-nuages ont le même effectif : c'est un bon contrôle.

EXERCICE RÉSOLU 9 Droite de Mayer pour la récolte de maïs

On reprend la série de l'exercice précédent :

x_i	2	4	6	8	10
y_i	3	5	7	8	10

Déterminer, par la méthode de Mayer, une équation de la droite d'ajustement de y en x .

SOLUTION

Étape 1 et 2. Les points sont déjà rangés par abscisses croissantes. Avec $n = 5$ (impair), on partage en un premier groupe de 2 points et un second de 3 points :

Groupe 1 : (2 ; 3), (4 ; 5) ; Groupe 2 : (6 ; 7), (8 ; 8), (10 ; 10).

Étape 3. Points moyens des sous-nuages :

$$G_1\left(\frac{2+4}{2}; \frac{3+5}{2}\right) = G_1(3; 4),$$

$$G_2\left(\frac{6+8+10}{3}; \frac{7+8+10}{3}\right) = G_2\left(8; \frac{25}{3}\right).$$

Étape 4. Coefficient directeur de (G_1G_2) :

$$a = \frac{\frac{25}{3} - 4}{8 - 3} = \frac{\frac{25 - 12}{3}}{5} = \frac{13}{15} \approx 0,87.$$

Ordonnée à l'origine, en utilisant G_1 :

$$b = y_1 - ax_1 = 4 - \frac{13}{15} \times 3 = 4 - \frac{13}{5} = \frac{7}{5} = 1,4.$$

Conclusion : la droite de Mayer a pour équation

$$y = \frac{13}{15}x + \frac{7}{5} \quad \text{soit environ} \quad y = 0,87x + 1,4.$$

Vérification : pour $G(6; 6,6)$: $\frac{13}{15} \times 6 + \frac{7}{5} = \frac{26}{5} + \frac{7}{5} = \frac{33}{5} = 6,6$. La droite passe bien par G : le calcul est cohérent.

9.4 Covariance de deux variables statistiques

MÉTHODE Covariance de deux variables statistiques

1. Calculer les moyennes $\bar{x}$ et $\bar{y}$.
2. Appliquer l'une des deux formules équivalentes :

$$\text{cov}(x,y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad \text{ou} \quad \text{cov}(x,y) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}.$$

La seconde (dite formule de König-Huygens) est souvent plus rapide avec un tableau.

3. Construire un tableau à colonnes x_i , y_i , $x_i y_i$ (et x_i^2 , y_i^2 si l'on vise ensuite les variances).
4. Interprétation du signe : $\text{cov}(x,y) > 0$: x et y varient globalement dans le même sens ; $\text{cov}(x,y) < 0$: en sens contraires ; $\text{cov}(x,y) = 0$: pas de liaison affine (mais possible liaison non-linéaire).

Réflexe : $\text{cov}(x,x) = V(x)$: la variance est un cas particulier de covariance.

EXERCICE RÉSOLU 10 Covariance surface/récolte

On considère à nouveau la série :

x_i	2	4	6	8	10
y_i	3	5	7	8	10

Calculer $\text{cov}(x,y)$ par les deux méthodes et interpréter le signe du résultat.

SOLUTION

On sait déjà que $\bar{x} = 6$ et $\bar{y} = 6,6$.

Méthode 1 : formule de König-Huygens. On complète le tableau :

x_i	y_i	$x_i y_i$	x_i^2
2	3	6	4
4	5	20	16
6	7	42	36
8	8	64	64
10	10	100	100
Sommes		232	220

$$\text{cov}(x, y) = \frac{232}{5} - 6 \times 6,6 = 46,4 - 39,6 = 6,8.$$

Méthode 2 : écarts aux moyennes.

$$\begin{aligned} \text{cov}(x, y) &= \frac{1}{5} [(2 - 6)(3 - 6,6) + (4 - 6)(5 - 6,6) + (6 - 6)(7 - 6,6) \\ &\quad + (8 - 6)(8 - 6,6) + (10 - 6)(10 - 6,6)] \\ &= \frac{1}{5} [(-4)(-3,6) + (-2)(-1,6) + 0 \times 0,4 + 2 \times 1,4 + 4 \times 3,4] \\ &= \frac{1}{5} [14,4 + 3,2 + 0 + 2,8 + 13,6] = \frac{34}{5} = 6,8. \end{aligned}$$

Conclusion : $\text{cov}(x, y) = 6,8 > 0$: surface cultivée et récolte varient globalement dans le même sens, ce qui confirme l'observation du nuage.

9.5 Droites de régression par la méthode des moindres carrés

MÉTHODE Droites de régression de y en x et de x en y

1. Calculer $\bar{x}$, $\bar{y}$, $\text{cov}(x, y)$, $V(x)$ et $V(y)$ avec :

$$V(x) = \frac{1}{n} \sum x_i^2 - \bar{x}^2 \quad ; \quad V(y) = \frac{1}{n} \sum y_i^2 - \bar{y}^2.$$

2. Droite de régression de y en x (on prédit y à partir de x) : $y = ax + b$ avec

$$a = \frac{\text{cov}(x, y)}{V(x)} \quad \text{et} \quad b = \bar{y} - a\bar{x}.$$

3. Droite de régression de x en y (on prédit x à partir de y) : $x = a'y + b'$ avec

$$a' = \frac{\text{cov}(x, y)}{V(y)} \quad \text{et} \quad b' = \bar{x} - a'\bar{y}.$$

4. Propriété de contrôle : les deux droites passent par le point moyen $G(\bar{x}; \bar{y})$.

ATTENTION Ne pas confondre les deux droites

La droite de x en y s'écrit $x = a'y + b'$: pour la comparer à $y = ax + b$, il faut la réécrire $y = \frac{x - b'}{a'}$. Ce ne sont pas les mêmes droites, sauf corrélation parfaite ($|r| = 1$).

EXERCICE RÉSOLU 11 Droites des moindres carrés

Toujours avec la série $(x_i; y_i) : (2; 3), (4; 5), (6; 7), (8; 8), (10; 10)$.

1. Déterminer l'équation de la droite de régression de y en x .
2. Déterminer l'équation de la droite de régression de x en y , et vérifier que les deux droites passent par G .

SOLUTION

On dispose déjà de : $\bar{x} = 6, \bar{y} = 6,6, \text{cov}(x, y) = 6,8, \sum x_i^2 = 220$. Il reste à calculer $\sum y_i^2$:

$$\sum y_i^2 = 9 + 25 + 49 + 64 + 100 = 247.$$

Variances :

$$V(x) = \frac{220}{5} - 6^2 = 44 - 36 = 8 \quad ; \quad V(y) = \frac{247}{5} - 6,6^2 = 49,4 - 43,56 = 5,84.$$

1. Droite de régression de y en x .

$$a = \frac{\text{cov}(x, y)}{V(x)} = \frac{6,8}{8} = 0,85 \quad ; \quad b = \bar{y} - a\bar{x} = 6,6 - 0,85 \times 6 = 6,6 - 5,1 = 1,5.$$

$$y = 0,85x + 1,5$$

2. Droite de régression de x en y .

$$a' = \frac{\text{cov}(x, y)}{V(y)} = \frac{6,8}{5,84} \approx 1,164 \quad ; \quad b' = \bar{x} - a'\bar{y} = 6 - 1,164 \times 6,6 \approx 6 - 7,685 = -1,685.$$

$$x \approx 1,164y - 1,685$$

Vérification du passage par $G(6; 6,6)$:

- $0,85 \times 6 + 1,5 = 5,1 + 1,5 = 6,6 = \bar{y}$ ✓
- $1,164 \times 6,6 - 1,685 \approx 7,685 - 1,685 = 6 = \bar{x}$ ✓

Les deux droites concourent bien au point moyen G .

9.6 Coefficient de corrélation linéaire et qualité d'un ajustement

MÉTHODE Coefficient de corrélation linéaire r

1. Calculer $\text{cov}(x, y)$, $\sigma_x = \sqrt{V(x)}$ et $\sigma_y = \sqrt{V(y)}$.
2. Appliquer la formule :

$$r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y} = \frac{\text{cov}(x, y)}{\sqrt{V(x) V(y)}}.$$
3. Interpréter (on a toujours $-1 \leq r \leq 1$) :
 - $|r|$ proche de 1 (en pratique $|r| \geq 0,87$, c'est-à-dire $r^2 \geq 0,75$) : forte corrélation linéaire, l'ajustement affine est pertinent ;
 - r proche de 0 : pas de relation affine (l'ajustement affine est à rejeter) ;
 - le signe de r est celui de la covariance : $r > 0$ relation croissante, $r < 0$ décroissante.
4. Lien avec les droites : $a \times a' = r^2$ (produit des coefficients directeurs des deux droites de régression).

EXERCICE RÉSOLU 12 Qualité de l'ajustement surface/récolte

Avec les résultats précédents : $\text{cov}(x, y) = 6,8$, $V(x) = 8$, $V(y) = 5,84$.

1. Calculer le coefficient de corrélation linéaire r (arrondir à 10^{-3}).
2. Un ajustement affine de cette série est-il justifié ?
3. Retrouver r^2 à partir des coefficients $a = 0,85$ et $a' \approx 1,164$.

SOLUTION

1. Calcul de r .

$$r = \frac{6,8}{\sqrt{8 \times 5,84}} = \frac{6,8}{\sqrt{46,72}} \approx \frac{6,8}{6,835} \approx 0,995.$$

2. Interprétation. On a $r \approx 0,995$, donc $r^2 \approx 0,99 \geq 0,75$ (et même $|r| \geq 0,87$). La corrélation linéaire entre la surface cultivée et la récolte est très forte et positive : l'ajustement affine est pleinement justifié.

3. Vérification par le produit $a \times a'$.

$$a \times a' = 0,85 \times 1,164 \approx 0,990 \approx r^2.$$

Le contrôle est concluant : les calculs des deux droites de régression sont cohérents avec le coefficient de corrélation.

9.7 Utiliser un ajustement affine pour effectuer une prévision

MÉTHODE**Prévision à partir d'une droite d'ajustement**

1. Justifier d'abord que la prévision est légitime : coefficient de corrélation satisfaisant ($|r|$ proche de 1) et valeur de la variable dans (ou proche de) la plage des données observées.
2. Pour prévoir y à partir d'une valeur x_0 : utiliser la droite de régression de y en x : $y_0 = ax_0 + b$.
3. Pour prévoir x à partir d'une valeur y_0 : utiliser la droite de régression de x en y : $x_0 = a'y_0 + b'$.
4. Conclure par une phrase en contexte, avec l'unité, et mentionner qu'il s'agit d'une estimation.

Réflexe : se méfier des extrapolations lointaines (prévoir très loin en dehors des données observées est hasardeux, même avec un bon r).

EXERCICE RÉSOLU 13**Prévision de récolte et de surface**

On admet que la droite de régression de y en x est $y = 0,85x + 1,5$ et celle de x en y est $x = 1,164y - 1,685$ (avec $r \approx 0,995$).

1. Estimer la récolte attendue pour une exploitation de 12 hectares.
2. Un exploitant vise une récolte de 15 tonnes. Quelle surface devrait-il cultiver?

SOLUTION

Justification préalable : $r \approx 0,995$, très proche de 1 : l'ajustement affine est de bonne qualité, les prévisions sont donc pertinentes.

1. Prévision de la récolte pour $x_0 = 12$ ha. On utilise la droite de régression de y en x :

$$y_0 = 0,85 \times 12 + 1,5 = 10,2 + 1,5 = 11,7.$$

Pour une exploitation de 12 hectares, on peut estimer la récolte à environ 11,7 tonnes de maïs. (La valeur 12 est proche des données observées, l'estimation est raisonnable.)

2. Surface nécessaire pour $y_0 = 15$ tonnes. On utilise la droite de régression de x en y :

$$x_0 = 1,164 \times 15 - 1,685 = 17,46 - 1,685 = 15,775 \approx 15,8.$$

Pour espérer une récolte de 15 tonnes, l'exploitant devrait cultiver environ 15,8 hectares. Il s'agit d'une extrapolation au-delà des données (y maximal observé : 10 t) : le résultat est à prendre avec prudence.

ATTENTION Les 5 erreurs qui coûtent des points au Bac

1. Oublier de trier les points pour Mayer. La méthode de Mayer exige des points rangés par abscisses croissantes avant le partage en deux sous-nuages. Un partage dans l'ordre du tableau non trié donne une droite fausse.
2. Confondre les deux droites de régression. $y = ax + b$ sert à prévoir y connaissant x ; $x = a'y + b'$ sert à prévoir x connaissant y . Utiliser la mauvaise droite pour une prévision est une erreur éliminatoire. Et on ne passe pas de l'une à l'autre par une simple inversion!
3. Se tromper de dénominateur dans les coefficients. $a = \frac{\text{COV}(x,y)}{V(x)}$ mais $a' = \frac{\text{COV}(x,y)}{V(y)}$. Mélanger $V(x)$ et $V(y)$ fausse tout le reste. Contrôle possible : $a \times a' = r^2$ et les deux droites passent par $G(\bar{x}; \bar{y})$.
4. Interpréter r sans le justifier, ou mal. Il ne suffit pas d'écrire « $r = 0,99$ » : il faut conclure explicitement (« $|r|$ proche de 1, donc forte corrélation linéaire, l'ajustement affine est pertinent »). Rappel : r proche de 0 ne signifie pas « pas de relation », mais « pas de relation affine ».
5. Erreurs de calcul sur les moyennes et la covariance. Oublier de diviser par n , confondre $\overline{xy}$ et $\bar{x}\bar{y}$ dans la formule $\text{cov}(x,y) = \overline{xy} - \bar{x}\bar{y}$, ou perdre des signes dans les écarts $(x_i - \bar{x})(y_i - \bar{y})$. Rédiger un tableau à colonnes $x_i, y_i, x_i y_i, x_i^2, y_i^2$ sécurise tous les calculs.

LE SAVAIS-TU ? Le coefficient de corrélation et la causalité

Un coefficient de corrélation r proche de 1 ou -1 prouve une liaison affine forte, mais pas une relation de cause à effet. Exemple : au Cameroun, le nombre d'abonnés MTN et la production de cacao ont tous deux augmenté ces 20 dernières années ($r \approx 0,95$). Cela ne veut pas dire que téléphoner fait pousser le cacao ! Les deux sont liés à une troisième variable : le développement économique et démographique. Au Bac, on écrit : « forte corrélation linéaire », jamais « x cause y ».

EXERCICE 7 Entraînement Bac – Consommation d'électricité à Douala

Le tableau ci-dessous donne la consommation mensuelle d'électricité y (en kWh) en fonction du nombre d'appareils électroménagers x dans 10 foyers doualais.

x_i	3	4	5	5	6	7	7	8	9	10
y_i	120	150	180	190	210	240	250	280	300	330

1. Représenter le nuage de points et le point moyen G .
2. Déterminer la droite de Mayer.

3. Calculer $\text{cov}(x, y)$, $V(x)$, $V(y)$ et les deux droites de régression.
4. Calculer r et conclure sur la pertinence d'un ajustement affine.
5. Prévoir la consommation pour un foyer possédant 11 appareils. Est-ce une interpolation ou une extrapolation?

CORRIGÉ Exercice Entraînement Bac

1. $\bar{x} = \frac{64}{10} = 6,4$; $\bar{y} = \frac{2250}{10} = 225$. $G(6,4; 225)$. Nuage allongé croissant. 2. $n = 10$ pair. Groupe 1 (5 premiers) : $G_1(4,4; 170)$. Groupe 2 (5 derniers) : $G_2(8,2; 280)$. $a = \frac{110}{3,8} \approx 28,95$. $b = 170 - 28,95 \times 4,4 \approx 42,6$. Droite de Mayer : $y \approx 28,95x + 42,6$. 3. $\sum x_i^2 = 430$, $\sum y_i^2 = 537\,500$, $\sum x_i y_i = 15\,380$. $\text{cov} = \frac{15380}{10} - 6,4 \times 225 = 1538 - 1440 = 98$. $V(x) = \frac{430}{10} - 6,4^2 = 43 - 40,96 = 2,04$. $V(y) = \frac{537500}{10} - 225^2 = 53750 - 50625 = 3125$. $a = \frac{98}{2,04} \approx 48,04$; $b = 225 - 48,04 \times 6,4 \approx -82,46$. Droite y en x : $y \approx 48,04x - 82,46$. $a' = \frac{98}{3125} = 0,03136$; $b' = 6,4 - 0,03136 \times 225 \approx -0,656$. Droite x en y : $x \approx 0,03136y - 0,656$. 4. $r = \frac{98}{\sqrt{2,04 \times 3125}} = \frac{98}{\sqrt{6375}} \approx \frac{98}{79,84} \approx 0,977$. $r^2 \approx 0,955 \geq 0,75$. Ajustement très pertinent. 5. $y_0 = 48,04 \times 11 - 82,46 \approx 446$ kWh. Extrapolation ($11 > 10$ max observé), prudence.

10 EXERCICES

11 STATISTIQUES À DEUX VARIABLES

11.1 Séries statistiques à deux caractères

DÉFINITION Série statistique à deux caractères

On appelle **série statistique à deux caractères** (ou série double) une série où chaque individu est caractérisé par deux variables X et Y . Elle se présente sous la forme d'un tableau à double entrée ou d'une liste de couples $(x_i; y_i)$ avec des effectifs n_i (souvent $n_i = 1$).

DÉFINITION Séries marginales

Soit un tableau à double entrée croisant les modalités (ou classes) de X et Y .

- La **série marginale de X** est la série obtenue en sommant les effectifs de chaque ligne (ou colonne selon l'orientation) : elle donne la distribution de X seule.
- La **série marginale de Y** est la série obtenue en sommant les effectifs de chaque colonne (ou ligne) : elle donne la distribution de Y seule.

Les effectifs marginaux sont notés $n_{i.}$ pour X et $n_{.j}$ pour Y . L'effectif total est $n = \sum n_{i.} = \sum n_{.j}$.

PROPRIÉTÉ Moyennes et variances marginales

Les moyennes $\bar{x}$, $\bar{y}$ et les variances $V(X)$, $V(Y)$ se calculent uniquement à partir des séries marginales, exactement comme pour une série à une variable.

$$\bar{x} = \frac{1}{n} \sum n_{i.} x_i, \quad V(X) = \frac{1}{n} \sum n_{i.} (x_i - \bar{x})^2 = \overline{x^2} - \bar{x}^2$$

Idem pour Y .

EXEMPLE Tableau à double entrée : notes de maths et physique

On reprend l'exercice Bac (p. 73). Le tableau croise les notes de maths X (lignes) et physique Y (colonnes). La série marginale de X donne le nombre d'élèves par classe de note

en maths, celle de Y le nombre par classe en physique.

11.2 Nuage de points et point moyen

DÉFINITION Nuage de points

À chaque couple $(x_i; y_i)$ de la série double, on associe un point $M_i(x_i; y_i)$ dans un repère orthogonal $(O; \vec{i}, \vec{j})$. L'ensemble de ces points forme le **nuage de points**.

DÉFINITION Point moyen

Le **point moyen** G du nuage a pour coordonnées $(\bar{x}; \bar{y})$, où $\bar{x}$ et $\bar{y}$ sont les moyennes des séries marginales.

PROPRIÉTÉ Propriété fondamentale du point moyen

Le point moyen G est le centre de gravité du nuage de points (affecté des effectifs n_i). Toute droite d'ajustement affine raisonnable (Mayer, moindres carrés) passe par G .

MÉTHODE Construire un nuage de points et placer G

1. Choisir des unités graphiques adaptées à l'étendue des valeurs (ex : 1 cm pour 1 unité en x , 0,5 cm pour 10 unités en y).
2. Gradués les axes en commençant si possible à l'origine ou à une valeur proche du minimum.
3. Reporter chaque point $M_i(x_i; y_i)$.
4. Calculer $\bar{x}$ et $\bar{y}$, placer $G(\bar{x}; \bar{y})$ (souvent en rouge ou avec un symbole distinctif).

11.3 Ajustement affine par la méthode de Mayer

DÉFINITION Principe de la méthode de Mayer

Lorsque le nuage de points suggère une tendance affine, on peut tracer une droite d'ajus-

tement « à l'œil » ou par la **méthode de Mayer** :

1. Ordonner les points par x croissant.
2. Partager le nuage en deux sous-nuages de même effectif (ou au plus 1 d'écart). Si n est impair, le point central est souvent exclu ou mis dans l'un des deux.
3. Calculer les points moyens $G_1(\bar{x}_1; \bar{y}_1)$ et $G_2(\bar{x}_2; \bar{y}_2)$ de chaque sous-nuage.
4. La **droite de Mayer** est la droite (G_1G_2) .

PROPRIÉTÉ Équation de la droite de Mayer

Si $\bar{x}_1 \neq \bar{x}_2$, l'équation est $y = ax + b$ avec :

$$a = \frac{\bar{y}_2 - \bar{y}_1}{\bar{x}_2 - \bar{x}_1}, \quad b = \bar{y}_1 - a\bar{x}_1 \quad (\text{ou } \bar{y}_2 - a\bar{x}_2).$$

Si $\bar{x}_1 = \bar{x}_2$, la droite est verticale (pas de fonction $y = f(x)$).

ATTENTION Limites de la méthode de Mayer

- Le partage en deux sous-nuages est arbitraire (on pourrait couper autrement).
- Elle ne minimise aucun critère d'erreur global.
- Elle est sensible aux valeurs extrêmes (points aberrants) qui tirent G_1 ou G_2 .
- Au Bac : on l'utilise seulement si l'énoncé le demande explicitement. Sinon, on privilégie les moindres carrés.

11.4 Covariance et moindres carrés

DÉFINITION Covariance

La **covariance** de X et Y mesure leur liaison linéaire moyenne :

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n n_i (x_i - \bar{x})(y_i - \bar{y}).$$

PROPRIÉTÉ Formule de König–Huygens pour la covariance

$$\text{cov}(X, Y) = \overline{xy} - \bar{x}\bar{y} = \frac{1}{n} \sum n_i x_i y_i - \bar{x}\bar{y}.$$

C'est la formule la plus pratique pour le calcul numérique.

PROPRIÉTÉ Propriétés de la covariance

- $\text{cov}(X, X) = V(X)$.
- $\text{cov}(X, Y) = \text{cov}(Y, X)$ (symétrie).
- Bilinéarité : $\text{cov}(aX + b, cY + d) = ac \text{cov}(X, Y)$.
- Si X et Y sont indépendantes $\Rightarrow \text{cov}(X, Y) = 0$. Le réciproque est faux (liaison non linéaire possible).

EXPÉRIENCE Découverte de la méthode des moindres carrés

On cherche une droite $y = ax + b$ qui « colle » au nuage. L'erreur verticale pour M_i est $e_i = y_i - (ax_i + b)$. On minimise la somme des carrés des erreurs $S(a, b) = \sum (y_i - ax_i - b)^2$.

1. Exprimer $S(a, b)$ en fonction de $a, b, \bar{x}, \bar{y}, V(X), \text{cov}(X, Y)$.
2. Annuler les dérivées partielles $\frac{\partial S}{\partial a} = 0$ et $\frac{\partial S}{\partial b} = 0$.
3. Retrouver les formules de a et b .

PROPRIÉTÉ Droites de régression par les moindres carrés — Démonstration exigible au Bac

- Droite de régression de y en x (notée $D_{y/x}$) : prédit y connaissant x .

$$a_{y/x} = \frac{\text{cov}(X, Y)}{V(X)}, \quad b_{y/x} = \bar{y} - a_{y/x} \bar{x}.$$

- Droite de régression de x en y (notée $D_{x/y}$) : prédit x connaissant y .

$$a_{x/y} = \frac{\text{cov}(X, Y)}{V(Y)}, \quad b_{x/y} = \bar{x} - a_{x/y} \bar{y}.$$

Les deux droites passent par le point moyen $G(\bar{x}; \bar{y})$.

À RETENIR Choix de la droite de régression

- Pour prévoir y à partir de $x \rightarrow$ utiliser $D_{y/x}$ (minimise erreurs verticales).
- Pour prévoir x à partir de $y \rightarrow$ utiliser $D_{x/y}$ (minimise erreurs horizontales).
- Les deux droites sont différentes (sauf si $|r| = 1$). Elles se coupent en G .

11.5 Coefficient de corrélation linéaire**DÉFINITION** Coefficient de corrélation linéaire (de Pearson)

$$r = \frac{\text{cov}(X,Y)}{\sqrt{V(X)V(Y)}} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y}.$$

PROPRIÉTÉ Propriétés fondamentales de r

1. $-1 \leq r \leq 1$ (inégalité de Cauchy-Schwarz).
2. $r = 1 \Leftrightarrow$ tous les points sont alignés sur une droite de pente positive ($y = ax + b, a > 0$).
3. $r = -1 \Leftrightarrow$ tous les points sont alignés sur une droite de pente négative ($a < 0$).
4. $r = 0 \Leftrightarrow \text{cov}(X,Y) = 0$ (aucune liaison linéaire). Attention : $r = 0$ n'implique pas l'indépendance (ex : $y = x^2$ symétrique).
5. r est adimensionnel (sans unité) et invariant par changement d'origine et d'échelle (affine) sur X et/ou Y .

À RETENIR Interprétation de $|r|$ — Qualité de l'ajustement affine

Valeur de $ r $	Interprétation
$ r < 0,5$	Liaison linéaire faible ou nulle — ajustement peu pertinent
$0,5 \leq r < 0,8$	Liaison linéaire modérée — ajustement acceptable
$0,8 \leq r < 0,95$	Liaison linéaire forte — ajustement bon
$ r \geq 0,95$	Liaison linéaire très forte — ajustement excellent

Au Bac : on considère souvent qu'un ajustement affine est justifié si $|r| \geq 0,8$ (seuil usuel).

On commente toujours : « $r \approx 0,92$, proche de 1, donc liaison linéaire forte, l'ajustement affine est pertinent. »

PROPRIÉTÉ Coefficient de détermination r^2

r^2 représente la part de la variance de Y « expliquée » par la liaison affine avec X .

$$r^2 = \frac{[\text{cov}(X,Y)]^2}{V(X)V(Y)} = 1 - \frac{\text{Variance résiduelle}}{V(Y)}.$$

Si $r^2 = 0,85$, 85% de la dispersion de Y est expliquée par la droite de régression.

11.6 Prévisions et synthèse méthodologique

ATTENTION Interpolation vs Extrapolation

- Interpolation : prévoir y pour un x à l'intérieur de l'intervalle des x_i observés. Fiable si $|r|$ fort.
- Extrapolation : prévoir y pour un x à l'extérieur de l'intervalle observé. Très risqué : la relation affine peut ne plus tenir (saturation, seuil, courbure). Au Bac, on le fait si demandé, mais on doit signaler le risque.

MÉTHODE Synthèse : Étapes d'une étude de liaison affine

1. Représenter le nuage de points et placer $G(\bar{x}; \bar{y})$.
2. Calculer $\bar{x}, \bar{y}, V(X), V(Y), \text{cov}(X,Y)$ (formule de König-Huygens).
3. Calculer r et interpréter sa valeur (signe, intensité, pertinence de l'ajustement).
4. Si $|r|$ est assez grand ($\geq 0,8$) : déterminer l'équation de la droite de régression adaptée ($D_{y/x}$ ou $D_{x/y}$).
5. Tracer la droite de régression (deux points : G et un autre x simple).
6. Prévoir si demandé (interpolation/extrapolation) et commenter la fiabilité.

LESAVAIS-TU ? Linéarisation : quand le nuage n'est pas affine

Si le nuage de points $(x_i; y_i)$ a une allure courbe (ex : croissance exponentielle, loi de puissance), on peut parfois transformer les variables pour retrouver une liaison affine :

- **Modèle exponentiel** $y = Ae^{kx} \rightarrow$ poser $z = \ln y$. Le nuage $(x_i; z_i)$ devient affine : $z = kx + \ln A$.
- **Modèle puissance** $y = Ax^k \rightarrow$ poser $u = \ln x, v = \ln y$. Le nuage $(u_i; v_i)$ devient affine : $v = ku + \ln A$.

On applique alors toute la machinerie (régression, r , prévisions) sur les variables transformées, puis on revient au modèle initial. C'est un classique du Bac (voir exercice « Croissance d'une population »).

11.7 Je vérifie mes connaissances**EXERCICE 8 QCM**

Pour chaque question, une seule réponse est exacte. Recopie la lettre correspondante sur ta copie.

- On considère une série statistique double $(x_i; y_i)$ de point moyen $G(\bar{x}; \bar{y})$. La droite de régression de y en x :
 - passé toujours par l'origine du repère ;
 - passé toujours par le point moyen G ;
 - passé toujours par au moins deux points du nuage.
- La covariance de deux variables X et Y est définie par :
 - $\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n x_i y_i$;
 - $\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$;
 - $\text{cov}(X, Y) = \sqrt{V(X) V(Y)}$.
- Si le coefficient de corrélation linéaire vaut $r = -0,98$, alors :
 - il n'y a aucune relation entre X et Y ;
 - un ajustement affine est pertinent et Y est fonction décroissante de X ;
 - un ajustement affine est pertinent et Y est fonction croissante de X .
- La droite de régression de y en x a pour équation $y = ax + b$ avec :
 - $a = \frac{\text{cov}(X, Y)}{V(X)}$ et $b = \bar{y} - a\bar{x}$;

$$(b) \ a = \frac{V(X)}{\text{cov}(X,Y)} \text{ et } b = \bar{x} - a\bar{y};$$

$$(c) \ a = \frac{\text{cov}(X,Y)}{V(Y)} \text{ et } b = \bar{y} - a\bar{x}.$$

EXERCICE 9 Vrai ou faux, en justifiant

Réponds par vrai ou faux en justifiant chaque réponse par un argument ou un contre-exemple.

1. Deux droites de régression (de y en x et de x en y) passent toujours par le point moyen du nuage.
2. Si $r = 0$, alors les variables X et Y sont indépendantes.
3. Si $|r| = 1$, alors tous les points du nuage sont alignés.
4. La méthode de Mayer et la méthode des moindres carrés donnent toujours la même droite d'ajustement.
5. La covariance peut être un nombre négatif.

EXERCICE 10 Définitions et vocabulaire

1. Définis la **covariance** de deux variables statistiques X et Y , puis donne la formule développée de König-Huygens permettant de la calculer.
2. Définis le **coefficient de corrélation linéaire** r de deux variables X et Y . Quel encadrement vérifie-t-il toujours ?
3. Qu'appelle-t-on **séries marginales** d'un tableau statistique à double entrée ?
4. À quelle condition sur r juge-t-on, en pratique, qu'un ajustement affine est de bonne qualité ?

EXERCICE 11 Calculs directs

On considère la série statistique double suivante :

x_i	1	2	3	4
y_i	3	5	6	10

1. Calcule les moyennes $\bar{x}$ et $\bar{y}$, puis place le point moyen G .

2. Calcule la variance $V(X)$ et la covariance $\text{cov}(X, Y)$.
3. Détermine l'équation de la droite de régression de y en x .
4. Calcule le coefficient de corrélation linéaire r (on donne $V(Y) = 7,25$). Un ajustement affine est-il justifié ?

11.8 Je m'entraîne

EXERCICE 12 Nuage, point moyen et méthode de Mayer

Une coopérative agricole de l'Ouest Cameroun relève la quantité d'engrais utilisée x_i (en sacs) et le rendement du maïs y_i (en quintaux par hectare) sur six parcelles :

x_i (sacs)	1	2	3	4	5	6
y_i (q/ha)	8	11	13	15	18	21

1. Représente le nuage de points dans un repère orthogonal (unités : 2 cm pour 1 sac en abscisse, 0,5 cm pour 1 quintal en ordonnée).
2. Calcule les coordonnées du point moyen G et place-le sur le graphique.
3. Partage le nuage en deux sous-nuages de trois points chacun ; détermine les points moyens G_1 et G_2 .
4. Détermine l'équation de la droite de Mayer (G_1G_2) et trace-la.
5. À l'aide de cette droite, estime le rendement attendu pour 8 sacs d'engrais.

EXERCICE 13 Droites de régression par les moindres carrés

Le tableau ci-dessous donne la dépense mensuelle en données internet x_i (en milliers de FCFA) et le nombre d'heures de connexion y_i de huit abonnés d'un quartier de Douala :

x_i	2	3	5	5	7	8	10	12
y_i	10	14	18	22	26	30	36	40

On donne : $\sum x_i = 52$; $\sum y_i = 196$; $\sum x_i^2 = 424$; $\sum y_i^2 = 5616$; $\sum x_i y_i = 1554$.

1. Calcule $\bar{x}$, $\bar{y}$, $V(X)$ et $\text{cov}(X, Y)$.
2. Détermine l'équation de la droite de régression $D_{y/x}$ de y en x .
3. Détermine l'équation de la droite de régression $D_{x/y}$ de x en y (on donne $V(Y) = 102$).
4. Vérifie que les deux droites passent par le point moyen G .

EXERCICE 14 Comparaison de deux ajustements

On considère la série double suivante :

x_i	1	2	3	4	5	6
y_i	2,1	3,9	6,2	7,8	10,1	11,9

1. Détermine, par la méthode de Mayer (deux sous-échantillons de trois points), une équation de la droite d'ajustement D_1 .
2. Détermine, par la méthode des moindres carrés, l'équation de la droite de régression D_2 de y en x .
3. Pour $x = 10$, calcule la prévision donnée par chacune des deux droites, puis l'écart absolu entre ces deux prévisions.
4. Calcule le coefficient de corrélation linéaire r . Laquelle des deux méthodes te semble la plus fiable pour prévoir? Justifie.

EXERCICE 15 Exercice inverse

Pour une série statistique double $(X; Y)$ de 50 observations, on sait que :

- le point moyen est $G(12; \bar{y})$ avec $\bar{y}$ inconnu;
 - $V(X) = 16$ et $\text{cov}(X, Y) = 24$;
 - la droite de régression de y en x a pour équation $y = 1,5x + 4$.
1. Retrouve la valeur de $\bar{y}$ en utilisant le fait que la droite de régression passe par G .
 2. Vérifie la cohérence du coefficient directeur 1,5 avec les données de l'énoncé.
 3. On donne de plus $V(Y) = 40$. Calcule le coefficient de corrélation linéaire r .
 4. Détermine l'équation de la droite de régression de x en y sous la forme $x = a'y + b'$.

11.9 Je me prépare au Bac**EXERCICE 16** Type Bac — Chiffre d'affaires d'une entreprise de téléphonie

Une entreprise de vente de téléphones et de services mobiles, installée à Yaoundé, a relevé son chiffre d'affaires annuel y_i (en millions de FCFA) en fonction du rang x_i de l'année :

Rang x_i	1	2	3	4	5	6	7	8
CA y_i (millions FCFA)	42	50	57	65	74	81	90	97

On donne les sommes corrigées (calculées à partir du tableau) : $\sum_{i=1}^8 x_i^2 = 204$; $\sum_{i=1}^8 x_i y_i = 2835$; $\sum_{i=1}^8 y_i^2 = 41284$.

1. Représente le nuage de points $M_i(x_i ; y_i)$ dans un repère orthogonal (unités : 1 cm pour 1 an en abscisse ; 1 cm pour 10 millions de FCFA en ordonnée, en commençant la graduation à 40).
2. Calcule les coordonnées du point moyen G et place-le dans le repère.
3. (a) Calcule la variance $V(X)$ et la covariance $\text{cov}(X, Y)$.
(b) Détermine une équation de la droite de régression D de y en x (arrondir les coefficients à 10^{-2} près).
(c) Trace D dans le repère.
4. (a) Calcule le coefficient de corrélation linéaire r (arrondir à 10^{-3} près).
(b) Un ajustement affine de y en x est-il justifié ? Justifie ta réponse.
5. En admettant que l'évolution se poursuive ainsi, estime le chiffre d'affaires de l'entreprise pour l'année de rang 9, puis pour l'année de rang 12.
6. À partir de quel rang d'année le chiffre d'affaires dépassera-t-il, selon ce modèle, 150 millions de FCFA ?

EXERCICE 17 Type Bac — Tableau à double entrée : notes de maths et de physique

Dans une classe de Terminale C de 40 élèves, on a relevé les notes de mathématiques X et de physique Y (sur 20) au premier devoir harmonisé. Les résultats sont regroupés dans le tableau à double entrée suivant :

$X \setminus Y$	$[0 ; 5[$	$[5 ; 10[$	$[10 ; 15[$	$[15 ; 20]$
$[0 ; 5[$	2	1	0	0
$[5 ; 10[$	1	8	4	0
$[10 ; 15[$	0	3	10	3
$[15 ; 20]$	0	0	2	6

On prendra les centres des classes comme valeurs des caractères : 2,5 ; 7,5 ; 12,5 ; 17,5.

1. Détermine la série marginale de la variable X (effectifs par classe), puis celle de la variable Y .
2. Calcule les moyennes $\bar{x}$ et $\bar{y}$ des deux séries marginales.

3. (a) Calcule les variances $V(X)$ et $V(Y)$.
 (b) Calcule la covariance $\text{cov}(X, Y)$ (on pourra utiliser $\text{cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$ en dressant le tableau des produits $x_i y_i$ pondérés).
4. Calcule le coefficient de corrélation linéaire r entre les notes de mathématiques et de physique (arrondir à 10^{-2} près).
5. Le professeur de physique affirme : « Les élèves forts en mathématiques sont en général forts en physique. » Ce résultat statistique confirme-t-il son affirmation ? Rédige un commentaire de trois à quatre lignes.
6. Détermine l'équation de la droite de régression de y en x , puis estime la note de physique d'un élève ayant 14 en mathématiques.

EXERCICE 18 Type Bac — Changement de variable : croissance d'une population

La population d'une ville du Nord-Cameroun, bien desservie par un nouveau programme d'électrification rurale, a été relevée tous les ans pendant six ans. On note x_i le rang de l'année et y_i la population en milliers d'habitants :

Rang x_i	1	2	3	4	5	6
Population y_i (milliers)	20,0	24,2	29,3	35,5	43,0	52,1

Le nuage de points $M_i(x_i; y_i)$ présente une allure nettement courbe : un ajustement affine de y en x ne semble pas approprié. On pose alors $z_i = \ln(y_i)$.

1. Recopie et complète le tableau suivant (arrondir les z_i à 10^{-3} près) :

x_i	1	2	3	4	5	6
$z_i = \ln(y_i)$	2,996	3,186	3,378	3,570	3,761	3,953

2. Représente le nuage de points $N_i(x_i; z_i)$. Que constates-tu quant à son allure ?
3. On admet que z et x sont liés par une relation affine $z = ax + b$.
 (a) Calcule le coefficient de corrélation linéaire r' entre x et z (on donne : $\bar{z} \approx 3,474$; $\sum x_i z_i \approx 76,304$; $\sum z_i^2 \approx 73,05$; arrondir r' à 10^{-3} près). Conclue sur la pertinence de l'ajustement affine de z en x .
 (b) Détermine l'équation de la droite de régression de z en x (arrondir a à 10^{-3} et b à 10^{-2} près).
4. Dédus-en une expression de y en fonction de x de la forme $y = A e^{ax}$, où A est un réel à déterminer (arrondir à l'unité).
5. Estime la population de la ville à l'année de rang 11 (c'est-à-dire dans 5 ans). Arrondir au millier d'habitants.

6. Selon ce modèle, à partir de quelle année la population dépassera-t-elle 100 000 habitants ? (On pourra résoudre une inéquation avec la fonction $\ln$.)

12 CORRIGÉS DES EXERCICES

CORRIGÉ Exercice 1 — QCM

- Réponse b. La droite de régression de y en x a pour équation $y = ax + b$ avec $b = \bar{y} - a\bar{x}$; en $x = \bar{x}$, on obtient $y = a\bar{x} + (\bar{y} - a\bar{x}) = \bar{y}$: elle passe donc toujours par $G(\bar{x}; \bar{y})$. Elle ne passe ni par l'origine en général, ni nécessairement par des points du nuage.
- Réponse b. Par définition, $\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$. La réponse a oublie le centrage (c'est $\overline{xy}$, pas la covariance); la réponse c est le produit des écarts types.
- Réponse b. $r = -0,98$: $|r|$ est très proche de 1, donc la liaison linéaire est très forte et l'ajustement affine est pertinent; le signe négatif de r (et donc de $\text{cov}(X, Y)$, donc de la pente a) traduit une fonction décroissante.
- Réponse a. $a = \frac{\text{cov}(X, Y)}{V(X)}$ et $b = \bar{y} - a\bar{x}$. Attention : la réponse c est le coefficient de la droite de régression de x en y .

CORRIGÉ Exercice 2 — Vrai ou faux, en justifiant

- Vrai. Pour $D_{y/x}$: $b = \bar{y} - a\bar{x}$, donc $y(\bar{x}) = a\bar{x} + b = \bar{y}$. Pour $D_{x/y}$: $b' = \bar{x} - a'\bar{y}$, donc $x(\bar{y}) = a'\bar{y} + b' = \bar{x}$. Les deux droites passent par $G(\bar{x}; \bar{y})$.
- Faux. $r = 0$ signifie seulement l'absence de liaison linéaire. Contre-exemple : les points $(-2; 4), (-1; 1), (0; 0), (1; 1), (2; 4)$ vérifient $y = x^2$ (liaison parfaite, donc dépendance totale) et pourtant $\text{cov}(X, Y) = 0$ par symétrie, donc $r = 0$.
- Vrai. $|r| = 1$ si et seulement si tous les points sont alignés sur une droite non verticale (pente positive si $r = 1$, négative si $r = -1$). C'est une conséquence du cas d'égalité dans l'inégalité de Cauchy-Schwarz.
- Faux. La méthode de Mayer dépend du partage (arbitraire) en deux sous-nuages, alors que les moindres carrés minimisent un critère global unique. Voir l'exercice « Comparaison de deux ajustements » : on obtient $y \approx 1,956x + 0,155$ (Mayer) et $y \approx 1,977x + 0,081$ (moindres carrés) : deux droites distinctes.
- Vrai. La covariance donne le sens de la liaison : elle est négative dès que Y tend à décroître quand X croît. Exemple : $(1; 10), (2; 6), (3; 2)$: $\bar{x} = 2, \bar{y} = 6$,

$$\text{cov}(X, Y) = \frac{1 \times 10 + 2 \times 6 + 3 \times 2}{3} - 2 \times 6 = \frac{28}{3} - 12 = -\frac{8}{3} < 0.$$

CORRIGÉ Exercice 3 — Définitions et vocabulaire

1. La **covariance** de X et Y est la moyenne des produits des écarts à la moyenne :

$$\text{cov}(X, Y) = \frac{1}{n} \sum_{i=1}^p n_i (x_i - \bar{x})(y_i - \bar{y}).$$

Formule de König-Huygens (forme développée, pratique pour les calculs) :

$$\text{cov}(X, Y) = \overline{xy} - \bar{x} \bar{y} = \frac{1}{n} \sum_{i=1}^p n_i x_i y_i - \bar{x} \bar{y}.$$

2. Le **coefficient de corrélation linéaire** est

$$r = \frac{\text{cov}(X, Y)}{\sqrt{V(X) V(Y)}} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}.$$

Il vérifie toujours l'encadrement $-1 \leq r \leq 1$ (conséquence de l'inégalité de Cauchy-Schwarz).

3. Les **séries marginales** d'un tableau à double entrée sont les deux séries à une variable obtenues en sommant les effectifs par ligne (série marginale de X , effectifs $n_{i.}$) et par colonne (série marginale de Y , effectifs $n_{.j}$). Elles décrivent la distribution de chaque caractère pris isolément.
4. En pratique, on juge l'ajustement affine de bonne qualité lorsque $|r| \geq 0,8$ (liaison linéaire forte), et excellent lorsque $|r| \geq 0,95$. En dessous de 0,5, l'ajustement affine n'a guère de sens.

CORRIGÉ Exercice 4 — Calculs directs

1. $n = 4$. $\bar{x} = \frac{1+2+3+4}{4} = \frac{10}{4} = 2,5$; $\bar{y} = \frac{3+5+6+10}{4} = \frac{24}{4} = 6$. Donc $G(2,5; 6)$.

2. Variance de X (König-Huygens) :

$$V(X) = \frac{1^2 + 2^2 + 3^2 + 4^2}{4} - (2,5)^2 = \frac{30}{4} - 6,25 = 7,5 - 6,25 = 1,25.$$

$$\text{Moyenne des produits : } \overline{xy} = \frac{1 \times 3 + 2 \times 5 + 3 \times 6 + 4 \times 10}{4} = \frac{3 + 10 + 18 + 40}{4} = \frac{71}{4} = 17,75.$$

$$\text{cov}(X, Y) = \overline{xy} - \bar{x} \bar{y} = 17,75 - 2,5 \times 6 = 17,75 - 15 = 2,75.$$

3. $a = \frac{\text{cov}(X, Y)}{V(X)} = \frac{2,75}{1,25} = 2,2$; $b = \bar{y} - a\bar{x} = 6 - 2,2 \times 2,5 = 6 - 5,5 = 0,5$.

$$D_{y/x} : y = 2,2x + 0,5.$$

4. Variance de Y (König-Huygens) :

$$V(Y) = \frac{3^2 + 5^2 + 6^2 + 10^2}{4} - 6^2 = \frac{9 + 25 + 36 + 100}{4} - 36 = \frac{170}{4} - 36 = 42,5 - 36 = 6,5.$$

$$\sigma_x = \sqrt{1,25} \approx 1,118; \sigma_y = \sqrt{6,5} \approx 2,550.$$

$$r = \frac{2,75}{1,118 \times 2,550} \approx \frac{2,75}{2,851} \approx 0,965.$$

Comme $|r| \approx 0,97 > 0,95$, la liaison linéaire est très forte : l'ajustement affine est pleinement justifié.

CORRIGÉ Exercice 5 — Nuage, point moyen et méthode de Mayer

- On place les points $M_1(1; 8)$, $M_2(2; 11)$, $M_3(3; 13)$, $M_4(4; 15)$, $M_5(5; 18)$, $M_6(6; 21)$ dans le repère avec les unités indiquées. Le nuage a une allure nettement rectiligne ascendante.
 - $\bar{x} = \frac{1+2+3+4+5+6}{6} = \frac{21}{6} = 3,5$; $\bar{y} = \frac{8+11+13+15+18+21}{6} = \frac{86}{6} = \frac{43}{3} \approx 14,33$. Donc $G\left(3,5; \frac{43}{3}\right) \approx (3,5; 14,33)$, placé sur le graphique.
 - Sous-nuage 1 (points 1 à 3) : $\bar{x}_1 = \frac{1+2+3}{3} = 2$, $\bar{y}_1 = \frac{8+11+13}{3} = \frac{32}{3} \approx 10,67$, donc $G_1\left(2; \frac{32}{3}\right)$. Sous-nuage 2 (points 4 à 6) : $\bar{x}_2 = \frac{4+5+6}{3} = 5$, $\bar{y}_2 = \frac{15+18+21}{3} = 18$, donc $G_2(5; 18)$.
 - Pente : $a = \frac{18 - \frac{32}{3}}{5 - 2} = \frac{\frac{22}{3}}{3} = \frac{22}{9} \approx 2,44$. Ordonnée à l'origine : $b = \frac{32}{3} - \frac{22}{9} \times 2 = \frac{96 - 44}{9} = \frac{52}{9} \approx 5,78$.
 $(G_1G_2) : y = \frac{22}{9}x + \frac{52}{9}$ (soit environ $y = 2,44x + 5,78$).
- On la trace en reliant G_1 et G_2 ; on vérifie qu'elle passe par $G : \frac{22}{9} \times 3,5 + \frac{52}{9} = \frac{77+52}{9} = \frac{129}{9} = \frac{43}{3} = \bar{y}$.
- Pour $x = 8 : y = \frac{22}{9} \times 8 + \frac{52}{9} = \frac{176 + 52}{9} = \frac{228}{9} \approx 25,3$ q/ha. Commentaire : il s'agit d'une extrapolation ($x = 8$ est hors de l'intervalle $[1; 6]$ observé) : l'estimation de 25,3 q/ha est à prendre avec prudence (saturation possible du rendement).

CORRIGÉ Exercice 6 — Droites de régression par les moindres carrés

$$1. n = 8. \bar{x} = \frac{52}{8} = 6,5; \bar{y} = \frac{196}{8} = 24,5.$$

$$V(X) = \frac{424}{8} - (6,5)^2 = 53 - 42,25 = 10,75.$$

$$\overline{xy} = \frac{1554}{8} = 194,25, \text{ donc}$$

$$\text{cov}(X, Y) = 194,25 - 6,5 \times 24,5 = 194,25 - 159,25 = 35.$$

$$2. D_{y/x} : a = \frac{\text{cov}(X, Y)}{V(X)} = \frac{35}{10,75} = \frac{140}{43} \approx 3,256.$$

$$b = \bar{y} - a\bar{x} = 24,5 - \frac{140}{43} \times 6,5 = \frac{1053,5 - 910}{43} = \frac{143,5}{43} \approx 3,337.$$

$$D_{y/x} : y = \frac{140}{43}x + \frac{143,5}{43} \quad (\text{soit } y \approx 3,26x + 3,34).$$

$$3. D_{x/y} : a' = \frac{\text{cov}(X, Y)}{V(Y)} = \frac{35}{102} \approx 0,343.$$

$$b' = \bar{x} - a'\bar{y} = 6,5 - \frac{35}{102} \times 24,5 = \frac{663 - 857,5}{102} = -\frac{194,5}{102} \approx -1,907.$$

$$D_{x/y} : x = \frac{35}{102}y - \frac{194,5}{102} \quad (\text{soit } x \approx 0,343y - 1,91).$$

$$4. \text{ Pour } D_{y/x} : a\bar{x} + b = \frac{140}{43} \times 6,5 + \frac{143,5}{43} = \frac{910 + 143,5}{43} = \frac{1053,5}{43} = 24,5 = \bar{y}. \text{ Pour } D_{x/y} : a'\bar{y} + b' = \frac{35}{102} \times 24,5 - \frac{194,5}{102} = \frac{857,5 - 194,5}{102} = \frac{663}{102} = 6,5 = \bar{x}. \text{ Les deux droites passent bien par } G(6,5; 24,5).$$

CORRIGÉ Exercice 7 — Comparaison de deux ajustements

$$1. \text{ Mayer. Sous-nuage 1 : } \bar{x}_1 = 2, \bar{y}_1 = \frac{2,1 + 3,9 + 6,2}{3} = \frac{12,2}{3} \approx 4,067, \text{ donc } G_1(2; 4,067).$$

$$\text{Sous-nuage 2 : } \bar{x}_2 = 5, \bar{y}_2 = \frac{7,8 + 10,1 + 11,9}{3} = \frac{29,8}{3} \approx 9,933, \text{ donc } G_2(5; 9,933).$$

$$a_1 = \frac{9,933 - 4,067}{5 - 2} = \frac{5,866}{3} \approx 1,956; \quad b_1 = 4,067 - 1,956 \times 2 \approx 0,155.$$

$$D_1 : y \approx 1,956x + 0,155.$$

$$2. \text{ Moindres carrés. } \bar{x} = \frac{21}{6} = 3,5; \bar{y} = \frac{42}{6} = 7. V(X) = \frac{1 + 4 + 9 + 16 + 25 + 36}{6} - 12,25 = \frac{91}{6} - 12,25 = \frac{35}{12} \approx 2,917. \overline{xy} = \frac{2,1 + 7,8 + 18,6 + 31,2 + 50,5 + 71,4}{6} = \frac{181,6}{6} \approx 30,267. \text{ cov}(X, Y) =$$

$$30,267 - 3,5 \times 7 = 30,267 - 24,5 = 5,767.$$

$$a_2 = \frac{5,767}{2,917} \approx 1,977; \quad b_2 = 7 - 1,977 \times 3,5 \approx 0,081.$$

$$D_2 : y \approx 1,977x + 0,081.$$

3. Pour $x = 10$: D_1 donne $1,956 \times 10 + 0,155 \approx 19,71$; D_2 donne $1,977 \times 10 + 0,081 \approx 19,85$. Écart absolu : $|19,85 - 19,71| \approx 0,14$.

$$4. V(Y) = \frac{2,1^2 + 3,9^2 + 6,2^2 + 7,8^2 + 10,1^2 + 11,9^2}{6} - 49 = \frac{362,52}{6} - 49 = 60,42 - 49 = 11,42.$$

$$r = \frac{5,767}{\sqrt{2,917 \times 11,42}} = \frac{5,767}{\sqrt{33,31}} \approx \frac{5,767}{5,772} \approx 0,999.$$

r est extrêmement proche de 1 : la liaison linéaire est quasi parfaite. La méthode des moindres carrés est la plus fiable : elle minimise globalement la somme des carrés des erreurs et ne dépend d'aucun choix arbitraire, contrairement au partage de Mayer.

CORRIGÉ Exercice 8 — Exercice inverse

1. La droite de régression de y en x passe par $G(12; \bar{y})$, donc :

$$\bar{y} = 1,5 \times 12 + 4 = 18 + 4 = 22.$$

2. Le coefficient directeur théorique est $a = \frac{\text{cov}(X,Y)}{V(X)} = \frac{24}{16} = 1,5$. Il coïncide avec celui de l'énoncé : les données sont cohérentes.

3.

$$r = \frac{\text{cov}(X,Y)}{\sqrt{V(X)V(Y)}} = \frac{24}{\sqrt{16 \times 40}} = \frac{24}{\sqrt{640}} = \frac{24}{8\sqrt{10}} = \frac{3}{\sqrt{10}} \approx 0,949.$$

Liaison linéaire forte ($|r| \approx 0,95$).

4. $D_{x/y} : a' = \frac{\text{cov}(X,Y)}{V(Y)} = \frac{24}{40} = 0,6$; $b' = \bar{x} - a'\bar{y} = 12 - 0,6 \times 22 = 12 - 13,2 = -1,2$.

$$D_{x/y} : x = 0,6y - 1,2.$$

Vérification : le produit des pentes $a \times a' = 1,5 \times 0,6 = 0,9 = r^2$ (car $r^2 = \frac{9}{10}$) : cohérent.

CORRIGÉ Exercice 9 — Type Bac : chiffre d'affaires d'une entreprise de téléphonie

1. On place les points $M_i(x_i; y_i)$ avec les unités indiquées (graduation en ordonnée à partir de 40). Le nuage est quasiment rectiligne, croissant.

2. $n = 8; \sum x_i = 36, \sum y_i = 556.$

$$\bar{x} = \frac{36}{8} = 4,5; \quad \bar{y} = \frac{556}{8} = 69,5. \quad G(4,5; 69,5).$$

3. (a) $V(X) = \frac{204}{8} - (4,5)^2 = 25,5 - 20,25 = 5,25. \quad \overline{xy} = \frac{2835}{8} = 354,375, \text{ donc}$

$$\text{cov}(X, Y) = 354,375 - 4,5 \times 69,5 = 354,375 - 312,75 = 41,625.$$

(b) $a = \frac{41,625}{5,25} \approx 7,93; b = 69,5 - 7,93 \times 4,5 \approx 69,5 - 35,68 \approx 33,82.$

$$D : y = 7,93x + 33,82.$$

(c) On trace D par deux points : $G(4,5; 69,5)$ et par exemple $A(0; 33,82)$ ou $B(8; 97,26)$.

4. (a) $V(Y) = \frac{41284}{8} - (69,5)^2 = 5160,5 - 4830,25 = 330,25.$

$$r = \frac{41,625}{\sqrt{5,25 \times 330,25}} = \frac{41,625}{\sqrt{1733,8125}} \approx \frac{41,625}{41,639} \approx 0,9997.$$

(b) $r \approx 0,9997$: la liaison linéaire est quasi parfaite ($|r| \geq 0,95$). L'ajustement affine de y en x est pleinement justifié.

5. Rang 9 : $y = 7,93 \times 9 + 33,82 \approx 105,2$ millions de FCFA. Rang 12 : $y = 7,93 \times 12 + 33,82 \approx 129,0$ millions de FCFA. Ce sont des extrapolations : elles supposent que la tendance se maintienne, ce qui doit être signalé.

6. $7,93x + 33,82 > 150 \iff 7,93x > 116,18 \iff x > 14,65$. Le chiffre d'affaires dépassera 150 millions de FCFA à partir du rang 15.

Barème indicatif (sur 10) : nuage 1 pt ; G 1 pt ; $V(X)$ et covariance 2 pts ; équation de D 1,5 pt ; tracé 0,5 pt ; r et justification 1,5 pt ; prévisions 1,5 pt ; inéquation 1 pt.

Points de vigilance : citer la formule de König-Huygens avant tout calcul de variance ou covariance ; justifier la pertinence de l'ajustement uniquement à partir de r (pas « à l'œil ») ; mentionner le caractère extrapolé des prévisions ; bien arrondir comme demandé (10^{-2} pour a, b ; 10^{-3} pour r).

CORRIGÉ

Exercice 10 — Type Bac : tableau à double entrée, notes de maths et de physique

1. En sommant par lignes, série marginale de X : 3 ; 13 ; 16 ; 8 (total 40). En sommant par

colonnes, série marginale de Y : 3 ; 12 ; 16 ; 9 (total 40).

2. Avec les centres 2,5 ; 7,5 ; 12,5 ; 17,5 :

$$\bar{x} = \frac{3 \times 2,5 + 13 \times 7,5 + 16 \times 12,5 + 8 \times 17,5}{40} = \frac{7,5 + 97,5 + 200 + 140}{40} = \frac{445}{40} = 11,125.$$

$$\bar{y} = \frac{3 \times 2,5 + 12 \times 7,5 + 16 \times 12,5 + 9 \times 17,5}{40} = \frac{7,5 + 90 + 200 + 157,5}{40} = \frac{455}{40} = 11,375.$$

3. (a) $\overline{x^2} = \frac{3 \times 6,25 + 13 \times 56,25 + 16 \times 156,25 + 8 \times 306,25}{40} = \frac{5700}{40} = 142,5.$

$$V(X) = 142,5 - (11,125)^2 = 142,5 - 123,766 \approx 18,73.$$

$$\overline{y^2} = \frac{3 \times 6,25 + 12 \times 56,25 + 16 \times 156,25 + 9 \times 306,25}{40} = \frac{5950}{40} = 148,75.$$

$$V(Y) = 148,75 - (11,375)^2 = 148,75 - 129,391 \approx 19,36.$$

(b) Tableau des produits pondérés $n_{ij}x_iy_j$ (cases non nulles) : $2 \times 6,25 = 12,5$; $1 \times 18,75 = 18,75$; $1 \times 18,75 = 18,75$; $8 \times 56,25 = 450$; $4 \times 93,75 = 375$; $3 \times 93,75 = 281,25$; $10 \times 156,25 = 1562,5$; $3 \times 218,75 = 656,25$; $2 \times 218,75 = 437,5$; $6 \times 306,25 = 1837,5$.
Somme : 5650, donc $\overline{xy} = \frac{5650}{40} = 141,25.$

$$\text{cov}(X,Y) = 141,25 - 11,125 \times 11,375 = 141,25 - 126,547 \approx 14,70.$$

4.

$$r = \frac{14,70}{\sqrt{18,73 \times 19,36}} = \frac{14,70}{\sqrt{362,7}} \approx \frac{14,70}{19,04} \approx 0,77.$$

5. $r \approx 0,77$ est positif et proche de 0,8 : il existe une liaison linéaire modérée à forte entre les deux notes, qui varient globalement dans le même sens. L'affirmation du professeur est donc plutôt confirmée : un élève fort en maths a de bonnes chances d'être fort en physique. Toutefois, comme $|r| < 0,8$, la dispersion reste notable : la note de maths ne suffit pas à prédire précisément celle de physique.

6. $a = \frac{14,70}{18,73} \approx 0,785$; $b = 11,375 - 0,785 \times 11,125 \approx 2,64.$

$$D_{y/x} : y = 0,785x + 2,64.$$

Pour $x = 14$: $y \approx 0,785 \times 14 + 2,64 \approx 13,6$. Note de physique estimée : environ 13,6/20.

Barème indicatif (sur 10) : séries marginales 1,5 pt ; moyennes 1,5 pt ; variances 1,5 pt ; co-variance 2 pts ; r 1 pt ; commentaire 1 pt ; droite et estimation 1,5 pt.

Points de vigilance : utiliser les centres de classes (et non les bornes) ; vérifier que les deux totaux marginaux valent 40 ; dans le commentaire, citer la valeur de r , son signe et le seuil de comparaison ; l'estimation en 6. est une interpolation ($14 \in [2,5 ; 17,5]$), acceptable mais à nuancer vu $|r| < 0,8$.

CORRIGÉ Exercice 11 — Type Bac : changement de variable, croissance d'une population

1. Les valeurs $z_i = \ln(y_i)$ arrondies à 10^{-3} sont : 2,996 ; 3,186 ; 3,378 ; 3,570 ; 3,761 ; 3,953.
2. Le nuage $N_i(x_i ; z_i)$ est quasi rectiligne, croissant : la transformation $z = \ln y$ a linéarisé la relation. Un ajustement affine de z en x s'impose.

$$3. (a) \bar{x} = \frac{21}{6} = 3,5; \bar{z} = \frac{2,996 + 3,186 + 3,378 + 3,570 + 3,761 + 3,953}{6} = \frac{20,844}{6} = 3,474.$$

$$V(X) = \frac{91}{6} - 12,25 = \frac{35}{12} \approx 2,917. \overline{xz} = \frac{76,305}{6} \approx 12,718; \text{cov}(X, Z) = 12,718 - 3,5 \times 3,474 =$$

$$12,718 - 12,159 \approx 0,559. V(Z) = \frac{73,054}{6} - (3,474)^2 \approx 12,176 - 12,069 \approx 0,107.$$

$$r' = \frac{0,559}{\sqrt{2,917 \times 0,107}} = \frac{0,559}{\sqrt{0,312}} \approx \frac{0,559}{0,559} \approx 0,999.$$

$r' \approx 1$: l'ajustement affine de z en x est excellent, donc pertinent.

$$(b) a = \frac{0,559}{2,917} \approx 0,191; b = 3,474 - 0,191 \times 3,5 \approx 3,474 - 0,669 \approx 2,81.$$

$$z = 0,191x + 2,81.$$

$$4. \ln y = 0,191x + 2,81 \iff y = e^{2,81} e^{0,191x}. \text{ Or } e^{2,81} \approx 16,6 \approx 17.$$

$$y = 17 e^{0,191x} \quad (\text{en milliers d'habitants}).$$

5. Rang 11 : $y = 17 e^{0,191 \times 11} = 17 e^{2,101} \approx 17 \times 8,17 \approx 139$ milliers. Population estimée : environ 139 000 habitants (extrapolation : résultat à manier avec prudence).

$$6. 17 e^{0,191x} > 100 \iff e^{0,191x} > \frac{100}{17} \approx 5,882 \iff 0,191x > \ln(5,882) \approx 1,772 \iff x >$$

$$\frac{1,772}{0,191} \approx 9,3. \text{ La population dépassera 100 000 habitants à partir du rang 10, c'est-à-dire dans 4 ans.}$$

Barème indicatif (sur 10) : tableau 0,5 pt ; nuage et constatation 1 pt ; covariance, variances et r' 2,5 pts ; conclusion 0,5 pt ; équation de la droite 1,5 pt ; modèle exponentiel 1,5 pt ; estimation 1 pt ; inéquation 1,5 pt.

Points de vigilance : travailler sur le couple $(x ; z)$ et non $(x ; y)$ dans toute la question 3 ; justifier la pertinence par r' (et non par l'allure seule) ; pour passer de z à y , composer par l'exponentielle ($A = e^b$, et non $A = b$) ; dans l'inéquation, la fonction $\ln$ étant croissante, le sens de l'inégalité est conservé ; arrondir la population au millier comme demandé.

13 FICHE BILAN

14 SÉRIES STATISTIQUES À DEUX CARACTÈRES

DÉFINITION Série statistique à deux caractères

Soit une population de taille n sur laquelle on observe simultanément deux caractères quantitatifs x et y . On obtient une **série statistique à deux caractères** (ou série bidimensionnelle) représentée par les couples $(x_i; y_i)$ pour $i = 1, \dots, n$, avec des effectifs n_i (souvent $n_i = 1$ pour des données brutes).

DÉFINITION Tableau à double entrée et séries marginales

Lorsque les effectifs sont importants, on regroupe les valeurs de x en p classes (ou valeurs distinctes) et celles de y en q classes. Le **tableau à double entrée** croise ces classes : la case (i, j) contient l'effectif n_{ij} des individus ayant x dans la classe i et y dans la classe j . Les **séries marginales** sont les séries de x seul et de y seul, obtenues en sommant les effectifs par lignes et par colonnes :

$$n_{i.} = \sum_{j=1}^q n_{ij} \quad (\text{effectif marginal de la ligne } i) \quad n_{.j} = \sum_{i=1}^p n_{ij} \quad (\text{effectif marginal de la colonne } j)$$

On a bien $\sum_i n_{i.} = \sum_j n_{.j} = n$.

EXEMPLE Consommation d'électricité et revenu — Douala

Une enquête auprès de 20 foyers à Douala donne le revenu mensuel x (en milliers de FCFA) et la consommation d'électricité y (en kWh). Le tableau à double entrée ci-dessous regroupe les données en classes.

Revenu x (kFCFA) \ Conso y (kWh)	[100;200[	[200;300[	[300;400[	[400;500[	[500;600[	Total $n_{i.}$
[50;100[	1	2	1	0	0	4
[100;150[	0	1	3	2	0	6
[150;200[	0	0	2	3	1	6
[200;250[	0	0	0	2	2	4
Total $n_{.j}$	1	3	6	7	3	20

Série marginale de x : effectifs 4, 6, 6, 4. Série marginale de y : effectifs 1, 3, 6, 7, 3.

MÉTHODE Lire un tableau à double entrée

1. Identifier les classes (ou valeurs) des deux caractères en lignes et en colonnes.
2. L'effectif n_{ij} à l'intersection correspond aux individus vérifiant les deux conditions simultanément.
3. Les totaux des lignes (série marginale de x) et des colonnes (série marginale de y) permettent de retrouver les distributions de chaque caractère pris séparément.
4. Pour calculer une moyenne marginale, utiliser les centres des classes (ou les valeurs exactes) et les effectifs marginaux.

15 NUAGE DE POINTS ET POINT MOYEN

DÉFINITION Nuage de points

Dans un repère orthonormé $(O; \vec{i}, \vec{j})$, on représente chaque individu par le point $M_i(x_i; y_i)$. L'ensemble de ces n points forme le **nuage de points**. Le choix des échelles sur les axes doit permettre de visualiser l'ensemble du nuage sans écrasement excessif.

PROPRIÉTÉ Point moyen (barycentre)

Le **point moyen** G du nuage a pour coordonnées les moyennes arithmétiques des deux

caractères :

$$G(\bar{x}; \bar{y}) \text{ avec } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

Toute droite d'ajustement affine (Mayer ou moindres carrés) passe par G . C'est un point de contrôle indispensable.


EXEMPLE Nuage et point moyen pour l'exemple Douala

On utilise les centres des classes : $x \in \{75; 125; 175; 225\}$, $y \in \{150; 250; 350; 450; 550\}$.
Calcul des moyennes marginales (pondérées par les effectifs marginaux) :

$$\bar{x} = \frac{75 \times 4 + 125 \times 6 + 175 \times 6 + 225 \times 4}{20} = \frac{300 + 750 + 1050 + 900}{20} = \frac{3000}{20} = 150$$

$$\bar{y} = \frac{150 \times 1 + 250 \times 3 + 350 \times 6 + 450 \times 7 + 550 \times 3}{20} = \frac{150 + 750 + 2100 + 3150 + 1650}{20} = \frac{7800}{20} = 390$$

Le point moyen est $G(150; 390)$. Sur le graphique, il se place au « centre de gravité » du nuage.



Nuage de points de l'enquête Douala et position du point moyen G .

16 AJUSTEMENT AFFINE PAR LA MÉTHODE DE MAYER

DÉFINITION Principe de l'ajustement affine

Un **ajustement affine** consiste à remplacer le nuage de points par une droite d'équation $y = ax + b$ qui « suit » au mieux la tendance globale. Cette droite permet de résumer la relation entre x et y et de faire des prévisions.

MÉTHODE Méthode de Mayer (ou des deux points moyens)

1. Ordonner les n points du nuage par valeurs croissantes de x (en cas d'égalité, ordonner par y croissant).
2. Partager la liste ordonnée en deux sous-nuages d'effectifs égaux (ou différant au maximum de 1 si n est impair). Noter n_1 et n_2 leurs effectifs ($n_1 + n_2 = n$).
3. Calculer les points moyens de chaque sous-nuage :

$$G_1(\bar{x}_1; \bar{y}_1), \quad \bar{x}_1 = \frac{1}{n_1} \sum_{\text{sous-nuage 1}} x_i, \quad \bar{y}_1 = \frac{1}{n_1} \sum_{\text{sous-nuage 1}} y_i$$

et de même pour $G_2(\bar{x}_2; \bar{y}_2)$.

4. La **droite de Mayer** est la droite (G_1G_2) . Son équation s'obtient par :

$$a = \frac{\bar{y}_2 - \bar{y}_1}{\bar{x}_2 - \bar{x}_1} \quad (\text{si } \bar{x}_1 \neq \bar{x}_2), \quad b = \bar{y}_1 - a\bar{x}_1.$$

5. Vérification : La droite passe par $G(\bar{x}; \bar{y})$ car G est le barycentre de G_1 (poids n_1) et G_2 (poids n_2).

ATTENTION Pièges fréquents — Méthode de Mayer

- Ne pas partager « au milieu de l'axe des x » (par la médiane des valeurs de x), mais par l'effectif : les deux sous-nuages doivent contenir le même nombre de points.
- Si n est impair, le point central (médiane) est exclu des deux sous-nuages (ou attribué à l'un des deux de façon à équilibrer les effectifs, la méthode standard l'exclut).
- La méthode de Mayer est sensible aux valeurs extrêmes (points aberrants) car elle ne utilise que G_1 et G_2 .

EXERCICE RÉSOLU 14 Droite de Mayer — Enquête Douala

Énoncé : Déterminer l'équation de la droite de Mayer pour les 20 foyers (données brutes triées par x croissant).

SOLUTION

Solution : $n = 20$ pair $\Rightarrow$ deux sous-ensembles de 10 points chacun. On calcule les moyennes sur les 10 premiers et les 10 derniers points (détail omis ici, supposons $G_1(110; 300)$ et $G_2(190; 480)$).

$$a = \frac{480 - 300}{190 - 110} = \frac{180}{80} = 2,25, \quad b = 300 - 2,25 \times 110 = 300 - 247,5 = 52,5$$

Droite de Mayer : $y = 2,25x + 52,5$. Vérification : pour $x = 150$, $y = 2,25 \times 150 + 52,5 = 337,5 + 52,5 = 390 = \bar{y}$. G appartient bien à la droite.

17 COVARIANCE ET MOINDRES CARRÉS**DÉFINITION** Covariance

La **covariance** des deux caractères x et y mesure leur variation conjointe :

$$\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \overline{xy} - \bar{x}\bar{y}$$

où $\overline{xy} = \frac{1}{n} \sum x_i y_i$ (moyenne des produits).

PROPRIÉTÉ Propriétés de la covariance

- $\text{cov}(x, x) = V(x)$ (variance de x).
- $\text{cov}(x, y) = \text{cov}(y, x)$ (symétrie).
- Bilinéarité : $\text{cov}(ax + b, cy + d) = ac \text{cov}(x, y)$ pour $a, b, c, d \in \mathbb{R}$.
- Interprétation du signe : $\text{cov}(x, y) > 0$ signifie que x et y ont tendance à varier dans le même sens (corrélation positive) ; < 0 dans le sens inverse ; $= 0$ absence de liaison linéaire (mais pas nécessairement indépendance).

EXPÉRIENCE Démonstration guidée — Méthode des moindres carrés (Droite de régression y en x)

On cherche la droite $y = ax + b$ qui minimise la somme des carrés des écarts verticaux $S(a,b) = \sum_{i=1}^n (y_i - (ax_i + b))^2$.

1. Exprimer $S(a,b)$ en fonction de a, b et des sommes $\sum x_i, \sum y_i, \sum x_i^2, \sum x_i y_i$.
2. Annuler les dérivées partielles $\frac{\partial S}{\partial a} = 0$ et $\frac{\partial S}{\partial b} = 0$ (système normal).
3. Montrer que le système donne :

$$\begin{cases} a \sum x_i^2 + b \sum x_i = \sum x_i y_i \\ a \sum x_i + nb = \sum y_i \end{cases} \iff \begin{cases} a(\bar{x}^2 - \bar{x}^2) = \bar{x}\bar{y} - \bar{x}\bar{y} \\ b = \bar{y} - a\bar{x} \end{cases}$$

4. Conclure : $a = \frac{\text{COV}(x,y)}{V(x)}, b = \bar{y} - a\bar{x}$.

PROPRIÉTÉ Droites de régression par les moindres carrés

- **Droite de régression de y en x** (notée $D_{y/x}$) : $y = ax + b$ avec

$$a = \frac{\text{COV}(x,y)}{V(x)}, \quad b = \bar{y} - a\bar{x}.$$

Elle minimise la somme des carrés des distances verticales aux points. On l'utilise pour prévoir y connaissant x.

- **Droite de régression de x en y** (notée $D_{x/y}$) : $x = a'y + b'$ avec

$$a' = \frac{\text{COV}(x,y)}{V(y)}, \quad b' = \bar{x} - a'\bar{y}.$$

Elle minimise la somme des carrés des distances horizontales. On l'utilise pour prévoir x connaissant y.

Les deux droites passent par $G(\bar{x}; \bar{y})$ et s'y coupent. Elles sont distinctes sauf si $|r| = 1$ (points alignés).

EXEMPLE Calcul des droites de régression — Enquête Douala

On dispose des sommes (calculées à partir du tableau à double entrée avec centres de classes) : $\sum x_i = 3000, \sum y_i = 7800, \sum x_i^2 = 487\,500, \sum y_i^2 = 3\,318\,000, \sum x_i y_i = 1\,252\,500, n = 20$. Moyennes : $\bar{x} = 150, \bar{y} = 390, \overline{xy} = 62\,625, \overline{x^2} = 24\,375, \overline{y^2} = 165\,900, V(x) =$

$$24\,375 - 150^2 = 24\,375 - 22\,500 = 1\,875. V(y) = 165\,900 - 390^2 = 165\,900 - 152\,100 = 13\,800.$$

$$\text{cov}(x,y) = 62\,625 - 150 \times 390 = 62\,625 - 58\,500 = 4\,125.$$

$$\text{Droite } D_{y/x} : a = \frac{4\,125}{1\,875} = 2,2; b = 390 - 2,2 \times 150 = 390 - 330 = 60. \Rightarrow D_{y/x} : y = 2,2x + 60.$$

$$\text{Droite } D_{x/y} : a' = \frac{4\,125}{13\,800} \approx 0,2989; b' = 150 - 0,2989 \times 390 \approx 150 - 116,57 = 33,43. \Rightarrow D_{x/y} : x = 0,2989y + 33,43 \text{ (ou } y \approx 3,345x - 111,8 \text{ en tirant } y \text{ en fonction de } x, \text{ mais ce n'est plus la régression de } y \text{ en } x).$$

18 COEFFICIENT DE CORRÉLATION LINÉAIRE

DÉFINITION Coefficient de corrélation linéaire (de Pearson)

Le **coefficient de corrélation linéaire** r (ou ρ) est défini par :

$$r = \frac{\text{cov}(x,y)}{\sigma_x \sigma_y} = \frac{\text{cov}(x,y)}{\sqrt{V(x)V(y)}}$$

où $\sigma_x = \sqrt{V(x)}$, $\sigma_y = \sqrt{V(y)}$ sont les écarts-types.

PROPRIÉTÉ Propriétés fondamentales de r

- $-1 \leq r \leq 1$ (inégalité de Cauchy-Schwarz).
- $r = 1 \iff$ tous les points sont alignés sur une droite de pente positive ($y = ax + b$, $a > 0$).
- $r = -1 \iff$ tous les points sont alignés sur une droite de pente négative ($a < 0$).
- $r = 0 \iff \text{cov}(x,y) = 0$ (absence de corrélation linéaire ; il peut exister une relation non-linéaire).
- $r^2 = a \times a'$ (produit des pentes des deux droites de régression). r^2 est le **coefficient de détermination** : proportion de la variance de y expliquée par l'ajustement affine sur x .

À RETENIR Interprétation de $|r|$ — Seuil de pertinence au Bac

Valeur de $ r $	Interprétation
$ r \geq 0,87$	Corrélation linéaire forte — L'ajustement affine est pertinent (on peut prévoir).
$0,5 \leq r < 0,87$	Corrélation linéaire modérée — Ajustement possible mais prévisions peu fiables.
$ r < 0,5$	Corrélation linéaire faible ou nulle — Ajustement affine non pertinent (ne pas prévoir).

Attention : Le seuil 0,87 (correspondant à $r^2 \approx 0,75$) est la convention usuelle dans l'enseignement secondaire camerounais. Vérifiez toujours l'énoncé du sujet.

EXEMPLE Calcul et interprétation de r — Enquête Douala

$\sigma_x = \sqrt{1875} \approx 43,30$; $\sigma_y = \sqrt{13800} \approx 117,47$. $r = \frac{4125}{43,30 \times 117,47} \approx \frac{4125}{5086} \approx 0,811$. $r^2 \approx 0,658$.
Conclusion : $r > 0$ (corrélation positive : plus le revenu augmente, plus la consommation augmente). $|r| = 0,811 < 0,87$: la corrélation linéaire est modérée, l'ajustement affine est peu pertinent pour des prévisions précises. Environ 66% de la variabilité de la consommation est expliquée par le revenu.

19 PRÉVISIONS ET SYNTHÈSE MÉTHODOLOGIQUE

MÉTHODE Réaliser une prévision par ajustement affine

- Vérifier la pertinence : Calculer r . Si $|r| < 0,87$ (seuil Bac), écrire : « L'ajustement affine n'est pas pertinent, la prévision n'est pas fiable » et s'arrêter (ou préciser « à titre indicatif » si le sujet l'impose).
- Choisir la bonne droite :
 - Pour prévoir y à partir d'une valeur x_0 : utiliser $D_{y/x}$ ($y_0 = ax_0 + b$).
 - Pour prévoir x à partir d'une valeur y_0 : utiliser $D_{x/y}$ ($x_0 = a'y_0 + b'$).
- Calculer la prévision en remplaçant dans l'équation de la droite choisie.
- Discuter le résultat : Interpolation (x_0 dans l'intervalle des x observés) → prévision assez fiable. Extrapolation (x_0 hors intervalle) → prévision très incertaine, à formuler avec prudence.

ATTENTION Erreurs classiques en prévision

- Utiliser $D_{y/x}$ pour prévoir x (ou l'inverse). Les deux droites sont différentes (sauf $|r| = 1$).
- Oublier de vérifier $|r| \geq 0,87$ avant de conclure « la prévision est fiable ».
- Faire une extrapolation lointaine sans avertir sur le risque (ex : prévoir la consommation pour un revenu de 1 000 kFCFA alors que l'échantillon s'arrête à 250).
- Arrondir les coefficients a, b trop tôt (garder 3 à 4 décimales pour les calculs intermédiaires, arrondir le résultat final selon le contexte).

LESAVAIS-TU ? Le seuil 0,87 et le coefficient de détermination

Le seuil $|r| \geq 0,87$ correspond à $r^2 \geq 0,7569 \approx 75\%$. Cela signifie que la droite de régression explique au moins 75% de la variance du caractère prédit. En économie ou en biologie (ex : rendement maïs vs engrais à Dschang), on accepte parfois des seuils plus bas (0,7 ou 0,8) selon la variabilité naturelle du phénomène. Au Bac, appliquez le seuil indiqué dans l'énoncé (souvent 0,87 ou 0,9).

EXERCICE RÉSOLU 15 Prévision — Enquête Douala

Énoncé : Un foyer a un revenu de 180 kFCFA. Estimer sa consommation. Un autre foyer consomme 300 kWh. Estimer son revenu.

SOLUTION

Solution : $r \approx 0,811 < 0,87 \Rightarrow$ L'ajustement n'est pas pertinent au seuil 0,87. Les prévisions ci-dessous sont données à titre indicatif seulement.

1. Prévoir y pour $x_0 = 180$: utiliser $D_{y/x}$: $y = 2,2x + 60$. $y_0 = 2,2 \times 180 + 60 = 396 + 60 = 456$ kWh. (Interpolation : $180 \in [50; 250]$, prévision acceptable mais incertaine car $r < 0,87$).
2. Prévoir x pour $y_0 = 300$: utiliser $D_{x/y}$: $x = 0,2989y + 33,43$. $x_0 = 0,2989 \times 300 + 33,43 \approx 89,67 + 33,43 = 123,1$ kFCFA. (Interpolation : $300 \in [100; 600]$, même réserve).

À RETENIR Synthèse : La « boîte à outils » pour le Bac

- Tableau double entrée $\rightarrow$ Séries marginales (totaux lignes/colonnes).
- Nuage de points $\rightarrow$ Repère adapté, point moyen $G(\bar{x}, \bar{y})$.
- Mayer : Trier par x , couper en 2 (effectifs), G_1, G_2 , droite $(G_1 G_2)$. Vérifier $G \in (G_1 G_2)$.
- Moindres carrés : $\text{cov}(x, y) = \overline{xy} - \bar{x}\bar{y}$, $V(x) = \overline{x^2} - \bar{x}^2$. $D_{y/x}$: $a = \frac{\text{cov}}{V(x)}$, $b = \bar{y} - a\bar{x}$. $D_{x/y}$: $a' =$

$$\frac{\text{cov}}{V(y)}, b' = \bar{x} - a' \bar{y}.$$

- **Corrélation** : $r = \frac{\text{cov}}{\sigma_x \sigma_y}$. Vérifier $-1 \leq r \leq 1$. Interpréter signe et $|r|$ vs seuil.
- **Prévision** : Choisir la bonne droite ($D_{y/x}$ pour y , $D_{x/y}$ pour x). Dire si interpolation/extrapolation. Conclure avec prudence.

EXERCICE 19 Entraînement — Ventes de mangues et pluviométrie

Un producteur de mangues à Njombé note sur 12 mois la pluviométrie x (mm) et la production y (tonnes) : (120; 4,2), (150; 5,1), (180; 5,8), (200; 6,5), (220; 7,0), (250; 7,8), (280; 8,5), (300; 9,0), (320; 9,5), (350; 10,2).

1. Représenter le nuage de points et le point moyen G .
2. Déterminer la droite de Mayer.
3. Calculer la covariance, les variances, le coefficient r .
4. Déterminer les deux droites de régression.
5. Prévoir la production pour une pluviométrie de 330 mm. Commenter.

CORRIGÉ Exercice — Ventes de mangues

1. $n = 12$. $\sum x = 3150 \Rightarrow \bar{x} = 262,5$. $\sum y = 95,4 \Rightarrow \bar{y} = 7,95$. $G(262,5; 7,95)$.
2. **Mayer** : n pair, 2 sous-nuages de 6 points. Sous-nuage 1 (6 premiers) : $\bar{x}_1 = 187,5$, $\bar{y}_1 = 6,05 \Rightarrow G_1(187,5; 6,05)$. Sous-nuage 2 (6 derniers) : $\bar{x}_2 = 337,5$, $\bar{y}_2 = 9,85 \Rightarrow G_2(337,5; 9,85)$. $a = \frac{9,85 - 6,05}{337,5 - 187,5} = \frac{3,8}{150} \approx 0,02533$. $b = 6,05 - 0,02533 \times 187,5 \approx 1,30$. **Mayer** : $y = 0,0253x + 1,30$. (Vérif : $0,0253 \times 262,5 + 1,30 \approx 7,95 = \bar{y}$).
3. $\sum x^2 = 917700 \Rightarrow \overline{x^2} = 76475 \Rightarrow V(x) = 76475 - 262,5^2 = 7593,75$. $\sum y^2 = 798,48 \Rightarrow \overline{y^2} = 66,54 \Rightarrow V(y) = 66,54 - 7,95^2 = 3,3375$. $\sum xy = 27399 \Rightarrow \overline{xy} = 2283,25 \Rightarrow \text{cov} = 2283,25 - 262,5 \times 7,95 = 200,5625$. $r = \frac{200,5625}{\sqrt{7593,75 \times 3,3375}} \approx \frac{200,56}{159,1} \approx 0,996$.
4. $D_{y/x}$: $a = \frac{200,56}{7593,75} \approx 0,02641$, $b = 7,95 - 0,02641 \times 262,5 \approx 1,02$. $y = 0,0264x + 1,02$. $D_{x/y}$: $a' = \frac{200,56}{3,3375} \approx 60,10$, $b' = 262,5 - 60,10 \times 7,95 \approx -215,3$. $x = 60,10y - 215,3$.
5. $r = 0,996 > 0,87$: ajustement très pertinent. Prévoir y pour $x_0 = 330$ (interpolation) : utiliser $D_{y/x}$. $y_0 = 0,0264 \times 330 + 1,02 \approx 9,73$ tonnes.





Signé • OnBuch+

ÉQUIPE PÉDAGOGIQUE ONBUCH+
CONFORME AU PROGRAMME OFFICIEL MINESEC

OnBuch+