

MATHÉMATIQUES • 1ÈRE A

ORGANISATION ET GESTION DES DONNÉES

LEÇON NA06

STATISTIQUES

DURÉE CONSEILLÉE : 8 H

DANS CETTE LEÇON

Cette leçon aborde l'organisation de données discrètes en classes d'égales amplitudes, le calcul et l'interprétation de la moyenne, de la médiane, de la variance et de l'écart-type, ainsi que la construction d'histogrammes et de polygones des effectifs cumulés. Elle prépare l'élève à mener de petites enquêtes statistiques concrètes.

- À la fin de cette leçon, je sais regrouper une population en classes d'égales amplitudes et construire le tableau des effectifs et des fréquences cumulés croissants et décroissants.
- Je sais calculer la moyenne d'une série à modalités simples et d'une série regroupée en classes.
- Je sais déterminer la médiane à partir des tableaux des effectifs cumulés et à partir des polygones des effectifs cumulés.
- Je sais calculer la variance et l'écart-type d'une série statistique.
- Je sais construire un histogramme et les polygones des effectifs (ou fréquences) cumulés croissants et décroissants.
- Je sais interpréter la moyenne, la médiane, la variance et l'écart-type dans le contexte d'une enquête réelle.

TÉLÉCHARGE
ONBUCH

Gratuit • Google Play
Tuteur IA, annales,
concours, résultats



PASSE À ONBUCH+

Tous les cours signés, Tuteur IA
illimité, fiches PDF — onglet
OnBuch+ de l'app

CE COURS SIGNÉ CONTIENT

COURS

complet, illustré, pas à pas

MÉTHODES

et exercices résolus

EXERCICES

type examen + corrigés

FICHE BILAN

l'essentiel à retenir



Signé • OnBuch+

ÉQUIPE PÉDAGOGIQUE ONBUCH+
CONFORME AU PROGRAMME OFFICIEL MINESEC

OnBuch+

SOMMAIRE

- | | |
|--|---|
| 1. 1. Organisation des données : classes d'égales amplitudes et tableaux de fréquences | cumulés |
| 2. 2. Caractéristique de position : la moyenne | 6. 6. Interprétation et communication des résultats d'une enquête |
| 3. 3. Caractéristique de position : la médiane | 7. 7. Compléments utiles pour la Terminale (optionnel) |
| 4. 4. Caractéristiques de dispersion : variance et écart-type | 8. Activité d'intégration |
| 5. 5. Représentations graphiques : histogramme et polygones des effectifs | 9. Méthodes et exercices résolus |
| | 10. Exercices |
| | 11. Corrigés des exercices |
| | 12. Fiche bilan |

OBJECTIFS DE LA LEÇON

- À la fin de cette leçon, je sais regrouper une population en classes d'égales amplitudes et construire le tableau des effectifs et des fréquences cumulés croissants et décroissants.
- Je sais calculer la moyenne d'une série à modalités simples et d'une série regroupée en classes.
- Je sais déterminer la médiane à partir des tableaux des effectifs cumulés et à partir des polygones des effectifs cumulés.
- Je sais calculer la variance et l'écart-type d'une série statistique.
- Je sais construire un histogramme et les polygones des effectifs (ou fréquences) cumulés croissants et décroissants.
- Je sais interpréter la moyenne, la médiane, la variance et l'écart-type dans le contexte d'une enquête réelle.
- Je sais choisir la représentation graphique la plus adaptée pour communiquer les résultats d'une étude statistique.
- Je sais identifier les erreurs fréquentes lors du calcul des caractéristiques de position et de dispersion.

PRÉREQUIS

- Notion de variable statistique discrète et continue (Seconde).
- Calcul de moyennes arithmétiques simples (Seconde).
- Lecture et construction de tableaux à double entrée (Seconde).
- Notions de base sur les graphiques cartésiens (abscisses, ordonnées, échelles).
- Manipulation des pourcentages et des fréquences (Seconde).

1 ORGANISATION DES DONNÉES : CLASSES D'ÉGALES AMPLITUDES ET TABLEAUX DE FRÉQUENCES

Situation d'accroche. Au marché Mokolo à Yaoundé, Maman Béa vend des plantains. Chaque soir, pendant trente jours, elle note soigneusement dans son cahier le nombre de kilogrammes vendus : 45, 62, 38, 71, 55, 49, 66, 58, 42, 60, 53, 47, 69, 51, 64, 57, 44, 73, 50, 59, 63, 48, 56, 70, 41, 65, 52, 61, 46, 54 (en kg). Trente nombres éparpillés : impossible d'y voir clair à l'œil nu ! Pourtant, Maman Béa a des questions très concrètes : quelle quantité vend-elle en moyenne par jour ? Quelle vente sépare ses « petits jours » de ses « grands jours » ? Ses ventes sont-elles régulières ou très irrégulières ? Pour répondre, il faut d'abord **organiser** les données : les trier, les regrouper en classes, compter les effectifs et calculer des fréquences. C'est l'objet de cette première section, fondation de toute la leçon.

Problématique. Comment transformer une liste brute de données en un tableau clair, exploitable et prêt pour les calculs (moyenne, médiane, écart-type) et les représentations graphiques ?

1.1 Population, caractère et modalités

Avant de calculer quoi que ce soit, il faut savoir de quoi et de qui l'on parle. Le vocabulaire de la statistique est précis ; prenons le temps de le fixer une fois pour toutes.

DÉFINITION Population, individu, caractère, modalité

- Une **population statistique** est l'ensemble des objets (personnes, jours, marchandises, élèves...) sur lesquels porte l'étude. Chaque élément de la population est un **individu** (ou unité statistique).
- Un **caractère** (ou variable statistique) est une propriété que l'on observe sur chaque individu.
- Les différentes valeurs prises par le caractère sont ses **modalités**.
- Un caractère est **quantitatif discret** s'il ne prend que des valeurs numériques isolées (nombre d'enfants, nombre de sacs vendus) ; il est **quantitatif continu** s'il peut prendre n'importe quelle valeur d'un intervalle (taille, masse, durée).

Dans notre situation : la population est l'ensemble des 30 jours d'observation ; chaque jour est un individu ; le caractère est la masse de plantains vendue, exprimée en kg ; les modalités observées sont les nombres 38, 41, 42, ..., 73. Bien que la masse soit en théorie un caractère continu, les valeurs relevées ici sont des entiers : on parle de série à caractère discret à nombreuses modalités, ce qui justifiera le regroupement en classes.

ATTENTION Bien délimiter la population

Toute conclusion statistique n'est valable que pour la population étudiée. Si Maman Béa

a relevé ses ventes en saison sèche, elle ne peut pas en déduire ses ventes de saison des pluies. Au Probatoire, précise toujours la population et le caractère dans ta rédaction : c'est un point de méthode apprécié.

1.2 Pourquoi regrouper en classes ?

Lorsque le caractère prend beaucoup de valeurs distinctes (ici 20 modalités différentes pour 30 observations), un tableau « valeur par valeur » serait long et peu lisible : presque chaque valeur n'apparaîtrait qu'une ou deux fois. L'idée — naturelle — est de **regrouper** les valeurs proches dans des « cases » appelées **classes**. C'est exactement ce que fait un commerçant qui range sa monnaie par coupures, ou le service des examens qui annonce : « tant de candidats entre 0 et 5, tant entre 5 et 10... ».

DÉFINITION Classe d'égales amplitudes, centre de classe

Regrouper une série en **classes d'égales amplitudes**, c'est partager l'intervalle $[\min; \max]$ des valeurs en k intervalles de même longueur h , appelée **amplitude** :

$$[a_0; a_1[, [a_1; a_2[, \dots, [a_{k-1}; a_k], \quad h = a_{i+1} - a_i \text{ pour tout } i.$$

Le **centre** de la classe $[a_i; a_{i+1}[$ est le nombre $c_i = \frac{a_i + a_{i+1}}{2}$. C'est lui qui représentera la classe dans les calculs de moyenne et de variance.

ATTENTION Classes disjointes et exhaustives

Deux règles d'or :

- les classes ne doivent jamais se chevaucher : on utilise des intervalles semi-ouverts $[a; b[$, de sorte que la borne b appartient à la classe suivante ;
- la dernière classe est fermée des deux côtés : $[a_{k-1}; a_k]$, pour inclure la valeur maximale.

Écrire $[40; 50]$ puis $[50; 60]$ est une erreur classique : où rangerait-on la valeur 50 ? La convention correcte est $[40; 50[, [50; 60[, \dots$, et la dernière classe fermée.

1.3 Combien de classes ? La règle de Sturges

Trop peu de classes écrasent l'information ; trop de classes la dispersent. Le statisticien Herbert Sturges a proposé en 1926 une règle simple, encore enseignée partout dans le monde, qui donne un bon compromis pour les échantillons de taille modérée.

MÉTHODE Choisir le nombre de classes et l'amplitude

Pour une série de N observations dont le minimum est m et le maximum M :

1. Calculer le nombre de classes par la **règle de Sturges** : $k \approx 1 + 3,3 \log_{10}(N)$, arrondi à l'entier le plus proche.
2. Calculer l'**amplitude** : $h = \frac{M - m}{k}$, arrondie au supérieur (à l'unité ou au dixième près selon les données) pour être sûr de couvrir toute l'étendue.
3. Construire les classes en partant d'une borne inférieure $a_0 \leq m$ (souvent m elle-même) : $[a_0; a_0 + h[$, $[a_0 + h; a_0 + 2h[$, ...
4. Vérifier que la dernière classe contient bien M .

EXEMPLE Application aux ventes de plantains

Ici $N = 30$, $m = 38$, $M = 73$.

$$k \approx 1 + 3,3 \log_{10}(30) \approx 1 + 3,3 \times 1,477 \approx 5,87 \implies k = 6 \text{ classes.}$$

$$h = \frac{73 - 38}{6} = \frac{35}{6} \approx 5,83 \implies h = 6 \text{ (arrondi au supérieur).}$$

En partant de 38, les classes sont : $[38; 44[$, $[44; 50[$, $[50; 56[$, $[56; 62[$, $[62; 68[$, $[68; 74]$. La dernière contient bien 73. Les centres sont 41, 47, 53, 59, 65, 71.

LES AVAIS-TU ? Sturges et au-delà

La règle de Sturges suppose que les données suivent à peu près une répartition « en cloche » et donne de bons résultats pour $N < 200$. Pour de grands échantillons, les statisticiens préfèrent la règle de Freedman–Diaconis, qui utilise l'écart interquartile et résiste mieux aux valeurs extrêmes. Tu la rencontreras peut-être en études supérieures — en Première, Sturges suffit amplement et est exigible.

1.4 Effectifs, fréquences et cumulés

Une fois les classes posées, on dépouille les données : pour chaque classe, on compte combien d'observations tombent dedans. C'est le travail le plus long, et il exige de la méthode (barre chaque donnée traitée dans la liste brute!).

DÉFINITION Effectif, fréquence, cumulés

Soit une série de N observations réparties en k classes.

- L'**effectif** n_i d'une classe est le nombre d'observations appartenant à cette classe.
- La **fréquence** de la classe est $f_i = \frac{n_i}{N}$ (nombre entre 0 et 1, souvent exprimé en pourcentage).
- L'**effectif cumulé croissant** $N_i^\uparrow$ est le nombre d'observations strictement inférieures à la borne supérieure de la classe : $N_i^\uparrow = n_1 + n_2 + \dots + n_i$.
- L'**effectif cumulé décroissant** $N_i^\downarrow$ est le nombre d'observations supérieures ou égales à la borne inférieure de la classe : $N_i^\downarrow = n_i + n_{i+1} + \dots + n_k$.
- On définit de même les **fréquences cumulées** croissantes $F_i^\uparrow = \frac{N_i^\uparrow}{N}$ et décroissantes $F_i^\downarrow = \frac{N_i^\downarrow}{N}$.

EXERCICE RÉSOLU 1 Tableau complet des ventes de plantains

Énoncé. Voici les ventes quotidiennes (kg) de Maman Béa sur 30 jours : 45, 62, 38, 71, 55, 49, 66, 58, 42, 60, 53, 47, 69, 51, 64, 57, 44, 73, 50, 59, 63, 48, 56, 70, 41, 65, 52, 61, 46, 54. Construire le tableau complet : classes, centres, effectifs, fréquences (en %), effectifs cumulés croissants et décroissants.

SOLUTION

Solution détaillée. Les classes ont été déterminées plus haut (Sturges : $k = 6$, $h = 6$). Dé-pouillons classe par classe.

Classe $[38; 44[$: valeurs 38, 42, 41 $\Rightarrow n_1 = 3$. Classe $[44; 50[$: valeurs 45, 49, 47, 44, 48, 46 $\Rightarrow n_2 = 6$. Classe $[50; 56[$: valeurs 55, 53, 51, 50, 52, 54 $\Rightarrow n_3 = 6$. Classe $[56; 62[$: valeurs 58, 60, 57, 59, 56, 61 $\Rightarrow n_4 = 6$. Classe $[62; 68[$: valeurs 62, 66, 64, 63, 65 $\Rightarrow n_5 = 5$. Classe $[68; 74]$: valeurs 71, 69, 73, 70 $\Rightarrow n_6 = 4$.

Cumuls croissants : 3 ; 3 + 6 = 9 ; 9 + 6 = 15 ; 15 + 6 = 21 ; 21 + 5 = 26 ; 26 + 4 = 30. Cumuls décroissants : 30 ; 30 - 3 = 27 ; 27 - 6 = 21 ; 21 - 6 = 15 ; 15 - 6 = 9 ; 9 - 5 = 4.


Classe	Centre c_i	Effectif n_i	Fréquence f_i (%)	Eff. cum. croissant	Eff. cum. décroissant
$[38; 44[$	41	3	10,0	3	30
$[44; 50[$	47	6	20,0	9	27
$[50; 56[$	53	6	20,0	15	21
$[56; 62[$	59	6	20,0	21	15
$[62; 68[$	65	5	16,7	26	9
$[68; 74]$	71	4	13,3	30	4
Total		30	100		

Lecture : la fréquence cumulée croissante de la classe $[56; 62[$ vaut $\frac{21}{30} = 70\%$: Maman Béa vend moins de 62 kg dans 70 % des journées. Symétriquement, l'effectif cumulé décroissant de la classe $[50; 56[$ vaut 21 : il y a 21 journées où elle vend au moins 50 kg. Voilà déjà une information précieuse pour l'approvisionnement !

Lecture du tableau des fréquences cumulées

Cumul croissant en 62 : 26
 $\Rightarrow$ 26 jours sur 30 : ventes < 62 kg

Cumul décroissant en 50 : 21
 $\Rightarrow$ 21 jours sur 30 : ventes ≥ 50 kg



Les deux lectures complémentaires des effectifs cumulés : « moins de 62 kg » (croissant, 26 jours) et « au moins 50 kg » (décroissant, 21 jours).

1.5 Vérifier la cohérence du tableau

Un tableau de fréquences contient des tests de cohérence intégrés. Avant de passer aux calculs, vérifie systématiquement :

À RETENIR Contrôles obligatoires

- $\sum_{i=1}^k n_i = N$: la somme des effectifs égale l'effectif total (ici $3 + 6 + 6 + 6 + 5 + 4 = 30$).
- $\sum_{i=1}^k f_i = 1$ (ou 100 %), aux arrondis près (ici $10 + 20 + 20 + 20 + 16,7 + 13,3 = 100$).
- Le dernier effectif cumulé croissant vaut N ; la dernière fréquence cumulée croissante vaut 1 (ou 100 %).
- Le premier effectif cumulé décroissant vaut N .
- Pour chaque classe : $N_i^{\uparrow} + N_{i+1}^{\downarrow} = N$ (croissant d'une classe + décroissant de la suivante).

ATTENTION Pièges fréquents au Probatoire

- Oublier d'arrondir l'amplitude au supérieur : avec $h = 5,83$ non arrondi, la dernière classe s'arrêterait à $38 + 6 \times 5,83 \approx 73$, mais les classes « propres » à valeurs entières deviennent impossibles ; arrondir à 6 garantit la couverture.
- Confondre cumul croissant et décroissant : le cumul croissant répond à « moins de... », le décroissant à « au moins... ». Lis la question deux fois.
- Arrondis des fréquences : si la somme des fréquences arrondies donne 99,9 % ou 100,1 %, ce n'est pas une erreur de calcul mais un effet d'arrondi ; signale-le par « aux arrondis près ».
- Une observation égale à une borne : la valeur 44 appartient à $[44; 50[$, pas à $[38; 44[$. C'est la convention semi-ouverte qui tranche.

EXERCICE 1 À toi de jouer

Un cybercafé de Douala relève le nombre de clients par jour pendant 20 jours : 12, 25, 8, 31, 19, 22, 15, 28, 10, 24, 17, 33, 21, 14, 26, 9, 30, 18, 23, 16.

1. Déterminer le nombre de classes par la règle de Sturges et l'amplitude correspondante.
2. Construire le tableau complet (effectifs, fréquences, cumuls croissants et décroissants).
3. Quel pourcentage de journées compte moins de 26 clients ?

CORRIGÉ Exercice 1

1. $N = 20$, $m = 8$, $M = 33$. Sturges : $k \approx 1 + 3,3 \log_{10}(20) \approx 1 + 3,3 \times 1,301 \approx 5,29$, donc $k = 5$ classes. Amplitude : $h = \frac{33-8}{5} = 5$. Classes : $[8; 13[$, $[13; 18[$, $[18; 23[$, $[23; 28[$, $[28; 33]$.
2. Dépouillement : $[8; 13[: 12, 8, 10, 9 \Rightarrow 4$; $[13; 18[: 15, 17, 14, 16 \Rightarrow 4$; $[18; 23[: 19, 22, 21, 18 \Rightarrow 4$; $[23; 28[: 25, 24, 26, 23 \Rightarrow 4$; $[28; 33] : 31, 28, 33, 30 \Rightarrow 4$. Cumuls croissants : 4, 8, 12, 16, 20 ; décroissants : 20, 16, 12, 8, 4 ; fréquences : 20 % chacune. Vérifications : $4 \times 5 = 20$; dernière fréquence cumulée croissante = 100 %.
3. « Moins de 26 clients » : la borne 26 se trouve à l'intérieur de la classe $[23; 28[$.
 - À partir du tableau seulement (données groupées) : on utilise l'interpolation linéaire (méthode vue en section 3). L'effectif cumulé croissant au début de la classe est 12. On suppose une répartition uniforme dans la classe : $12 + \frac{26-23}{5} \times 4 = 12 + 2,4 = 14,4$ journées, soit environ 72 %.
 - À partir des données brutes (disponibles ici) : on compte exactement les valeurs < 26 : 8, 9, 10, 12, 14, 15, 16, 17, 18, 19, 21, 22, 23, 24, 25 soit 15 journées, donc 75 %.

Au Probatoire, si seules les classes sont données, on applique l'interpolation linéaire.

À RETENIR L'essentiel de la section

- Une étude statistique porte sur une **population**, décrite par un **caractère** dont les valeurs sont les **modalités**.
- Quand les modalités sont nombreuses, on regroupe en **classes d'égales amplitudes** $[a; b[$ (dernière fermée), de nombre $k \approx 1 + 3,3 \log_{10} N$ (Sturges) et d'amplitude $h = \frac{M-m}{k}$ arrondie au supérieur.
- Le tableau complet donne effectifs n_i , fréquences $f_i = n_i/N$, cumuls croissants (« moins de ») et décroissants (« au moins »).
- Contrôles : $\sum n_i = N$, $\sum f_i = 1$, dernier cumul croissant = N , premier cumul décroissant = N .
- Ce tableau est la matière première des sections suivantes : moyenne, médiane, variance, histogramme et polygones cumulés s'en déduiront directement.

2 CARACTÉRISTIQUE DE POSITION : LA MOYENNE

Dans la section précédente, nous avons appris à organiser les données : regrouper une série statistique en classes d'égales amplitudes, dresser le tableau des effectifs et des fréquences cumulés. C'est un premier pas, mais un tableau reste une masse d'informations difficile à lire d'un coup d'œil. Le directeur d'une coopérative de planteurs de la plaine de la Mvila ne veut pas contempler 40 lignes de chiffres : il veut savoir, en une phrase, « en moyenne, combien de régimes de plantains chaque producteur a-t-il vendus cette semaine ? ».

C'est exactement le rôle d'une **caractéristique de position** : résumer toute la série par un seul nombre qui indique autour de quelle valeur les données se situent. La plus célèbre — et la plus utilisée — est la **moyenne**. Cette section lui est entièrement consacrée : nous la définirons rigoureusement, nous l'étendrons aux séries regroupées en classes, nous justifierons pourquoi le centre de classe joue un rôle central, et nous apprendrons à l'interpréter comme le « centre de gravité » de la distribution.

2.1 La moyenne d'une série à modalités simples

Intuition. Imagine que cinq élèves de ta classe ont obtenu les notes 8, 10, 12, 12 et 18 sur 20 au dernier devoir de mathématiques. Si l'on voulait « redistribuer équitablement » le total des points entre les cinq élèves, chacun recevrait

$$\frac{8 + 10 + 12 + 12 + 18}{5} = \frac{60}{5} = 12.$$

La moyenne est exactement cela : la valeur que recevrait chaque individu si l'on partageait le

total de manière égale. Remarque au passage que la note 12 apparaît deux fois : plutôt que d'additionner deux fois 12, on peut écrire 2×12 . C'est l'idée de la pondération par les effectifs.

DÉFINITION Moyenne arithmétique d'une série statistique

Soit une série statistique à caractère discret, de modalités $x_1, x_2, \dots, x_p$, d'effectifs respectifs $n_1, n_2, \dots, n_p$, et d'effectif total $N = n_1 + n_2 + \dots + n_p$. La **moyenne** de la série, notée $\bar{x}$, est le nombre

$$\bar{x} = \frac{n_1 x_1 + n_2 x_2 + \dots + n_p x_p}{n_1 + n_2 + \dots + n_p} = \frac{\sum_{i=1}^p n_i x_i}{\sum_{i=1}^p n_i} = \frac{1}{N} \sum_{i=1}^p n_i x_i.$$

On dit que $\bar{x}$ est la moyenne arithmétique pondérée des modalités par leurs effectifs.

À RETENIR Moyenne et fréquences

En divisant numérateur et dénominateur par N , on obtient une écriture équivalente avec les fréquences $f_i = \frac{n_i}{N}$:

$$\bar{x} = \sum_{i=1}^p f_i x_i.$$

Cette formule est très pratique lorsque l'énoncé donne directement les fréquences (ou les pourcentages) plutôt que les effectifs.

EXEMPLE Moyenne des notes d'un groupe

Un groupe de 10 élèves de Première A a obtenu les notes suivantes en français : 6 ; 8 ; 8 ; 10 ; 11 ; 12 ; 12 ; 12 ; 14 ; 17. Le tableau des effectifs est :

Note x_i	6	8	10	11	12	14	17
Effectif n_i	1	2	1	1	3	1	1

La moyenne vaut :

$$\bar{x} = \frac{1 \times 6 + 2 \times 8 + 1 \times 10 + 1 \times 11 + 3 \times 12 + 1 \times 14 + 1 \times 17}{10} = \frac{110}{10} = 11.$$

En moyenne, les élèves du groupe ont obtenu 11 sur 20.

2.2 Une propriété fondamentale : la somme des écarts est nulle

Voici une propriété simple en apparence, mais qui éclaire profondément ce qu'est la moyenne : si l'on mesure, pour chaque donnée, son écart à la moyenne (c'est-à-dire $x_i - \bar{x}$), et que l'on additionne tous ces écarts en tenant compte des effectifs, on obtient toujours zéro.

PROPRIÉTÉ Somme nulle des écarts à la moyenne

Pour toute série statistique de moyenne $\bar{x}$, on a :

$$\sum_{i=1}^p n_i (x_i - \bar{x}) = 0.$$

Autrement dit, la somme des écarts positifs compense exactement la somme des écarts négatifs.

EXPÉRIENCE Démonstration guidée

Développons la somme en séparant les deux termes :

$$\begin{aligned} \sum_{i=1}^p n_i (x_i - \bar{x}) &= \sum_{i=1}^p n_i x_i - \sum_{i=1}^p n_i \bar{x} \\ &= \sum_{i=1}^p n_i x_i - \bar{x} \sum_{i=1}^p n_i \\ &= N\bar{x} - \bar{x}N \quad \text{car } \sum_{i=1}^p n_i x_i = N\bar{x} \text{ et } \sum_{i=1}^p n_i = N \\ &= 0. \end{aligned}$$

La démonstration tient en trois lignes : elle repose uniquement sur la définition $\bar{x} = \frac{1}{N} \sum n_i x_i$. Retiens l'idée clé : $\bar{x}$ est une constante, donc elle peut sortir de la somme.

Cette propriété justifie l'interprétation physique de la moyenne : c'est le **centre de gravité** de la distribution. Si l'on place sur une tige des poids égaux aux positions x_i (chaque position répétée n_i fois), la tige est en équilibre exactement au point d'abscisse $\bar{x}$: les « moments » à gauche et à droite se compensent. C'est pourquoi une seule valeur extrême peut « tirer » la moyenne vers elle, comme un poids lourd éloigné du point d'équilibre.

2.3 Extension aux séries regroupées en classes

Le problème. Revenons à notre enquête de la section 1 : la coopérative a relevé le nombre de régimes de plantains vendus par 40 producteurs pendant une semaine, et nous avons regroupé les données en classes d'amplitude 10 :

Classe (nombre de régimes)	[0; 10[	[10; 20[	[20; 30[	[30; 40[	[40; 50[
Effectif n_i	4	9	14	8	5

Une fois le regroupement effectué, les valeurs individuelles sont « perdues » : nous savons que 9 producteurs ont vendu entre 10 et 19 régimes, mais nous ne connaissons plus les ventes exactes de chacun. Comment alors calculer une moyenne ?

L'idée. On choisit, pour chaque classe, une valeur représentative unique, et l'on fait comme si tous les individus de la classe avaient cette valeur. Le choix naturel est le **centre de classe**.

DÉFINITION Centre de classe et moyenne d'une série groupée

Le **centre** de la classe $[a_i ; b_i[$ est le nombre

$$c_i = \frac{a_i + b_i}{2}.$$

La moyenne d'une série regroupée en classes est alors approchée par :

$$\bar{x} \approx \frac{1}{N} \sum_{i=1}^p n_i c_i.$$

EXPÉRIENCE Pourquoi le centre de classe donne-t-il une bonne approximation ?

Raisonnons sur une classe $[a ; b[$ contenant n individus, dont les valeurs exactes (inconnues) sont $v_1, v_2, \dots, v_n$. La contribution exacte de cette classe à la somme totale serait $v_1 + v_2 + \dots + v_n$.

Faisons l'hypothèse de répartition uniforme : les valeurs sont régulièrement dispersées dans la classe, c'est-à-dire qu'il y en a « autant » dans la moitié basse $[a ; c[$ que dans la moitié haute $[c ; b]$, où $c = \frac{a+b}{2}$. Alors, pour chaque valeur située à une distance d au-dessus du centre, il y a en moyenne une valeur située à peu près à la distance d en dessous :

$$(c + d) + (c - d) = 2c.$$

Les écarts se compensent deux à deux, et la somme des valeurs de la classe vaut approximativement $n \times c$:

$$v_1 + v_2 + \dots + v_n \approx n c.$$

En sommant sur toutes les classes, la somme totale des données vaut approximativement $\sum n_i c_i$, d'où $\bar{x} \approx \frac{1}{N} \sum n_i c_i$.

Conclusion : remplacer chaque classe par son centre revient à supposer que, à l'intérieur de chaque classe, la moyenne des valeurs est le centre. C'est une approximation d'autant meilleure que les classes sont étroites et que les données s'y répartissent de façon équilibrée.

ATTENTION Une moyenne approchée, pas exacte

Pour une série regroupée en classes, la valeur obtenue $\bar{x} = \frac{1}{N} \sum n_i c_i$ est une approximation de la vraie moyenne : elle dépend du découpage en classes choisi. Au Probatoire, on écrira proprement « la moyenne est environ égale à ... » et l'on utilisera le symbole $\approx$ dans la conclusion, même si les calculs intermédiaires se mènent avec le signe $=$.

2.4 Méthode de calcul à partir du tableau des effectifs**MÉTHODE** Calculer la moyenne d'une série groupée en classes

1. Compléter le tableau par une ligne (ou une colonne) « centre de classe c_i » : pour chaque classe $[a_i ; b_i[$, calculer $c_i = \frac{a_i + b_i}{2}$.
2. Ajouter une ligne « produit $n_i c_i$ » : multiplier chaque centre par l'effectif de sa classe.
3. Additionner les produits : $S = \sum n_i c_i$, et vérifier l'effectif total $N = \sum n_i$.
4. Diviser : $\bar{x} = \frac{S}{N}$, puis conclure par une phrase d'interprétation dans le contexte de l'énoncé.

EXERCICE RÉSOLU 2 Moyenne des ventes de plantains

Énoncé. La coopérative de la Mvila a relevé les ventes hebdomadaires (en régimes de plantains) de ses 40 producteurs, regroupées dans le tableau ci-dessous. Calculer la moyenne de cette série et interpréter le résultat.

Classe	[0; 10[	[10; 20[	[20; 30[	[30; 40[	[40; 50[
Effectif n_i	4	9	14	8	5

SOLUTION

Solution. On complète le tableau avec les centres de classe et les produits $n_i c_i$:

Classe	[0; 10[	[10; 20[	[20; 30[	[30; 40[	[40; 50[	Total
Centre c_i	5	15	25	35	45	
Effectif n_i	4	9	14	8	5	40
$n_i c_i$	20	135	350	280	225	1010

Détail des produits : $4 \times 5 = 20$; $9 \times 15 = 135$; $14 \times 25 = 350$; $8 \times 35 = 280$; $5 \times 45 = 225$. La

somme vaut

$$S = 20 + 135 + 350 + 280 + 225 = 1010.$$

On en déduit :

$$\bar{x} = \frac{1010}{40} = 25,25.$$

Interprétation. En moyenne, un producteur de la coopérative a vendu environ 25 régimes de plantains cette semaine-là. Si l'on redistribuait équitablement la totalité des 1010 régimes vendus entre les 40 producteurs, chacun en recevrait 25,25.

La figure suivante visualise cette distribution : les barres représentent les effectifs de chaque classe, et la ligne verticale marque la position de la moyenne $\bar{x} = 25,25$. On observe qu'elle se situe au cœur de la classe la plus peuplée, $[20; 30[$, légèrement « tirée » vers la droite par les producteurs des classes élevées.




Diagramme en barres des effectifs et position de la moyenne $\bar{x} = 25,25$: la moyenne est le « centre de gravité » de la distribution.

ATTENTION Les deux erreurs classiques au Probatoire

- Oublier la pondération. Calculer $\frac{5 + 15 + 25 + 35 + 45}{5} = 25$, c'est-à-dire la moyenne des centres sans tenir compte des effectifs, est faux : la classe $[20; 30[$ compte 14 producteurs, elle doit « peser » plus lourd que la classe $[40; 50[$ qui n'en compte que 5. Ici, la moyenne correcte est 25,25 et non 25.
- Confondre série brute et série groupée. Si l'énoncé donne les valeurs exactes (série brute), on calcule la moyenne exacte avec les modalités x_i ; si l'énoncé donne des classes, on utilise les centres c_i et l'on obtient une valeur approchée. Ne mélange ja-

mais les deux démarches dans un même calcul.

EXERCICE 2 À toi de jouer

Une boutique de recharge MTN et Orange a noté le montant (en FCFA) de 50 transactions un samedi :

Montant (FCFA)	[0; 1000[	[1000; 2000[	[2000; 3000[	[3000; 4000[
Effectif	12	18	14	6

1. Compléter le tableau avec les centres de classe et les produits $n_i c_i$.
2. Calculer le montant moyen d'une transaction.
3. Le gérant affirme : « la moitié des clients a dépensé plus que la moyenne ». Cette affirmation est-elle nécessairement vraie ? Justifier.

CORRIGÉ Exercice : montant moyen des transactions

1. Les centres sont $c_1 = 500$, $c_2 = 1500$, $c_3 = 2500$, $c_4 = 3500$. Les produits : $12 \times 500 = 6000$; $18 \times 1500 = 27000$; $14 \times 2500 = 35000$; $6 \times 3500 = 21000$.
2. Somme : $S = 6000 + 27000 + 35000 + 21000 = 89000$. Moyenne :

$$\bar{x} = \frac{89000}{50} = 1780 \text{ FCFA.}$$

3. Non. La moyenne ne partage pas la population en deux moitiés égales : c'est une caractéristique de répartition du total, pas de partage de l'effectif. Ici, $12 + 18 = 30$ clients sur 50 ont dépensé moins de 2000 FCFA, donc probablement plus de la moitié des clients a dépensé moins que la moyenne de 1780 FCFA. Le paramètre qui partage l'effectif en deux est la médiane, étudiée dans la section suivante.

LESAVAIS-TU ? D'autres moyennes existent

La moyenne étudiée ici est la moyenne arithmétique. En Terminale, tu rencontreras deux autres moyennes, adaptées aux données de nature multiplicative :

- la **moyenne géométrique** $\sqrt[n]{x_1 x_2 \dots x_n}$, idéale pour les taux d'évolution successifs (par exemple, si le prix du cacao augmente de 10 % puis de 21 %, le taux moyen annuel n'est pas 15,5 % mais se calcule avec la moyenne géométrique) ;

- la **moyenne harmonique** $\frac{n}{\frac{1}{x_1} + \dots + \frac{1}{x_n}}$, utilisée pour les moyennes de vitesses ou de débits.

Ces trois moyennes vérifient toujours : moyenne harmonique $\leq$ moyenne géométrique $\leq$ moyenne arithmétique. Un beau résultat que tu démontreras peut-être un jour!

À RETENIR L'essentiel sur la moyenne

- Série à modalités simples : $\bar{x} = \frac{1}{N} \sum n_i x_i = \sum f_i x_i$.
- Série groupée en classes : on remplace chaque classe par son centre $c_i = \frac{a_i + b_i}{2}$ et $\bar{x} \approx \frac{1}{N} \sum n_i c_i$ (valeur approchée, justifiée par l'hypothèse de répartition uniforme).
- La somme des écarts à la moyenne est nulle : $\sum n_i (x_i - \bar{x}) = 0$; la moyenne est le centre de gravité de la distribution.
- La moyenne est sensible aux valeurs extrêmes : elle ne résume pas toujours bien une série très étalée ou asymétrique — d'où l'intérêt de la médiane (section 3) et des caractéristiques de dispersion (section 4).

3 CARACTÉRISTIQUE DE POSITION : LA MÉDIANE

Dans la section précédente, nous avons appris à calculer la **moyenne** d'une série statistique : elle résume la série par une valeur « centrale » obtenue en répartissant équitablement le total des valeurs. Mais la moyenne possède un défaut bien connu : elle est très sensible aux valeurs extrêmes. Imaginons une classe de Première A où neuf élèves ont entre 8 et 12 sur 20 en mathématiques, et où un dixième élève, excellent, a 19. La moyenne de la classe sera tirée vers le haut par cette seule note, et ne reflétera plus vraiment le niveau « typique » du groupe. Pour décrire le centre d'une série autrement, les statisticiens utilisent un deuxième paramètre de position : la **médiane**. C'est l'objet de cette section.

3.1 Intuition et définition de la médiane

Une situation concrète.

Le marché central de Douala accueille chaque samedi des dizaines de vendeuses de plantains. Une enquête menée par des élèves a relevé le chiffre d'affaires (en milliers de francs CFA) de 60 vendeuses. Si l'on range ces 60 valeurs de la plus petite à la plus grande, on peut chercher la valeur qui coupe la population en deux : la moitié des vendeuses gagne moins que cette valeur, l'autre moitié gagne plus. Cette valeur « du milieu » est la médiane. Contrairement à la moyenne, une vendeuse qui aurait réalisé des ventes exceptionnelles ne la déplace pas : seule compte la position des valeurs, pas leur grandeur.

DÉFINITION Médiane d'une série statistique

Soit une série statistique d'effectif total N , dont les valeurs sont rangées dans l'ordre croissant. On appelle **médiane**, notée Me , toute valeur qui partage la population en deux parties d'effectifs égaux :

- au moins 50 % des valeurs sont inférieures ou égales à Me ;
- au moins 50 % des valeurs sont supérieures ou égales à Me .

Pour une série discrète non groupée, si N est impair, la médiane est la valeur de rang $\frac{N+1}{2}$; si N est pair, on prend par convention le centre de l'intervalle formé par les valeurs de rangs $\frac{N}{2}$ et $\frac{N}{2} + 1$ (soit la moyenne arithmétique de ces deux valeurs).

EXEMPLE Médiane d'une petite série discrète

Les notes de 7 élèves à un devoir sont, rangées dans l'ordre croissant :

5 ; 7 ; 9 ; 10 ; 11 ; 13 ; 18.

Ici $N = 7$ est impair : la médiane est la valeur de rang $\frac{7+1}{2} = 4$, soit $Me = 10$. Trois notes sont en dessous, trois au-dessus. Remarquons que la moyenne vaut $\frac{73}{7} \approx 10,4$: la note 18 l'a légèrement tirée vers le haut, alors que la médiane reste à 10.

3.2 Classe médiane et effectifs cumulés croissants

Lorsque les données sont regroupées en classes d'égales amplitudes, on ne connaît plus les valeurs individuelles : on ne peut donc pas « prendre la valeur du milieu » directement. On procède en deux temps : on repère d'abord la **classe médiane**, puis on estime la médiane à l'intérieur de cette classe.

DÉFINITION Classe médiane, effectif cumulé antérieur

Soit une série regroupée en classes d'effectif total N . On calcule les **effectifs cumulés croissants** (ECC) : pour chaque classe, l'ECC est la somme des effectifs de cette classe et de toutes les classes précédentes.

- La **classe médiane** est la première classe dont l'effectif cumulé croissant est supérieur ou égal à $\frac{N}{2}$.
- L'**effectif cumulé antérieur**, noté F_{prec} , est l'effectif cumulé croissant de la classe qui précède la classe médiane (il vaut 0 si la classe médiane est la première).

MÉTHODE Déterminer la médiane à partir du tableau

1. Calculer l'effectif total N puis le rang médian $\frac{N}{2}$.
2. Construire la colonne des effectifs cumulés croissants.
3. Repérer la **classe médiane** : la première classe dont l'ECC est supérieur ou égal à $\frac{N}{2}$.
4. Noter L la borne inférieure de la classe médiane, h son amplitude, f_{med} son effectif et F_{prec} l'effectif cumulé antérieur.
5. Appliquer la formule d'interpolation linéaire :

$$Me = L + \frac{\frac{N}{2} - F_{\text{prec}}}{f_{\text{med}}} \times h.$$

3.3 La formule d'interpolation linéaire : d'où vient-elle ?

La formule précédente n'est pas une recette magique : elle repose sur une hypothèse simple et naturelle, la répartition uniforme des valeurs à l'intérieur de la classe médiane. La démonstration guidée ci-dessous est formatrice : elle t'aide à retenir la formule en la comprenant.

EXPÉRIENCE Démonstration guidée de la formule d'interpolation

On considère la classe médiane $[L ; L + h[$, d'effectif f_{med} , et on note F_{prec} l'effectif cumulé antérieur.

1. Cumul avant la classe. Avant d'entrer dans la classe médiane, F_{prec} individus ont déjà été comptés. Pour atteindre le rang médian $\frac{N}{2}$, il manque donc

$$\frac{N}{2} - F_{\text{prec}} \text{ individus.}$$

2. Hypothèse de répartition uniforme. On suppose que les f_{med} individus de la classe médiane sont répartis régulièrement sur l'intervalle $[L ; L + h[$. Ainsi, la proportion d'individus de la classe situés avant une valeur x de la classe est proportionnelle à la longueur $x - L$:

$$\frac{\text{nombre d'individus avant } x}{f_{\text{med}}} = \frac{x - L}{h}.$$

3. Application à la médiane. La médiane est la valeur $x = Me$ pour laquelle le nombre d'individus avant x , dans la classe, est exactement celui qui manque, à savoir $\frac{N}{2} - F_{\text{prec}}$. On obtient :

$$\frac{\frac{N}{2} - F_{\text{prec}}}{f_{\text{med}}} = \frac{Me - L}{h}.$$

4. Conclusion. En multipliant les deux membres par h puis en ajoutant L :

$$Me = L + \frac{\frac{N}{2} - F_{\text{prec}}}{f_{\text{med}}} \times h. \quad \square$$

Autrement dit : la médiane avance dans la classe médiane d'une fraction de l'amplitude égale à la fraction de l'effectif qu'il faut parcourir pour atteindre le rang médian.

ATTENTION Quand la médiane tombe sur une borne de classe

Si $\frac{N}{2}$ est exactement égal à un effectif cumulé croissant (cas fréquent quand N est pair), la formule donne $Me = L + h$, c'est-à-dire la borne supérieure de la classe médiane, qui est aussi la borne inférieure de la classe suivante. Ce n'est pas une erreur de calcul ! La médiane est alors la borne commune des deux classes : interprète le résultat en disant que la moitié de la population se situe en dessous de cette borne. Vérifie toujours la cohérence de ta réponse avec le tableau des ECC.

3.4 Exemple chiffré complet : les ventes de plantains

Reprenons l'enquête auprès des 60 vendeuses de plantains du marché central. Les chiffres d'affaires hebdomadaires (en milliers de FCFA) ont été regroupés en classes d'égales amplitudes :

Classe (milliers FCFA)	[10; 20[	[20; 30[	[30; 40[	[40; 50[	[50; 60[
Effectif n_i	8	15	20	12	5
ECC	8	23	43	55	60

EXERCICE RÉSOLU 3 Médiane des ventes de plantains

Énoncé. Déterminer la médiane de cette série par le calcul, puis interpréter le résultat.

SOLUTION

Solution détaillée.

- Effectif total : $N = 8 + 15 + 20 + 12 + 5 = 60$. Rang médian : $\frac{N}{2} = 30$.
- Dans la colonne des ECC, on cherche le premier cumul supérieur ou égal à 30 : c'est 43, correspondant à la classe [30 ; 40[. C'est la **classe médiane**.
- On relève : $L = 30$, $h = 10$, $f_{\text{med}} = 20$, et l'effectif cumulé antérieur $F_{\text{prec}} = 23$.

4. Interpolation linéaire :

$$\begin{aligned} Me &= L + \frac{\frac{N}{2} - F_{\text{prec}}}{f_{\text{med}}} \times h \\ &= 30 + \frac{30 - 23}{20} \times 10 \\ &= 30 + \frac{7}{20} \times 10 = 30 + 3,5 = 33,5. \end{aligned}$$

Interprétation. $Me = 33,5$ milliers de FCFA, soit 33500 FCFA : au moins la moitié des vendeuses réalisent un chiffre d'affaires hebdomadaire inférieur à 33500 FCFA, et au moins la moitié réalisent plus. À titre de comparaison, la moyenne de cette série (calculée avec les centres de classes) vaut 33,5 milliers de FCFA : les deux paramètres sont égaux, signe d'une distribution assez équilibrée.


3.5 Lecture graphique de la médiane sur le polygone des effectifs cumulés

Le **polygone des effectifs cumulés croissants** s'obtient en plaçant, pour chaque classe, le point dont l'abscisse est la borne supérieure de la classe et l'ordonnée l'effectif cumulé croissant, puis en reliant ces points par des segments (on part de la borne inférieure de la première classe, d'ordonnée 0). Puisque l'ECC en x représente le nombre d'individus dont la valeur est inférieure à x , la médiane est l'abscisse du point du polygone dont l'ordonnée est $\frac{N}{2}$.

MÉTHODE Lecture graphique de la médiane

1. Tracer le polygone des ECC.
2. Tracer la droite horizontale d'équation $y = \frac{N}{2}$.
3. Repérer son point d'intersection avec le polygone.
4. Projeter ce point sur l'axe des abscisses : la valeur lue est la médiane.

Graphiquement, l'interpolation linéaire revient exactement à lire l'abscisse sur le segment qui traverse la ligne $y = \frac{N}{2}$: calcul et graphique sont deux visages de la même méthode.



Polygone des effectifs cumulés croissants des ventes de plantains. La médiane est l'abscisse du point d'intersection du polygone avec la droite horizontale d'ordonnée $\frac{N}{2} = 30$: on lit $Me = 33,5$ milliers de FCFA.

Sur la figure, le segment qui joint les points (30 ; 23) et (40 ; 43) traverse la ligne $y = 30$ exactement en $x = 33,5$: la lecture graphique confirme le calcul par interpolation. C'est un excellent réflexe au Probatoire : vérifier ton calcul sur ton graphique.

3.6 Moyenne ou médiane : lequel choisir ?

Les deux paramètres décrivent le « centre » d'une série, mais ils ne réagissent pas de la même manière aux valeurs extrêmes.

PROPRIÉTÉ Propriété de minimisation de la médiane (admise)

La médiane Me est une valeur qui rend minimale la somme des écarts absolus :

$$\sum_i n_i |x_i - m|.$$

Autrement dit, parmi toutes les valeurs m candidates, la médiane est celle qui est, en moyenne, la « moins éloignée » des valeurs de la série au sens de la distance absolue. (On admet ce résultat ; rappelons de manière analogue que la moyenne minimise la somme des carrés des écarts.)

Cette propriété explique la robustesse de la médiane : déplacer une valeur extrême très loin ne change pas son rang, donc ne change pas la médiane, alors que la moyenne, elle, est entraînée.

EXEMPLE Sensibilité aux valeurs extrêmes

Les revenus mensuels (en milliers de FCFA) de 5 employés d'une petite entreprise de Ba-foussam sont : 80 ; 90 ; 100 ; 110 ; 120.

- Moyenne : $\bar{x} = 100$; médiane : $Me = 100$. Les deux coïncident.
- Le directeur s'attribue un revenu de 900 au lieu de 120 : la série devient 80 ; 90 ; 100 ; 110 ; 900. La moyenne grimpe à $\bar{x} = 256$, qui ne représente plus personne, tandis que la médiane reste $Me = 100$, fidèle au revenu « typique ».

C'est pourquoi les instituts de statistique publient souvent le salaire médian plutôt que le salaire moyen.

À RETENIR L'essentiel sur la médiane

- La médiane partage la population en deux effectifs égaux : Me est la valeur de rang $\frac{N}{2}$.
- Série groupée : la classe médiane est la première classe dont l'ECC atteint ou dépasse $\frac{N}{2}$, puis

$$Me = L + \frac{\frac{N}{2} - F_{\text{prec}}}{f_{\text{med}}} \times h.$$

- Graphiquement, Me est l'abscisse du point du polygone des ECC d'ordonnée $\frac{N}{2}$.
- La médiane est peu sensible aux valeurs extrêmes ; la moyenne l'est beaucoup.

ATTENTION Pièges fréquents au Probatoire

- Ne confonds pas l'effectif de la classe médiane f_{med} avec l'effectif cumulé : la formule utilise les deux, mais à des places différentes.
- Le rang médian est $\frac{N}{2}$, et non $\frac{N+1}{2}$, pour une série groupée en classes.
- Pour le polygone des ECC, on place les points aux bornes supérieures des classes, jamais aux centres.
- Donne toujours la médiane avec son unité et une phrase d'interprétation : un résultat nu sans commentaire coûte des points.

LESAVAIS-TU ? Quartiles et déciles : vers la Terminale

La médiane coupe la population en deux. Rien n'empêche de la couper en quatre : les **quartiles** $Q_1, Q_2 = Me$ et Q_3 sont les valeurs correspondant aux rangs $\frac{N}{4}, \frac{N}{2}$ et $\frac{3N}{4}$. On peut même couper en dix avec les **déciles**. En Terminale, tu utilisera ces paramètres pour construire des diagrammes en boîte et comparer finement des distributions — par exemple les notes de deux classes de Première au même devoir, ou les rendements de deux variétés de maïs dans la plaine des Mbo. La méthode reste la même : effectifs cumulés et interpolation linéaire.

EXERCICE 3 À toi de jouer

Une coopérative de la région de l'Ouest a relevé les masses (en kg) de sacs de haricots livrés par 50 producteurs :

Masse (kg)	[40; 50[	[50; 60[	[60; 70[	[70; 80[	[80; 90[
Effectif	6	12	18	9	5

1. Construire la colonne des effectifs cumulés croissants.
2. Déterminer la classe médiane puis calculer la médiane par interpolation linéaire.
3. Tracer le polygone des ECC et vérifier graphiquement le résultat.
4. La moyenne de la série vaut 64 kg. Comparer avec la médiane et commenter.

CORRIGÉ Exercice : masses des sacs de haricots

1. Les ECC sont : 6 ; 18 ; 36 ; 45 ; 50.
2. $N = 50$, donc $\frac{N}{2} = 25$. Le premier ECC supérieur ou égal à 25 est 36 : la classe médiane est [60 ; 70[. On a $L = 60, h = 10, f_{\text{med}} = 18, F_{\text{prec}} = 18$. D'où :

$$Me = 60 + \frac{25 - 18}{18} \times 10 = 60 + \frac{70}{18} \approx 63,9 \text{ kg.}$$

3. On place les points (40 ; 0), (50 ; 6), (60 ; 18), (70 ; 36), (80 ; 45), (90 ; 50), on les relie, puis on lit l'abscisse du point d'ordonnée 25 : on retrouve environ 64 kg.
4. $Me \approx 63,9 \text{ kg}$ et $\bar{x} = 64 \text{ kg}$ sont très proches : la distribution est presque symétrique, les quelques sacs lourds de la classe [80 ; 90[tirent très légèrement la moyenne vers le haut.

4 CARACTÉRISTIQUES DE DISPERSION : VARIANCE ET ÉCART-TYPE

Dans la section précédente, nous avons appris à situer le « centre » d'une série statistique grâce à la moyenne et à la médiane. Mais connaître le centre ne suffit pas. Imagine deux vendeuses du marché Mokolo à Yaoundé : chacune vend en moyenne 30 régimes de plantains par semaine. La première vend entre 28 et 32 régimes chaque semaine ; la seconde vend tantôt 5 régimes, tantôt 55. Leurs moyennes sont identiques, pourtant leurs situations sont totalement différentes : la première peut prévoir ses achats sereinement, la seconde vit dans l'incertitude. Il nous manque un outil pour mesurer cette différence : un indicateur de **dispersion**, qui quantifie à quel point les valeurs s'éloignent de la moyenne. C'est précisément le rôle de la **variance** et de l'**écart-type**.

4.1 Pourquoi mesurer la dispersion ? Intuition

Pour mesurer à quel point une valeur x_i s'éloigne de la moyenne $\bar{x}$, l'idée naturelle est de regarder l'**écart** $x_i - \bar{x}$. Mais si l'on additionne tous ces écarts, on obtient toujours 0 : les écarts positifs compensent exactement les écarts négatifs. Il faut donc rendre tous les écarts positifs. Deux choix sont possibles : prendre la valeur absolue $|x_i - \bar{x}|$, ou prendre le carré $(x_i - \bar{x})^2$. Les mathématiciens ont retenu le carré, pour deux raisons : le carré est une fonction dérivable (ce qui simplifie tous les calculs théoriques), et il accentue les grands écarts, ce qui rend l'indicateur sensible aux valeurs extrêmes — exactement ce que l'on souhaite.

La variance est donc la moyenne des carrés des écarts à la moyenne.

4.2 La variance : définition

DÉFINITION Variance d'une série statistique

Soit une série statistique d'effectif total N , de valeurs $x_1, x_2, \dots, x_p$ d'effectifs respectifs $n_1, n_2, \dots, n_p$, et de moyenne $\bar{x}$. La **variance** de la série, notée σ^2 (ou V), est le nombre positif défini par :

$$\sigma^2 = \frac{\sum_{i=1}^p n_i (x_i - \bar{x})^2}{\sum_{i=1}^p n_i} = \frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{x})^2.$$

Pour une série regroupée en classes, on remplace chaque valeur x_i par le **centre** c_i de la classe :

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^p n_i (c_i - \bar{x})^2.$$

À RETENIR Lecture de la formule

La variance se lit ainsi : « pour chaque valeur, je calcule son écart à la moyenne, j'élève cet écart au carré, je multiplie par l'effectif, j'additionne le tout, et je divise par l'effectif total ». C'est bien une moyenne (pondérée) des carrés des écarts.

ATTENTION La variance n'est pas dans l'unité de la variable

Parce que l'on élève les écarts au carré, la variance s'exprime dans l'unité au carré. Si les ventes sont en régimes de plantains, la variance est en « régimes² », ce qui n'a pas de signification concrète. C'est pourquoi on introduit l'écart-type, qui « défait » le carré.

4.3 L'écart-type : définition et interprétation

DÉFINITION Écart-type

L'**écart-type** d'une série statistique, noté σ , est la racine carrée de la variance :

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{x})^2}.$$

L'écart-type s'interprète comme un **écart moyen quadratique** : il donne l'ordre de grandeur de la distance « typique » entre les valeurs de la série et la moyenne.

PROPRIÉTÉ Interprétation de l'écart-type

- Plus σ est petit, plus les valeurs sont concentrées autour de la moyenne : la série est homogène, la moyenne est représentative.
- Plus σ est grand, plus les valeurs sont dispersées : la série est hétérogène, la moyenne résume mal la situation.
- On a toujours $\sigma \geq 0$, et $\sigma = 0$ si et seulement si toutes les valeurs sont égales.

LE SAVAIS-TU ? L'écart-type parle votre langue

Contrairement à la variance, l'écart-type s'exprime dans la même unité que la variable : en régimes de plantains, en francs CFA, en notes sur 20, en minutes. Dire « l'écart-type des

notes de la classe est de 3 points » se comprend immédiatement : les notes s'écartent typiquement d'environ 3 points de la moyenne. C'est ce qui fait de l'écart-type l'indicateur de dispersion le plus utilisé au monde, des laboratoires pharmaceutiques aux sondages électoraux.

4.4 La formule de König-Huygens : un calcul allégé

La formule de définition exige de calculer d'abord $\bar{x}$, puis chaque écart $x_i - \bar{x}$, puis son carré : c'est long, et les arrondis de $\bar{x}$ faussent le résultat. Il existe une formule équivalente, bien plus pratique.

PROPRIÉTÉ Formule de König-Huygens

La variance peut se calculer par la formule dite de **König-Huygens** :

$$\sigma^2 = \frac{\sum_{i=1}^p n_i x_i^2}{\sum_{i=1}^p n_i} - \bar{x}^2 = \frac{1}{N} \sum_{i=1}^p n_i x_i^2 - \bar{x}^2.$$

Autrement dit : la variance est la moyenne des carrés moins le carré de la moyenne. Pour une série en classes, on remplace x_i par le centre c_i .

EXPÉRIENCE Démonstration guidée de la formule de König-Huygens

Cette démonstration est formatrice et sa démarche est exigible. Suivons-la pas à pas. On part de la définition et on développe le carré :

$$\begin{aligned} \sum_{i=1}^p n_i (x_i - \bar{x})^2 &= \sum_{i=1}^p n_i (x_i^2 - 2\bar{x} x_i + \bar{x}^2) && \text{(identité remarquable)} \\ &= \sum_{i=1}^p n_i x_i^2 - 2\bar{x} \sum_{i=1}^p n_i x_i + \bar{x}^2 \sum_{i=1}^p n_i && \text{(on distribue et on sort les constantes)} \end{aligned}$$

Or, par définition de la moyenne, $\sum_{i=1}^p n_i x_i = N\bar{x}$, et $\sum_{i=1}^p n_i = N$. En remplaçant :

$$\begin{aligned}\sum_{i=1}^p n_i (x_i - \bar{x})^2 &= \sum_{i=1}^p n_i x_i^2 - 2\bar{x} \times N\bar{x} + \bar{x}^2 \times N \\ &= \sum_{i=1}^p n_i x_i^2 - 2N\bar{x}^2 + N\bar{x}^2 \\ &= \sum_{i=1}^p n_i x_i^2 - N\bar{x}^2.\end{aligned}$$

En divisant les deux membres par N , on obtient :

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^p n_i x_i^2 - \bar{x}^2.$$

La formule est démontrée. Retiens l'idée clé : développer le carré, puis utiliser les deux identités $\sum n_i x_i = N\bar{x}$ et $\sum n_i = N$.

MÉTHODE

Calculer variance et écart-type avec König-Huygens

1. Compléter le tableau avec deux colonnes : $n_i x_i$ (pour la moyenne) et $n_i x_i^2$ (pour la variance). Pour une série en classes, utiliser les centres c_i : colonnes $n_i c_i$ et $n_i c_i^2$.
2. Calculer la moyenne : $\bar{x} = \frac{\sum n_i x_i}{N}$.
3. Calculer la moyenne des carrés : $\frac{\sum n_i x_i^2}{N}$.
4. Appliquer König-Huygens : $\sigma^2 = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$.
5. Prendre la racine carrée : $\sigma = \sqrt{\sigma^2}$, en arrondissant raisonnablement (souvent au centième).

Cette méthode demande moins d'opérations que la définition et est plus stable numériquement : on évite de soustraire un $\bar{x}$ arrondi à chaque valeur.

ATTENTION

Pièges fréquents au Probatoire

- Diviser par N , pas par $N - 1$: pour décrire une population étudiée (le cadre de la Pre-

mière), on divise par l'effectif total N . L'estimateur « non biaisé » avec $N-1$ n'intervient que lorsqu'on veut estimer la variance d'une population à partir d'un échantillon : ce sera vu en Terminale.

- Ne pas confondre $\frac{\sum n_i x_i^2}{N}$ et $\bar{x}^2$: ce sont deux quantités différentes, et c'est leur différence qui donne la variance.
- Une variance est toujours positive ou nulle. Si ton calcul donne un nombre négatif, il y a forcément une erreur (souvent un arrondi de $\bar{x}$ trop brutal).
- Ne jamais écrire $\sigma^2 = \sum n_i (x_i - \bar{x})^2$ en oubliant la division par N .

4.5 Exemple chiffré : les ventes de plantains

EXERCICE RÉSOLU 4 Variance et écart-type des ventes de plantains

Mama Françoise, vendeuse au marché de Bafoussam, a relevé ses ventes quotidiennes de régimes de plantains pendant 20 jours :

Nombre de régimes x_i	10	20	30	40	50
Nombre de jours n_i	2	5	7	4	2

Calculer la moyenne, la variance et l'écart-type de cette série, puis interpréter.

SOLUTION

Solution détaillée. Complétons le tableau avec les colonnes $n_i x_i$ et $n_i x_i^2$:

x_i	10	20	30	40	50	Totaux
n_i	2	5	7	4	2	$N = 20$
$n_i x_i$	20	100	210	160	100	590
$n_i x_i^2$	200	2000	6300	6400	5000	19 900

Étape 1 — Moyenne :

$$\bar{x} = \frac{590}{20} = 29,5 \text{ régimes.}$$

Étape 2 — Moyenne des carrés :

$$\frac{\sum n_i x_i^2}{N} = \frac{19\,900}{20} = 995.$$

Étape 3 — Variance par König-Huygens :

$$\sigma^2 = 995 - (29,5)^2 = 995 - 870,25 = 124,75.$$


Étape 4 — Écart-type :

$$\sigma = \sqrt{124,75} \approx 11,17 \text{ régimes.}$$

Interprétation : Mama Françoise vend en moyenne 29,5 régimes par jour, avec un écart-type d'environ 11,2 régimes. Ses ventes quotidiennes s'écartent donc typiquement d'une dizaine de régimes de la moyenne : l'activité est assez variable. Pour sécuriser ses achats auprès des producteurs, elle devra prévoir une marge.

4.6 Comparer deux séries de même moyenne

Revenons à nos deux vendeuses du marché Mokolo. Les deux séries ci-dessous ont la même moyenne $\bar{x} = 30$ régimes, mais des dispersions très différentes.



Deux séries de même moyenne $\bar{x} = 30$: la série A (bleue) est concentrée autour de la moyenne (petit écart-type), la série B (orange) est très dispersée (grand écart-type).

PROPRIÉTÉ Rôle de l'écart-type dans la comparaison

Pour comparer deux séries de même nature (même unité), la moyenne indique le niveau général, et l'écart-type indique la régularité :

- à moyennes égales, la série au plus petit écart-type est la plus régulière, la plus prévisible ;
- à moyennes différentes, on compare d'abord les moyennes, puis on nuance avec les écarts-types.

EXEMPLE Notes de deux classes de Première A

Deux classes ont toutes deux une moyenne de 11/20 au même devoir de mathématiques. La classe A a un écart-type de 2 points, la classe B un écart-type de 5 points. En classe A, les notes sont homogènes : la plupart des élèves sont autour de 11. En classe B, les notes sont très dispersées : d'excellents élèves côtoient des élèves en grande difficulté. Le professeur de la classe B devra différencier son accompagnement, alors que celui de la classe A peut miser sur un enseignement uniforme. Même moyenne, réalités pédagogiques opposées : voilà toute la puissance de l'écart-type.

EXERCICE 4 À toi de jouer

On a relevé les durées de communication (en minutes) d'un échantillon d'abonnés MTN : les classes sont $[0; 10[$, $[10; 20[$, $[20; 30[$, $[30; 40[$, d'effectifs respectifs 8, 15, 12, 5.

1. Construire le tableau avec les centres c_i , les colonnes $n_i c_i$ et $n_i c_i^2$.
2. Calculer la moyenne $\bar{x}$.
3. Calculer la variance par la formule de König-Huygens, puis l'écart-type. Interpréter.

CORRIGÉ Exercice : durées de communication

1. Les centres sont $c_1 = 5$, $c_2 = 15$, $c_3 = 25$, $c_4 = 35$ et $N = 8 + 15 + 12 + 5 = 40$.

c_i	5	15	25	35	Totaux
n_i	8	15	12	5	40
$n_i c_i$	40	225	300	175	740
$n_i c_i^2$	200	3375	7500	6125	17 200

2. $\bar{x} = \frac{740}{40} = 18,5$ minutes.
3. Variance : $\sigma^2 = \frac{17\,200}{40} - (18,5)^2 = 430 - 342,25 = 87,75$. Écart-type : $\sigma = \sqrt{87,75} \approx 9,37$ minutes. Les durées de communication s'écartent typiquement d'environ 9,4 minutes de la durée moyenne de 18,5 minutes : les comportements des abonnés sont assez dispersés.

À RETENIR L'essentiel de la section

- La **variance** mesure la dispersion : $\sigma^2 = \frac{1}{N} \sum n_i (x_i - \bar{x})^2$ (avec les centres c_i pour les classes).
- La formule de **König-Huygens** allège les calculs : $\sigma^2 = \frac{1}{N} \sum n_i x_i^2 - \bar{x}^2$ — « moyenne des carrés moins carré de la moyenne ».
- L'**écart-type** $\sigma = \sqrt{\sigma^2}$ s'exprime dans l'unité de la variable : petit σ = série homogène ; grand σ = série dispersée.
- On divise toujours par l'effectif total N en Première.

5 REPRÉSENTATIONS GRAPHIQUES : HISTOGRAMME ET POLYGONES DES EFFECTIFS CUMULÉS

Dans la section précédente, nous avons résumé une série statistique par des nombres : la moyenne, la médiane, la variance et l'écart-type. Ces indicateurs sont précieux, mais ils restent abstraits. Un gestionnaire du marché de Mokolo, un chef d'établissement ou un agent de CAMTEL préfère souvent voir les données. C'est toute la force des représentations graphiques : un bon graphique révèle d'un coup d'œil la forme de la distribution (concentrée ou étalée, symétrique ou non), là où un tableau de chiffres demande un effort de lecture. Dans cette section, tu vas apprendre à construire rigoureusement les deux représentations exigibles au programme de Première : l'**histogramme** et les **polygones des effectifs cumulés**, et à lire graphiquement la médiane.

5.1 L'histogramme : représenter une série regroupée en classes

Intuition. Reprenons notre exemple fil rouge : un vendeur de plantains au marché a relevé, pendant 50 jours, la masse de plantains vendue chaque jour (en kg). Les données, regroupées en classes à la section 1, sont les suivantes :

Classe (kg)	[0 ; 10[	[10 ; 20[	[20 ; 30[	[30 ; 50[
Effectif n_i	5	15	20	10
Fréquence f_i	0,10	0,30	0,40	0,20

Comment dessiner cela ? L'idée naturelle est de représenter chaque classe par un rectangle dont la base est l'amplitude de la classe. Mais que mettre en hauteur ? Si toutes les classes ont la même amplitude, on peut mettre l'effectif directement. Mais ici, la dernière classe [30 ; 50[est deux fois plus large que les autres. Si l'on mettait simplement l'effectif 10 en hauteur, cette classe paraîtrait « petite » alors qu'elle couvre une large plage de valeurs : le dessin mentirait. La solution consiste à raisonner en aires.

DÉFINITION Histogramme et densité de fréquence

L'**histogramme** d'une série regroupée en classes est un graphique constitué de rectangles juxtaposés :

- la base de chaque rectangle, portée sur l'axe des abscisses, est l'intervalle de la classe (sa longueur est l'**amplitude** a_i);
- la hauteur du rectangle est la **densité** de la classe : densité d'effectif $d_i = \frac{n_i}{a_i}$ ou densité de fréquence $d_i = \frac{f_i}{a_i}$.

Ainsi, l'aire de chaque rectangle est proportionnelle à l'effectif (ou égale à la fréquence) de la classe.

ATTENTION Le piège des classes d'amplitudes inégales

Si les classes n'ont pas toutes la même amplitude, il est interdit de porter les effectifs (ou les fréquences) directement en hauteur. Un rectangle deux fois plus large aurait, à hauteur égale, une aire deux fois plus grande : le lecteur croirait que la classe contient deux fois plus d'individus. C'est l'aire, et non la hauteur, qui doit représenter l'effectif. En revanche, si toutes les classes ont la même amplitude, diviser par a_i ne change que l'échelle verticale : on peut alors porter directement les effectifs en hauteur.

PROPRIÉTÉ Aire totale de l'histogramme

Dans un histogramme construit avec les densités de fréquences $d_i = \frac{f_i}{a_i}$, l'aire totale des rectangles vaut 1 (soit 100 %). En effet, l'aire du rectangle de la classe i est $a_i \times d_i = a_i \times \frac{f_i}{a_i} = f_i$, donc :

$$\text{Aire totale} = \sum_i f_i = 1.$$

De même, avec les densités d'effectifs $d_i = \frac{n_i}{a_i}$, l'aire totale vaut l'effectif total N . Cette propriété permet de vérifier qu'un histogramme est correctement construit.

MÉTHODE Tracer correctement un histogramme

1. Repérer les classes et vérifier si les amplitudes sont égales ou non.


2. Calculer l'amplitude a_i de chaque classe, puis la densité $d_i = \frac{n_i}{a_i}$ (ou $\frac{f_i}{a_i}$).
3. Choisir les échelles : sur l'axe des abscisses, une unité graphique pour un nombre fixe d'unités du caractère ; sur l'axe des ordonnées, une échelle adaptée à la plus grande densité. Indiquer les unités sur chaque axe.
4. Tracer, pour chaque classe, le rectangle de base la classe et de hauteur sa densité, les rectangles étant juxtaposés sans espace.
5. Vérifier : la somme des aires doit valoir N (densités d'effectifs) ou 1 (densités de fréquences).

EXEMPLE Histogramme des ventes de plantains

Pour notre vendeur, calculons les densités d'effectifs :

Classe	[0 ; 10[	[10 ; 20[	[20 ; 30[	[30 ; 50[
Amplitude a_i	10	10	10	20
Effectif n_i	5	15	20	10
Densité $d_i = n_i / a_i$	0,5	1,5	2	0,5

Remarque bien la dernière colonne : l'effectif 10 divisé par l'amplitude 20 donne une densité de 0,5, deux fois moins que ce qu'aurait suggéré une lecture naïve. L'aire totale vaut $10 \times 0,5 + 10 \times 1,5 + 10 \times 2 + 20 \times 0,5 = 5 + 15 + 20 + 10 = 50 = N$: l'histogramme est cohérent.



Histogramme en densités d'effectifs des ventes journalières de plantains. La classe $[30;50[$, deux fois plus large, a une hauteur réduite de moitié : c'est l'aire de chaque rectangle qui est égale à l'effectif.

5.2 Les polygones des effectifs cumulés

Intuition. Supposons que le vendeur se pose la question : « Combien de jours ai-je vendu moins de 20 kg ? » La réponse, $5 + 15 = 20$ jours, est un effectif cumulé croissant. S'il se demande « combien de jours ai-je vendu au moins 20 kg ? », la réponse, $20 + 10 = 30$ jours, est un effectif cumulé décroissant. Plutôt que de refaire ces additions à chaque question, on dessine une courbe qui y répond pour toutes les bornes possibles : c'est le polygone des effectifs cumulés.

DÉFINITION Polygones des effectifs cumulés

Pour une série regroupée en classes de bornes $x_0 < x_1 < \dots < x_r$:


- le **polygone des effectifs cumulés croissants** est la ligne brisée joignant les points $(x_i; ECC_i)$, où ECC_i est le nombre d'individus dont la valeur est strictement inférieure à la borne supérieure x_i ; on le fait partir du point $(x_0; 0)$;
- le **polygone des effectifs cumulés décroissants** est la ligne brisée joignant les points $(x_i; ECD_i)$, où ECD_i est le nombre d'individus dont la valeur est supérieure ou égale à la borne inférieure x_i ; il se termine au point $(x_r; 0)$.

On définit de même les polygones de fréquences cumulées, en remplaçant les effectifs par les fréquences cumulées (comprises entre 0 et 1, ou 0 et 100 %).

EXEMPLE Tableau des cumuls pour les ventes de plantains

Borne x_i (kg)	0	10	20	30	50
ECC (moins de x_i kg)	0	5	20	40	50
ECD (au moins x_i kg)	50	45	30	10	0

Le polygone croissant joint donc les points (0 ; 0), (10 ; 5), (20 ; 20), (30 ; 40), (50 ; 50) ; le polygone décroissant joint (0 ; 50), (10 ; 45), (20 ; 30), (30 ; 10), (50 ; 0).



Polygones des effectifs cumulés croissants (bleu) et décroissants (orange). Les deux courbes se coupent à l'abscisse de la médiane ; on peut aussi lire la médiane en cherchant l'abscisse du point du polygone croissant d'ordonnée $N/2 = 25$.

PROPRIÉTÉ Lecture graphique de la médiane et des quartiles

- La **médiane** est l'abscisse du point d'intersection des polygones des effectifs cumulés croissants et décroissants. De façon équivalente, c'est l'abscisse du point du polygone croissant d'ordonnée $\frac{N}{2}$ (ou 50 % sur un polygone de fréquences cumulées).
- Plus généralement (préparation à la Terminale), le **premier quartile** Q_1 se lit à l'ordonnée $\frac{N}{4}$ (soit 25 %) et le **troisième quartile** Q_3 à l'ordonnée $\frac{3N}{4}$ (soit 75 %) sur le polygone croissant.

Ces lectures reposent sur l'hypothèse d'équirépartition des valeurs à l'intérieur de chaque classe : c'est exactement l'hypothèse qui justifie l'interpolation linéaire vue à la section 3.

EXERCICE RÉSOLU 5 Lecture graphique complète

Énoncé. À l'aide des polygones cumulés des ventes de plantains, déterminer graphiquement puis par interpolation : (a) la médiane ; (b) les quartiles Q_1 et Q_3 ; (c) le nombre de jours où le vendeur a vendu moins de 25 kg.

SOLUTION

Solution détaillée. (a) On a $N = 50$, donc $\frac{N}{2} = 25$. Sur le polygone croissant, l'ordonnée 25 est atteinte dans la classe $[20 ; 30[$, entre les points $(20 ; 20)$ et $(30 ; 40)$. Par interpolation linéaire :

$$Me = 20 + \frac{25 - 20}{40 - 20} \times 10 = 20 + 2,5 = 22,5 \text{ kg.}$$

Graphiquement, c'est aussi l'abscisse du point de croisement des deux polygones (pointillés verts sur la figure). (b) $\frac{N}{4} = 12,5$: cette ordonnée est atteinte dans la classe $[10 ; 20[$ entre $(10 ; 5)$ et $(20 ; 20)$:

$$Q_1 = 10 + \frac{12,5 - 5}{20 - 5} \times 10 = 10 + 5 = 15 \text{ kg.}$$

$\frac{3N}{4} = 37,5$: atteinte dans $[20 ; 30[$ entre $(20 ; 20)$ et $(30 ; 40)$:

$$Q_3 = 20 + \frac{37,5 - 20}{40 - 20} \times 10 = 20 + 8,75 = 28,75 \text{ kg.}$$

Ainsi, la moitié centrale des journées correspond à des ventes comprises entre 15 kg et 28,75 kg. (c) Pour $x = 25$, milieu de la classe $[20 ; 30[$, l'interpolation sur le polygone croissant donne :

$$ECC(25) = 20 + \frac{25 - 20}{30 - 20} \times (40 - 20) = 20 + 10 = 30.$$

Le vendeur a vendu moins de 25 kg pendant environ 30 jours sur 50, soit 60 % du temps.

ATTENTION Erreurs fréquentes sur les polygones cumulés

- Mauvaise abscisse : pour le polygone croissant, on place les effectifs cumulés aux bornes supérieures des classes ; pour le décroissant, aux bornes inférieures. Inverser les deux décale toute la courbe.
- Oublier les points d'attache : le polygone croissant doit partir de $(x_0 ; 0)$ et le décroissant de $(x_0 ; N)$. Sans ces points, la lecture graphique de la médiane par intersection est faussée.
- Relier par une courbe arrondie : ce sont des segments de droite (d'où le nom « polygone »), car on suppose la répartition uniforme dans chaque classe.

LESAVAIS-TU ? Des polygones cumulés à la mesure des inégalités

En Terminale, tu rencontreras la **courbe de Lorenz** : on y reporte les fréquences cumulées de la population (par exemple les ménages camerounais rangés du plus pauvre au plus riche) contre les fréquences cumulées du caractère (le revenu). Plus la courbe s'écarte de la diagonale, plus les inégalités sont fortes. On mesure cet écart par l'**indice de Gini**, un nombre compris entre 0 (égalité parfaite) et 1 (inégalité maximale), utilisé par l'Institut National de la Statistique du Cameroun et la Banque mondiale pour comparer les pays. Tout cela n'est qu'une généralisation des polygones de fréquences cumulées que tu viens d'apprendre à tracer !

À RETENIR L'essentiel de la section

- Dans un histogramme, c'est l'aire du rectangle qui représente l'effectif : la hauteur est la densité $d_i = \frac{n_i}{a_i}$. Avec les densités de fréquences, l'aire totale vaut 1.
- Le polygone des effectifs cumulés croissants joint les points (borne supérieure ; ECC) ; le décroissant joint les points (borne inférieure ; ECD).
- La médiane se lit à l'ordonnée $\frac{N}{2}$ sur le polygone croissant, ou à l'intersection des deux polygones ; Q_1 et Q_3 se lisent aux ordonnées $\frac{N}{4}$ et $\frac{3N}{4}$.

6 INTERPRÉTATION ET COMMUNICATION DES RÉSULTATS D'UNE ENQUÊTE

Dans la section précédente, tu as appris à construire un histogramme et les polygones des effectifs cumulés. Mais un tableau ou un graphique, aussi beau soit-il, ne parle pas tout seul : il faut encore le lire, le commenter et le communiquer. C'est toute la différence entre un élève qui « calcule » et un statisticien qui conclut. Dans cette dernière grande étape de la leçon, nous allons apprendre à rédiger un compte-rendu d'enquête complet, à croiser intelligemment la moyenne, la médiane et l'écart-type, à choisir la bonne représentation graphique selon le public visé, et surtout à connaître les **limites** de nos conclusions. C'est exactement le travail que font les instituts de sondage, les journalistes économiques ou les services de planification du MINESEC lorsqu'ils analysent les résultats du Probatoire.

6.1 Rédiger un compte-rendu statistique

Pourquoi rédiger ?

Une enquête statistique n'a de valeur que si elle peut être comprise et vérifiée par d'autres. Imagine que le proviseur de ton lycée te demande d'étudier le temps de trajet domicile-lycée

des élèves pour décider de l'heure d'ouverture des portes. Si tu lui remets simplement un tableau de nombres, il ne pourra rien en faire. Il te faut un **rapport** structuré, qui raconte l'enquête du début à la fin.

MÉTHODE Structure d'un rapport d'enquête statistique

Un bon rapport d'enquête se rédige en cinq parties, toujours dans le même ordre :

1. Introduction : on présente le problème posé et l'objectif de l'enquête (« Pourquoi cette étude ? »).
2. Méthode : on décrit la **population** étudiée (qui? combien?), le **caractère** observé (quoi? avec quelle unité?), et le **mode de collecte** des données (questionnaire, mesure directe, registre, date et lieu de l'enquête).
3. Résultats : on présente les tableaux (effectifs, fréquences, cumuls), les paramètres calculés (moyenne, médiane, écart-type) et les graphiques (histogramme, polygones).
4. Interprétation : on commente les résultats en langage courant, en croisant les indicateurs (voir 6.2).
5. Conclusion : on répond à la question de départ, on propose éventuellement une décision, et on signale honnêtement les limites de l'étude.

ATTENTION Présente toujours la population et le caractère avant tout calcul

Une moyenne de « 25 » ne veut rien dire si l'on ne sait pas qui a été interrogé et quoi on a mesuré. Dans toute copie de Probatoire et dans tout rapport, écris systématiquement une phrase du type : « La population étudiée est l'ensemble des 40 élèves de la classe de Première A du lycée de ... ; le caractère étudié est le temps de trajet domicile-lycée, exprimé en minutes ; les données ont été recueillies par questionnaire le 12 mars. » Oublier cette présentation est une faute de méthode, même si tous les calculs sont justes.

6.2 Analyse conjointe : moyenne, médiane et écart-type

L'intuition.

Un seul indicateur ne suffit jamais à décrire une série. Deux classes peuvent avoir la même moyenne de notes et des réalités totalement différentes : dans l'une, tous les élèves sont autour de 10 ; dans l'autre, la moitié a 4 et l'autre moitié 16. C'est en croisant les trois paramètres que le portrait devient fidèle.

PROPRIÉTÉ Lecture croisée des trois paramètres

Soit une série statistique de moyenne $\bar{x}$, de médiane Me et d'écart-type σ .

- Comparaison moyenne-médiane (forme de la distribution). Si $\bar{x} \approx Me$, la distribution est à peu près **symétrique**. Si $\bar{x} > Me$, la série est **étalée vers les grandes valeurs** (quelques valeurs élevées « tirent » la moyenne vers le haut) : on parle d'asymétrie à droite. Si $\bar{x} < Me$, la série est étalée vers les petites valeurs (asymétrie à gauche).
- Écart-type (concentration). Plus σ est petit devant $\bar{x}$, plus les données sont **concentrées** autour de la moyenne (population homogène). Plus σ est grand, plus les données sont **dispersées** (population hétérogène). En pratique, pour beaucoup de séries « raisonnablement régulières » (unimodales, symétriques, type « cloche »), environ les deux tiers des données se trouvent dans l'intervalle $[\bar{x} - \sigma; \bar{x} + \sigma]$.

ATTENTION La moyenne est sensible aux valeurs extrêmes, pas la médiane

Remplace une seule donnée par une valeur très grande : la moyenne augmente fortement, la médiane ne bouge presque pas. Ainsi, quand une série contient des valeurs exceptionnelles (un très gros salaire, un trajet de 2 heures), la médiane est souvent un meilleur résumé de la « valeur typique » que la moyenne. Dire le contraire, ou comparer deux séries uniquement par leurs moyennes alors que leurs dispersions sont très différentes, est l'erreur d'interprétation la plus fréquente.

EXEMPLE Interprétation complète : les ventes de plantains

Une coopérative du village de Obala a relevé, pendant 20 semaines, la masse hebdomadaire de plantains vendue au marché (en kg). Les calculs des sections précédentes donnent : moyenne $\bar{x} = 45$ kg, médiane $Me = 42$ kg, écart-type $\sigma = 12$ kg. Commentons :

- Position. En moyenne, la coopérative vend 45 kg par semaine ; une semaine sur deux, elle vend moins de 42 kg.
- Forme. On a $\bar{x} = 45 > Me = 42$: la moyenne dépasse la médiane, ce qui signale quelques semaines de très fortes ventes (par exemple pendant les fêtes) qui tirent la moyenne vers le haut. La distribution est légèrement asymétrique vers les grandes valeurs.
- Dispersion. $\sigma = 12$ kg, soit environ 27 % de la moyenne : les ventes sont assez dispersées. L'intervalle $[\bar{x} - \sigma; \bar{x} + \sigma] = [33; 57]$ contient la majorité des semaines : on peut annoncer prudemment que « une semaine ordinaire, la coopérative vend entre 33 et 57 kg ».
- Décision. Pour fixer un stock hebdomadaire de sécurité, viser 45 kg (la moyenne) est risqué la moitié du temps ; viser plutôt $\bar{x} + \sigma = 57$ kg couvre la grande majorité des semaines.

Voilà ce qu'est une interprétation : chaque nombre est traduit en une phrase utile pour agir.

LESAVAIS-TU ?**Pourquoi les journalistes préfèrent la médiane pour les salaires**

Quand un journal annonce « le salaire médian au Cameroun est de ...FCFA » plutôt que le salaire moyen, ce n'est pas un hasard. Quelques très hauts revenus (grands dirigeants, footballeurs professionnels) gonflent énormément la moyenne, qui donnerait une image trop optimiste du niveau de vie. La médiane, elle, n'est pas influencée par ces valeurs extrêmes : elle dit simplement que la moitié des salariés gagne moins, et l'autre moitié plus. Retiens ce réflexe de citoyen : quand on te donne une « moyenne », demande toujours si la médiane ne raconterait pas une autre histoire !

6.3 Choisir la représentation graphique adaptée au public

L'intuition.

Un graphique est un message. La question n'est pas « quel graphique est le plus beau ? » mais « quel graphique fait passer le mieux mon message à ce public ? ».

À RETENIR**Quel graphique pour quel message ?**



- Histogramme : il montre la **forme de la distribution** (où se concentrent les données, y a-t-il des classes dominantes, la répartition est-elle symétrique ?). C'est le graphique à présenter quand le message est : « voici comment la population se répartit ».
- Polygone des effectifs (ou fréquences) cumulés croissants : il répond aux questions de **position** et de **seuil** : « combien d'individus en dessous de telle valeur ? », « quelle est la médiane ? ». C'est le graphique à présenter quand le message est : « voici où se situe la moitié (ou tel pourcentage) de la population ».
- Polygone cumulé décroissant : il répond à la question inverse : « combien d'individus au-dessus de telle valeur ? » (utile pour les seuils de réussite, les dépassements de norme).

Devant un public non mathématicien (conseil d'administration, parents d'élèves), on privilégie l'histogramme, plus intuitif ; devant un jury ou un correcteur, on ajoute le polygone cumulé qui prouve la lecture graphique de la médiane.

EXEMPLE**Mini-rapport visuel : l'enquête « temps de trajet »**

La figure ci-dessous résume l'enquête menée auprès des 40 élèves d'une classe de Première A sur le temps de trajet domicile-lycée (en minutes), regroupés en classes d'amplitude 10. On y voit côte à côte le tableau récapitulatif, l'histogramme (forme de la distribution) et le polygone des effectifs cumulés croissants (lecture de la médiane, voisine de 25 minutes).

Classe (min)	Effectif n_i	Effectif cumulé croissant
[0 ; 10[	4	4
[10 ; 20[	10	14
[20 ; 30[	14	28
[30 ; 40[	8	36
[40 ; 50[	4	40



Mini-rapport visuel de l'enquête « temps de trajet » : tableau récapitulatif, histogramme (distribution concentrée sur [20 ; 30[) et polygone des effectifs cumulés croissants (lecture graphique de la médiane $Me \approx 25$ min).

Lecture du mini-rapport. L'histogramme montre une distribution presque symétrique, dominée par la classe [20 ; 30[: la plupart des élèves mettent entre 20 et 30 minutes. Le polygone cumulé croissant coupe la droite d'ordonnée $N/2 = 20$ en une abscisse voisine de 25 : la moitié des élèves met moins de 25 minutes pour venir au lycée. La moyenne calculée à partir des centres de classes vaut $\bar{x} = 24,5$ min ; la médiane lue graphiquement est voisine de 24,3 min (environ 25 min). Ici $\bar{x} \approx Me$, ce qui confirme la quasi-symétrie observée sur l'histogramme. Tout est cohérent : c'est cela, un rapport bien construit.

6.4 Exemples d'enquêtes élèves et critique des limites

Trois enquêtes à portée de classe.

Le programme recommande de conduire de petites enquêtes réelles. En voici trois, faciles à organiser :

- **Temps de trajet domicile-école** (caractère continu, regroupé en classes de 10 min) : c'est l'exemple traité ci-dessus. Collecte par questionnaire anonyme, en une heure de cours.
- **Nombre de frères et sœurs** (caractère discret, modalités 0, 1, 2, ...) : inutile de faire des classes ; on dresse directement le tableau des effectifs par modalité, et l'on compare moyenne et médiane. Dans beaucoup de classes camerounaises, on observe $\bar{x} > Me$ à cause de quelques familles très nombreuses : belle illustration de l'asymétrie à droite.
- **Hauteur des plants du jardin scolaire** (caractère continu, mesuré à la règle en cm, regroupé en classes de 5 cm) : enquête idéale en lien avec les travaux de SVT ; l'écart-type mesure alors l'homogénéité de la croissance, information utile pour juger de la qualité du semis ou de l'arrosage.

ATTENTION Ne conclus jamais au-delà de ce que tes données permettent

C'est la règle d'or de l'honnêteté statistique. Si tu as interrogé ta classe de 40 élèves, tes conclusions valent pour ta classe, éventuellement pour ton lycée avec prudence, mais certainement pas pour « tous les élèves de Douala » ou « les jeunes du Cameroun ». Trois limites doivent toujours être mentionnées dans la conclusion d'un rapport :

1. Effectif réduit : avec 30 ou 40 données, un seul questionnaire mal rempli peut déformer la moyenne. Plus l'effectif est grand, plus les résultats sont stables.
2. Classes arbitraires : le découpage en classes est un choix de l'enquêteur. Avec des classes de 5 min au lieu de 10 min, l'histogramme aurait une autre allure et la médiane lue graphiquement changerait légèrement.
3. Hypothèse d'uniformité : pour calculer la moyenne d'une série en classes, on remplace chaque classe par son centre, ce qui revient à supposer que les valeurs s'y répartissent uniformément. Ce n'est qu'une approximation : la moyenne obtenue est une valeur approchée de la vraie moyenne des données brutes.

Écrire ces limites dans ta conclusion n'affaiblit pas ton travail : au contraire, c'est la marque d'un esprit scientifique rigoureux, et c'est apprécié par les correcteurs.

EXERCICE RÉSOLU 6 Rédiger la conclusion d'une enquête

Énoncé. Les 36 élèves d'une classe de Première A ont mesuré la hauteur (en cm) de 36 plants de maïs du jardin scolaire, trois semaines après le semis. Les résultats, regroupés en classes d'amplitude 5 cm, donnent : moyenne $\bar{x} = 22$ cm, médiane lue sur le polygone cumulé $Me \approx 21$ cm, écart-type $\sigma = 6$ cm. Rédige la partie « interprétation et conclusion » du rapport d'enquête, en mentionnant les limites de l'étude.

SOLUTION

Solution détaillée. Interprétation. Trois semaines après le semis, les plants mesurent en moyenne 22 cm, et la moitié d'entre eux mesure moins de 21 cm. La moyenne (22 cm) est très proche de la médiane (21 cm) : la distribution des hauteurs est à peu près symétrique, il n'y a pas de groupe de plants anormalement grands ou petits. L'écart-type de 6 cm, soit environ 27 % de la moyenne, indique une dispersion modérée : la majorité des plants a une hauteur comprise entre $\bar{x} - \sigma = 16$ cm et $\bar{x} + \sigma = 28$ cm. La croissance du semis est donc globalement régulière, avec toutefois quelques plants en retard (classe des plus petits) qu'un apport d'eau ou d'engrais ciblé pourrait aider.

Conclusion et limites. Le semis du jardin scolaire présente une croissance homogène et satisfaisante. Cependant, cette conclusion porte sur 36 plants seulement, issus d'une seule parcelle : on ne peut pas la généraliser à toutes les parcelles de la région. De plus, le regroupement en classes de 5 cm et l'utilisation des centres de classes font de la moyenne une valeur approchée ; un autre découpage aurait pu donner des résultats légèrement différents. Une nouvelle mesure dans deux semaines permettra de suivre l'évolution.

EXERCICE 5 À toi de jouer : enquête sur les forfaits téléphoniques

Les 32 élèves d'une classe ont relevé leur dépense mensuelle en forfaits internet (MTN ou Orange), en centaines de FCFA. Les résultats regroupés donnent : $\bar{x} = 25$ (soit 2500 FCFA), $Me = 20$ (soit 2000 FCFA), $\sigma = 14$.

1. Compare la moyenne et la médiane : que révèle leur écart sur la forme de la distribution ?
2. Interprète l'écart-type en langage courant.
3. Rédige en cinq ou six lignes la conclusion du rapport, en précisant la population, le caractère et deux limites de l'étude.

CORRIGÉ Exercice : enquête sur les forfaits téléphoniques

1. On a $\bar{x} = 25 > Me = 20$: la moyenne est nettement supérieure à la médiane. Quelques élèves dépensent beaucoup (gros forfaits) et tirent la moyenne vers le haut : la distribution est asymétrique, étalée vers les grandes valeurs. La moitié des élèves dépense en fait moins de 2000 FCFA par mois.
2. $\sigma = 14$ centaines de FCFA, soit 1400 FCFA, ce qui représente 56 % de la moyenne : la dispersion est forte, les dépenses sont très inégales d'un élève à l'autre. La majorité des dépenses se situe approximativement entre $25 - 14 = 11$ et $25 + 14 = 39$ centaines, soit entre 1100 et 3900 FCFA.

3. Conclusion possible. « La population étudiée est l'ensemble des 32 élèves de la classe ; le caractère est la dépense mensuelle en forfaits internet, en FCFA, recueillie par questionnaire. La dépense moyenne est de 2500 FCFA, mais la médiane de 2000 FCFA montre que cette moyenne est gonflée par quelques gros consommateurs ; la forte dispersion ($\sigma = 1400$ FCFA) traduit de grandes inégalités de dépense. Ces résultats ne concernent que cette classe (effectif réduit de 32 élèves) et ne peuvent être généralisés à tous les lycéens de la ville ; de plus, le regroupement en classes rend la moyenne approximative. »

À RETENIR L'essentiel de la section

- Un rapport d'enquête suit cinq étapes : introduction, méthode (population, caractère, collecte), résultats, interprétation, conclusion.
- On croise toujours les trois paramètres : $\bar{x}$ et Me pour la forme (symétrie si $\bar{x} \approx Me$; asymétrie sinon), σ pour la concentration.
- L'histogramme décrit la distribution ; le polygone cumulé sert à lire la médiane et les seuils.
- Toute conclusion doit citer ses limites : effectif réduit, choix arbitraire des classes, approximation par les centres de classes, et interdiction de généraliser au-delà de la population réellement étudiée.

7 COMPLÉMENTS UTILES POUR LA TERMINALE (OPTIONNEL)

Dans la section précédente, tu as appris à interpréter et à communiquer les résultats d'une enquête : moyenne, médiane, écart-type, histogramme. Ces outils suffisent largement pour le programme de Première A. Mais en Terminale, tu rencontreras des situations plus fines : comparer deux séries qui n'ont pas la même unité, résumer une série entière en un seul dessin, ou encore étudier le lien entre deux caractères à la fois (par exemple le prix et la quantité vendue). Cette section optionnelle te donne une longueur d'avance : les notions qui suivent prolongent naturellement ce que tu sais déjà.

ATTENTION Hors programme de Première A

Les notions de cette section (variance corrigée, quartiles, boîte à moustaches, coefficient de variation, covariance, corrélation) ne sont pas exigibles au Probatoire A. Elles sont présentées ici pour préparer sereinement la transition vers la Terminale et pour enri-

chir ta culture statistique. Aucune n'est à restituer en devoir de Première, sauf demande explicite de ton professeur.

7.1 La variance corrigée : pourquoi diviser par $N - 1$?

Intuition. Jusqu'ici, tu as calculé la variance d'une population entière : les 40 élèves d'une classe, les 50 clients d'une boutique. Mais dans la vraie vie, on ne peut presque jamais interroger toute la population : on ne va pas peser tous les sacs de maïs du Cameroun ! On prélève alors un échantillon (par exemple 30 sacs) et on espère que la variance de l'échantillon donne une bonne idée de la variance de la population totale. Or un échantillon, par hasard, tend à être un peu moins dispersé que la population : les valeurs extrêmes y sont souvent absentes. La variance « classique » de l'échantillon sous-estime donc, en moyenne, la vraie variance. Pour corriger ce défaut, les statisticiens divisent par $N - 1$ au lieu de N .

DÉFINITION Variance corrigée d'un échantillon

Soit un échantillon de N valeurs $x_1, x_2, \dots, x_N$, de moyenne $\bar{x}$. La **variance corrigée** (ou variance d'échantillon, dite non biaisée) est :

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2.$$

L'**écart-type corrigé** est $s = \sqrt{s^2}$. On dit que s^2 est un **estimateur non biaisé** de la variance de la population : en moyenne, sur de nombreux échantillons, il ne surestime ni ne sous-estime la vraie variance.

EXEMPLE Variance classique ou corrigée ?

On relève les masses (en kg) de $N = 5$ sacs d'oignons au marché de Mokolo : 48 ; 50 ; 51 ; 49 ; 52. La moyenne est $\bar{x} = 50$ kg. Les écarts à la moyenne sont -2 ; 0 ; 1 ; -1 ; 2, de carrés 4, 0, 1, 1, 4, de somme 10.

- Variance « population » : $V = \frac{10}{5} = 2$, soit $\sigma = \sqrt{2} \approx 1,41$ kg.
- Variance corrigée : $s^2 = \frac{10}{5-1} = 2,5$, soit $s \approx 1,58$ kg.

Si ces 5 sacs sont un échantillon destiné à estimer la dispersion de toute la récolte, on retient $s^2 = 2,5$.

ATTENTION Quelle variance au Probatoire ?

En Première A, on divise toujours par N (variance de la série étudiée, considérée comme complète). La division par $N - 1$ ne concerne que l'estimation à partir d'un échantillon, notion de Terminale. Ne mélange pas les deux dans un devoir !

7.2 Quartiles, déciles, percentiles et boîte à moustaches

Intuition. La médiane partage une série ordonnée en deux moitiés. Pourquoi s'arrêter là ? En partageant chaque moitié à son tour, on obtient quatre quarts : c'est l'idée des quartiles. Trois nombres (Q_1, Q_2, Q_3) résument alors toute la dispersion, et un dessin très compact — la boîte à moustaches — les visualise d'un coup d'œil.

DÉFINITION Quartiles et écart interquartile

Soit une série statistique ordonnée par valeurs croissantes, d'effectif total N .

- Le **premier quartile** Q_1 est la plus petite valeur de la série telle qu'au moins 25 % des valeurs lui soient inférieures ou égales.
- Le **deuxième quartile** Q_2 n'est autre que la **médiane** Me (au moins 50 % des valeurs).
- Le **troisième quartile** Q_3 est la plus petite valeur telle qu'au moins 75 % des valeurs lui soient inférieures ou égales.

L'**écart interquartile** est $Q_3 - Q_1$: il mesure l'étalement de la « moitié centrale » des données. De même, les **déciles** $D_1, D_2, \dots, D_9$ partagent la série en dix dixièmes, et les **percentiles** en cent centièmes (le 25^e percentile est Q_1 , le 50^e est la médiane).

DÉFINITION Boîte à moustaches

La **boîte à moustaches** (ou box-plot) d'une série est un diagramme formé de :

- un rectangle (la « boîte ») allant de Q_1 à Q_3 , traversé par un trait à la médiane ;
- deux segments (les « moustaches ») allant de la boîte jusqu'au minimum et au maximum de la série (ou jusqu'à des bornes excluant les valeurs aberrantes, selon les conventions).

EXEMPLE Calcul des quartiles


Les ventes quotidiennes de régimes de plantains d'un vendeur du marché Central de

Yaoundé, sur 11 jours (série ordonnée) :

8 ; 10 ; 12 ; 13 ; 15 ; 16 ; 17 ; 19 ; 20 ; 22 ; 25.

- Médiane : 6^e valeur, $Q_2 = Me = 16$.
- Q_1 : médiane de la première moitié {8, 10, 12, 13, 15}, soit $Q_1 = 12$.
- Q_3 : médiane de la seconde moitié {17, 19, 20, 22, 25}, soit $Q_3 = 20$.
- Écart interquartile : $Q_3 - Q_1 = 20 - 12 = 8$ régimes.

La moitié centrale des journées voit des ventes comprises entre 12 et 20 régimes.



Boîte à moustaches superposée à l'histogramme des ventes quotidiennes de plantains : la boîte concentre 50 % des journées, entre $Q_1 = 12$ et $Q_3 = 20$ régimes.

LESAVAIS-TU ? John Tukey et l'analyse exploratoire

La boîte à moustaches a été popularisée en 1970 par le statisticien américain John Tukey, pionnier de « l'analyse exploratoire des données ». Son idée : avant tout calcul savant, un bon dessin doit permettre de voir la médiane, la dispersion et les valeurs extrêmes en une seconde. Tukey est aussi l'inventeur du mot « bit » et un père de la transformée de Fourier rapide, utilisée aujourd'hui dans tous les téléphones portables... y compris ceux des réseaux MTN et Orange !

ATTENTION Conventions variables

Selon les manuels et les logiciels, Q_1 et Q_3 peuvent être définis par des méthodes légèrement différentes (rang $\frac{N}{4}$, médiane des moitiés, interpolation). Les valeurs obtenues peuvent différer d'un cran pour les petites séries : ce n'est pas une erreur, mais une différence de convention. En Terminale, applique la convention de ton professeur et annonce-la clairement.

7.3 Le coefficient de variation : comparer des dispersions d'échelles différentes

Intuition. Un grossiste de Douala vend du riz (prix moyen $\bar{x}_1 = 350$ FCFA le kg, écart-type $\sigma_1 = 20$ FCFA) et des sacs de ciment (prix moyen $\bar{x}_2 = 5\,500$ FCFA, écart-type $\sigma_2 = 200$ FCFA). Quel produit a les prix les plus dispersés ? Comparer 20 et 200 FCFA n'a pas de sens : les ordres de grandeur sont différents. Il faut relativiser l'écart-type par la moyenne.

DÉFINITION Coefficient de variation

Le **coefficient de variation** d'une série de moyenne $\bar{x} \neq 0$ et d'écart-type σ est :

$$CV = \frac{\sigma}{\bar{x}}, \quad \text{souvent exprimé en pourcentage : } CV = \frac{\sigma}{\bar{x}} \times 100 \, \%.$$

PROPRIÉTÉ Dispersion relative

Le coefficient de variation est un nombre sans unité : il ne dépend ni de l'unité de mesure, ni de l'ordre de grandeur de la série. Il permet donc de comparer la dispersion relative de séries d'échelles ou de natures différentes : plus CV est grand, plus la série est dispersée relativement à sa moyenne. (Non exigible au Probatoire A.)

EXEMPLE Riz ou ciment : lequel fluctue le plus ?

Avec les données du grossiste :

$$CV_{\text{riz}} = \frac{20}{350} \approx 0,057 = 5,7 \, \% \quad ; \quad CV_{\text{ciment}} = \frac{200}{5\,500} \approx 0,036 = 3,6 \, \%.$$

Conclusion : bien que l'écart-type du ciment soit dix fois plus grand, c'est le prix du riz qui est relativement le plus instable ($5,7 \, \% > 3,6 \, \%$).

ATTENTION Moyenne nulle ou négative

Le coefficient de variation n'a de sens que si $\bar{x} > 0$. Pour une série de moyenne nulle (écarts de température, gains et pertes) ou négative, le quotient $\sigma/\bar{x}$ est infini ou absurde : on ne l'utilise pas.

7.4 Covariance et corrélation linéaire : étudier deux caractères à la fois

Intuition. Jusqu'ici, chaque individu était décrit par un seul caractère. Mais souvent, on en observe deux simultanément : les heures de révision x et la note au Probatoire blanc y de chaque élève. Question naturelle : quand x augmente, y a-t-il tendance à augmenter aussi ? La cova-

riance mesure cette « tendance à varier ensemble ».

DÉFINITION Covariance

Pour une série double (x_i, y_i) , $1 \leq i \leq N$, de moyennes $\bar{x}$ et $\bar{y}$, la **covariance** est :

$$\text{Cov}(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x} \bar{y}.$$

Si $\text{Cov}(x, y) > 0$, les deux caractères ont tendance à varier dans le même sens ; si $\text{Cov}(x, y) < 0$, en sens contraires.

La covariance dépend des unités : pour obtenir une mesure universelle, on la normalise par les écarts-types.

DÉFINITION Coefficient de corrélation linéaire

Le **coefficient de corrélation linéaire** de x et y est :

$$r = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}, \quad \text{et l'on a toujours } -1 \leq r \leq 1.$$

- r proche de 1 : forte dépendance croissante (les points du nuage s'alignent sur une droite montante) ;
- r proche de -1 : forte dépendance décroissante ;
- r proche de 0 : absence de relation linéaire entre x et y .

EXERCICE RÉSOLU 7 Révisions et notes au Probatoire blanc

Pour 5 élèves d'une classe de Première A à Bafoussam, on note x les heures de révision hebdomadaires et y la note sur 20 :

Élève	1	2	3	4	5
x_i (heures)	2	4	6	8	10
y_i (note)	8	10	11	14	17

Calculer le coefficient de corrélation linéaire et commenter.

SOLUTION

Étape 1 : moyennes. $\bar{x} = \frac{2 + 4 + 6 + 8 + 10}{5} = 6$ et $\bar{y} = \frac{8 + 10 + 11 + 14 + 17}{5} = 12$.

Étape 2 : covariance. On calcule les produits $x_i y_i$: 16 ; 40 ; 66 ; 112 ; 170, de somme 404.

Donc :

$$\text{Cov}(x,y) = \frac{404}{5} - 6 \times 12 = 80,8 - 72 = 8,8.$$

Étape 3 : écarts-types.

$$\sigma_x^2 = \frac{4^2 + 2^2 + 0^2 + 2^2 + 4^2}{5} = \frac{16 + 4 + 0 + 4 + 16}{5} = 8, \quad \sigma_x = \sqrt{8} \approx 2,83;$$

$$\sigma_y^2 = \frac{(-4)^2 + (-2)^2 + (-1)^2 + 2^2 + 5^2}{5} = \frac{16 + 4 + 1 + 4 + 25}{5} = 10, \quad \sigma_y = \sqrt{10} \approx 3,16.$$

Étape 4 : corrélation.

$$r = \frac{8,8}{\sqrt{8} \times \sqrt{10}} = \frac{8,8}{\sqrt{80}} \approx \frac{8,8}{8,94} \approx 0,98.$$

Interprétation : $r \approx 0,98$ est très proche de 1 : il existe une forte relation croissante entre le temps de révision et la note. Les points (x_i, y_i) sont presque alignés sur une droite montante. En Terminale, tu apprendras à tracer cette droite, appelée droite d'ajustement ou droite de régression.

ATTENTION Corrélation n'est pas causalité

Un coefficient r proche de 1 ne prouve pas que x provoque y ! Si les ventes de moustiquaires et celles de ventilateurs sont corrélées, c'est sans doute la saison sèche qui agit sur les deux. De même, $r \approx 0$ n'exclut pas une relation non linéaire (par exemple en arc de parabole). Retiens : la corrélation mesure uniquement la force d'une relation linéaire.

À RETENIR Ce qu'il faut retenir de cette ouverture

- Variance corrigée d'un échantillon : $s^2 = \frac{1}{N-1} \sum (x_i - \bar{x})^2$ (division par $N-1$).
- Quartiles $Q_1, Q_2 = Me, Q_3$; écart interquartile $Q_3 - Q_1$; la boîte à moustaches résume min, Q_1, Me, Q_3 , max en un seul dessin.
- Coefficient de variation $CV = \frac{\sigma}{\bar{x}}$: sans unité, il compare les dispersions relatives.
- Covariance $\text{Cov}(x,y) = \frac{1}{N} \sum x_i y_i - \bar{x} \bar{y}$ et corrélation $r = \frac{\text{Cov}(x,y)}{\sigma_x \sigma_y} \in [-1; 1]$.

Ces quatre outils seront tes compagnons de Terminale : les avoir rencontrés dès maintenant, c'est déjà les avoir à moitié compris.

EXERCICE 6 Pour aller plus loin

Une coopérative de café de l'Ouest prélève 6 sacs : masses (kg) 60 ; 62 ; 58 ; 61 ; 59 ; 60.

1. Calculer la moyenne, puis la variance corrigée s^2 et l'écart-type corrigé s .
2. Déterminer Q_1 , Me , Q_3 et l'écart interquartile.
3. Une autre coopérative a $\bar{x}' = 60$ kg et $\sigma' = 3$ kg. Comparer les dispersions relatives à l'aide du coefficient de variation.

CORRIGÉ Exercice : coopérative de café

1. $\bar{x} = \frac{60 + 62 + 58 + 61 + 59 + 60}{6} = \frac{360}{6} = 60$ kg. Les écarts sont 0, 2, -2, 1, -1, 0, de carrés 0, 4, 4, 1, 1, 0, de somme 10. Variance corrigée : $s^2 = \frac{10}{6-1} = 2$, d'où $s = \sqrt{2} \approx 1,41$ kg.
2. Série ordonnée : 58 ; 59 ; 60 ; 60 ; 61 ; 62. Médiane : $Me = \frac{60 + 60}{2} = 60$ kg. Première moitié {58, 59, 60} : $Q_1 = 59$ kg. Seconde moitié {60, 61, 62} : $Q_3 = 61$ kg. Écart interquartile : $Q_3 - Q_1 = 2$ kg.
3. Première coopérative : $CV = \frac{1,41}{60} \approx 2,4\%$. Seconde : $CV' = \frac{3}{60} = 5\%$. La seconde coopérative a des masses relativement plus dispersées : le remplissage de la première est plus régulier.

8 ACTIVITÉ D'INTÉGRATION

9 ACTIVITÉ D'INTÉGRATION : ENQUÊTE STATISTIQUE SUR LES TEMPS DE TRAJET DOMICILE-LYCÉE

9.1 Objectifs de l'activité

À l'issue de cette activité d'intégration, tu seras capable de mobiliser simultanément l'ensemble des savoir-faire de la leçon dans une situation authentique d'enquête statistique. Concrètement, tu devras :

- organiser une collecte de données réelles et regrouper une série brute en **classes d'égales amplitudes** ;
- construire un tableau complet des effectifs, des fréquences et des **effectifs cumulés croissants et décroissants** ;
- calculer la **moyenne**, la **médiane**, la **variance** et l'**écart-type** d'une série regroupée en classes ;
- construire un **histogramme** et les deux **polygones des effectifs cumulés** ;
- rédiger un rapport court interprétant les paramètres obtenus et le présenter oralement.

Cette activité reproduit exactement la démarche d'un statisticien : collecter, organiser, calculer, représenter, interpréter, communiquer.

9.2 Situation

Le proviseur du lycée bilingue de Nkongsamba s'inquiète des retards répétés constatés lors du premier cours de la journée. Le conseil d'administration envisage d'ajuster l'heure de début des cours, actuellement fixée à 7 h 30. Avant toute décision, le proviseur mandate la classe de Première A pour mener une enquête statistique sur le **temps de trajet domicile-lycée** des élèves (marche à pied, moto-taxi « benskin », taxi collectif ou car).

Chaque élève de la classe a noté anonymement, sur une fiche, la durée en minutes de son trajet le matin même. Voici les 30 données brutes recueillies (en minutes) :

5	8	12	15	18	20	22	25	25	27
28	30	32	35	38	40	42	45	10	14
16	22	24	26	28	33	36	44	48	20

Le proviseur pose trois questions à la classe :

- Quel est le temps de trajet moyen d'un élève du lycée ?
- À partir de quelle durée peut-on dire qu'un élève sur deux met plus de temps que les autres ?

3. Les temps de trajet sont-ils homogènes (regroupés autour de la moyenne) ou très dispersés? Cela justifie-t-il de décaler l'heure des cours?

9.3 Consignes

Partie A : Organisation des données

1. Justifier que le caractère étudié est quantitatif continu et proposer un regroupement en 5 classes d'amplitude 10, en commençant par $[0 ; 10[$.
2. Construire le tableau statistique complet : classes, centres c_i , effectifs n_i , fréquences f_i , effectifs cumulés croissants (ECC) et effectifs cumulés décroissants (ECD).

Partie B : Caractéristiques de position et de dispersion

3. Calculer la moyenne $\bar{x}$ de la série à l'aide des centres de classes.
4. Déterminer la classe médiane, puis calculer une valeur approchée de la médiane M_e par interpolation linéaire.
5. Calculer la variance V puis l'écart-type σ de la série.
6. Comparer la moyenne et la médiane. Que peut-on en déduire sur la forme de la distribution?

Partie C : Représentations graphiques

7. Construire l'histogramme des effectifs (sur papier millimétré : 1 cm pour 10 min en abscisse, 1 cm pour 2 élèves en ordonnée).
8. Construire, sur un même graphique, le polygone des ECC et le polygone des ECD. Retrouver graphiquement une valeur approchée de la médiane.

Partie D : Interprétation et communication

9. En groupes de quatre, rédiger un rapport d'une page répondant aux trois questions du professeur, en citant tous les paramètres calculés.
10. Chaque groupe présente ses conclusions en 3 minutes, puis la classe vote une recommandation argumentée (maintenir ou décaler l'heure de 7 h 30).

9.4 Ressources à mobiliser

À RETENIR**Boîte à outils de la leçon**

- Centre d'une classe $[a ; b[: c_i = \frac{a+b}{2}$.

- Moyenne (série en classes) : $\bar{x} = \frac{\sum n_i c_i}{N}$.
- Variance : $V = \frac{\sum n_i (c_i - \bar{x})^2}{N} = \frac{\sum n_i c_i^2}{N} - \bar{x}^2$ (formule de König-Huygens); écart-type : $\sigma = \sqrt{V}$.
- Médiane : valeur qui partage la série en deux effectifs égaux; pour une série en classes, on repère la classe médiane avec les ECC puis on interpole linéairement.
- Polygones cumulés : le polygone des ECC joint les points $(b_i; ECC_i)$ où b_i est la borne supérieure; le polygone des ECD joint les points $(a_i; ECD_i)$ où a_i est la borne inférieure; l'abscisse du point d'intersection des deux polygones approche la médiane.

MÉTHODE**Calcul de la médiane par interpolation linéaire (série en classes)**

1. Calculer $N/2$.
2. Repérer dans la colonne des ECC la première valeur $\geq N/2$; la classe correspondante est la **classe médiane** $[a; b[$.
3. Noter F_{av} l'ECC de la classe précédente (effectif cumulé avant la classe médiane) et n_{med} l'effectif de la classe médiane.
4. Appliquer la formule : $M_e = a + \frac{b - a}{n_{med}} \left(\frac{N}{2} - F_{av} \right)$.

9.5 Démarche et corrigé commenté**EXERCICE RÉSOLU 8****Enquête « Temps de trajet domicile–lycée » : corrigé complet**

Répondre à l'ensemble des consignes des parties A, B, C et D.

SOLUTION

Partie A. Organisation des données.

1. Le temps de trajet peut prendre n'importe quelle valeur réelle dans un intervalle (on peut mesurer 12,3 min, 12,34 min, etc.) : c'est un caractère **quantitatif continu**. L'étendue vaut $48 - 5 = 43$ minutes; un regroupement en 5 classes d'amplitude 10 est donc adapté : $[0; 10[$, $[10; 20[$, $[20; 30[$, $[30; 40[$, $[40; 50[$.

2. En dépouillant les 30 fiches (chaque valeur est rangée dans sa classe, la borne inférieure étant incluse), on obtient :

Classe	Centre c_i	n_i	f_i	ECC	ECD
[0 ; 10[	5	2	0,067	2	30
[10 ; 20[	15	6	0,200	8	28
[20 ; 30[	25	11	0,367	19	22
[30 ; 40[	35	6	0,200	25	11
[40 ; 50]	45	5	0,167	30	5
Total		30	1		

Vérification indispensable : la somme des effectifs vaut bien $N = 30$ et la somme des fréquences vaut 1 (aux arrondis près).

Partie B. Position et dispersion.

3. Moyenne :

$$\bar{x} = \frac{2 \times 5 + 6 \times 15 + 11 \times 25 + 6 \times 35 + 5 \times 45}{30} = \frac{10 + 90 + 275 + 210 + 225}{30} = \frac{810}{30} = 27.$$

Le temps de trajet moyen est donc de $\bar{x} = 27$ minutes.

4. On a $\frac{N}{2} = 15$. Dans la colonne des ECC, 15 se situe entre 8 et 19 : la **classe médiane** est donc [20 ; 30[. Par interpolation linéaire (formule de la méthode) :

$$M_e = 20 + 10 \times \frac{15 - 8}{19 - 8} = 20 + \frac{70}{11} \approx 26,4 \text{ min.}$$

Environ la moitié des élèves met moins de 26,4 minutes, l'autre moitié davantage.

5. Variance, avec les écarts au carré (on peut aussi utiliser la formule de König-Huygens) :


$$\begin{aligned} v &= \frac{2(5 - 27)^2 + 6(15 - 27)^2 + 11(25 - 27)^2 + 6(35 - 27)^2 + 5(45 - 27)^2}{30} \\ &= \frac{2 \times 484 + 6 \times 144 + 11 \times 4 + 6 \times 64 + 5 \times 324}{30} \\ &= \frac{968 + 864 + 44 + 384 + 1620}{30} = \frac{3880}{30} \approx 129,3. \end{aligned}$$

D'où $\sigma = \sqrt{129,3} \approx 11,4$ minutes.

6. On observe $M_e \approx 26,4 < \bar{x} = 27$: la moyenne, sensible aux valeurs élevées (élèves venant des quartiers éloignés), est légèrement supérieure à la médiane. La distribution est donc légèrement étirée vers les longs trajets (asymétrie positive). L'écart-type de 11,4 min, soit environ 42 % de la moyenne, traduit une dispersion notable.


Partie C. Représentations graphiques.

7. Histogramme des effectifs :



Histogramme des effectifs : la classe modale $[20 ; 30[$ concentre 11 élèves.

8. Polygones cumulés : le polygone des ECC joint les points $(0 ; 0)$, $(10 ; 2)$, $(20 ; 8)$, $(30 ; 19)$, $(40 ; 25)$, $(50 ; 30)$; le polygone des ECD joint $(0 ; 30)$, $(10 ; 28)$, $(20 ; 22)$, $(30 ; 11)$, $(40 ; 5)$, $(50 ; 0)$.



Les deux polygones se coupent au point d'abscisse $M_e \approx 26,4$ min : on retrouve graphiquement la médiane calculée.

Le point d'intersection des deux polygones a pour ordonnée $15 = \frac{N}{2}$ et pour abscisse environ 26,4 : la lecture graphique confirme le calcul par interpolation.

Partie D. Interprétation et communication (éléments attendus pour le rapport).

Le rapport doit contenir : le tableau statistique, les paramètres ($\bar{x} = 27$ min ; $M_e \approx 26,4$ min ; $\sigma \approx 11,4$ min), les graphiques, et une conclusion argumentée. Exemple de réponse aux questions du proviseur :

- Temps moyen : Un élève met en moyenne 27 minutes pour venir au lycée.
- Médiane : Un élève sur deux met plus de 26,4 minutes (la médiane).
- Dispersion : L'écart-type $\sigma \approx 11,4$ min montre une forte hétérogénéité. L'intervalle $[\bar{x} - \sigma ; \bar{x} + \sigma] = [15,6 ; 38,4]$ contient, d'après les données brutes, 19 élèves sur 30 (soit 63 %), confirmant une dispersion importante. Les extrêmes vont de 5 min (marche à pied, quartier proche) à 48 min (benskin depuis la périphérie).
- Recommandation argumentée : Décaler le début des cours à 7 h 45 ne résoudrait pas le problème des élèves les plus éloignés (ils arriveraient encore en retard). Mieux vaut négocier avec le transporteur local (CAMTEL/SOTUC) un circuit de ramassage scolaire desservant les quartiers situés à plus de 40 minutes, ou tolérer un accueil progressif entre 7 h 30 et 8 h.

ATTENTION Pièges fréquents dans ce type d'enquête

- Ne confonds pas borne de classe et centre de classe : tous les calculs (moyenne, variance) utilisent les centres c_i .
- Pour la médiane, n'oublie pas l'interpolation linéaire : répondre « la médiane est dans $[20 ; 30[$ » est insuffisant au Probatoire.
- Dans le polygone des ECC, on place les effectifs cumulés aux bornes supérieures des classes ; aux bornes inférieures pour les ECD.
- Vérifie toujours que $\sum n_i = N$ avant tout calcul : une erreur de dépouillement fausse toute la suite.
- Pour l'intervalle $[\bar{x} - \sigma ; \bar{x} + \sigma]$, ne compte pas les effectifs de classes entières si les bornes coupent des classes ; utilise les données brutes ou une interpolation.

LESAVAIS-TU ? La règle empirique (loi 68–95–99,7)

Pour une distribution proche de la loi normale (en forme de cloche symétrique), on sait que :

- environ 68 % des données sont dans $[\bar{x} - \sigma ; \bar{x} + \sigma]$,
- environ 95 % dans $[\bar{x} - 2\sigma ; \bar{x} + 2\sigma]$,
- environ 99,7 % dans $[\bar{x} - 3\sigma ; \bar{x} + 3\sigma]$.

Ici, la distribution est asymétrique (queue à droite), donc la règle n'est pas exacte : on

trouve 63 % au lieu de 68 %. Cela rappelle qu'il faut toujours regarder la forme de l'histogramme avant d'appliquer une règle théorique.

9.6 Bilan de l'activité

Cette enquête a permis de mettre en évidence plusieurs idées essentielles de la leçon :

- **La statistique est une démarche complète** : aucun paramètre n'a de sens sans une collecte soigneuse et un regroupement judicieux des données en classes d'égales amplitudes.
- **Moyenne et médiane se complètent** : ici, $\bar{x} = 27$ et $M_e \approx 26,4$ sont proches, mais leur comparaison révèle l'étirement de la distribution vers les longs trajets, information invisible si l'on ne calcule qu'un seul paramètre.
- **L'écart-type mesure l'homogénéité** : $\sigma \approx 11,4$ min montre que le « trajet moyen » ne décrit fidèlement personne ; les écarts individuels sont importants.
- **Les graphiques confirment les calculs** : l'histogramme visualise la classe modale, et l'intersection des polygones cumulés redonne la médiane sans nouveau calcul.
- **Les mathématiques éclairent la décision** : la recommandation finale au proviseur s'appuie sur des nombres, pas sur des impressions — c'est le cœur du savoir-être statistique : argumenter avec rigueur, honnêteté et esprit critique.

Tu es désormais prêt à mener ta propre mini-enquête (notes à un devoir, dépenses hebdomadaires en crédit téléphonique MTN/Orange, distances parcourues) et à en communiquer les résultats comme un véritable statisticien.

10 MÉTHODES ET EXERCICES RÉSOLUS

11 STATISTIQUES : ORGANISATION ET GESTION DES DONNÉES

11.1 Regrouper une population en classes d'égales amplitudes

MÉTHODE Regrouper des données en classes d'égales amplitudes

Pour regrouper une série de N données continues (ou discrètes nombreuses) en classes d'égales amplitudes :

1. Repérer la valeur minimale $x_{\min}$ et la valeur maximale $x_{\max}$, puis calculer l'**étendue** $e = x_{\max} - x_{\min}$.
2. Choisir le nombre de classes k (souvent imposé par l'énoncé ; sinon entre 5 et 8).
3. Calculer l'**amplitude** commune $a \approx \frac{e}{k}$, en l'arrondissant à une valeur simple (multiple de 5, 10, etc.).
4. Écrire les classes sous la forme $[b_i ; b_{i+1}[$: borne inférieure incluse, borne supérieure exclue (sauf éventuellement la dernière classe, fermée des deux côtés $[b_k ; b_{k+1}]$).
5. Compter l'effectif n_i de chaque classe en dépouillant les données une par une, puis vérifier que $\sum n_i = N$.
6. Compléter le tableau avec le centre de classe $c_i = \frac{b_i + b_{i+1}}{2}$, les fréquences $f_i = \frac{n_i}{N}$, les effectifs cumulés croissants (E.C.C.) et décroissants (E.C.D.), ainsi que les fréquences cumulées croissantes (F.C.C.) et décroissantes (F.C.D.).

EXERCICE RÉSOLU 9 Regroupement en classes et tableaux cumulés

Un grossiste de Mokolo a relevé les masses (en kg) de 40 sacs d'arachide :

42 ; 45 ; 47 ; 50 ; 52 ; 53 ; 55 ; 55 ; 56 ; 57 ; 58 ; 58 ; 59 ; 60 ; 60 ; 61 ; 61 ; 62 ; 62 ; 63

63 ; 64 ; 64 ; 65 ; 65 ; 66 ; 66 ; 67 ; 68 ; 68 ; 69 ; 70 ; 70 ; 71 ; 72 ; 73 ; 74 ; 75 ; 76 ; 78

Regrouper ces données en classes d'amplitude 8 en partant de 40, et dresser le tableau complet des effectifs, fréquences, effectifs et fréquences cumulés croissants et décroissants.

SOLUTION

Étape 1 : étendue. $x_{\min} = 42$, $x_{\max} = 78$, donc $e = 78 - 42 = 36$.

Étape 2 : classes d'amplitude 8 à partir de 40.

[40; 48[; [48; 56[; [56; 64[; [64; 72[; [72; 80]

Étape 3 : dépouillement. On compte les données dans chaque classe :

- [40; 48[: 42, 45, 47 $\Rightarrow n_1 = 3$;
- [48; 56[: 50, 52, 53, 55, 55 $\Rightarrow n_2 = 5$;
- [56; 64[: 56, 57, 58, 58, 59, 60, 60, 61, 61, 62, 62, 63, 63 $\Rightarrow n_3 = 13$;
- [64; 72[: 64, 64, 65, 65, 66, 66, 67, 68, 68, 69, 70, 70, 71 $\Rightarrow n_4 = 13$;
- [72; 80] : 72, 73, 74, 75, 76, 78 $\Rightarrow n_5 = 6$.

Vérification : $3 + 5 + 13 + 13 + 6 = 40 = N$. ✓

Étape 4 : tableau complet.

Classe	[40; 48[	[48; 56[	[56; 64[	[64; 72[	[72; 80]
Centre c_i	44	52	60	68	76
Effectif n_i	3	5	13	13	6
Fréquence f_i	0,075	0,125	0,325	0,325	0,15
E.C.C.	3	8	21	34	40
E.C.D.	40	37	32	19	6
F.C.C.	0,075	0,20	0,525	0,85	1
F.C.D.	1	0,925	0,80	0,475	0,15

Les fréquences sont calculées par $f_i = \frac{n_i}{40}$: par exemple $f_3 = \frac{13}{40} = 0,325$. On vérifie que la somme des fréquences vaut 1, que le dernier E.C.C. vaut $N = 40$, que le premier E.C.D. vaut $N = 40$, et que la dernière F.C.C. vaut 1 (ou 100 %).

11.2 Caractéristique de position : la moyenne

MÉTHODE Calculer une moyenne

1. Série à modalités simples (valeurs x_i d'effectifs n_i) :

$$\bar{x} = \frac{\sum_i n_i x_i}{N} = \frac{n_1 x_1 + n_2 x_2 + \dots + n_p x_p}{N}.$$

2. Série regroupée en classes : on remplace chaque classe par son **centre** c_i (valeur ap-

prochée) :

$$\bar{x} \approx \frac{\sum_i n_i c_i}{N}.$$

3. Construire une colonne $n_i x_i$ (ou $n_i c_i$) dans le tableau, faire la somme, puis diviser par N .
4. Conclure par une phrase avec l'unité et une valeur arrondie cohérente avec les données (généralement au dixième ou centième près).

Réflexe contrôle : la moyenne doit se situer entre la plus petite et la plus grande valeur de la série (ou entre les bornes extrêmes des classes).

EXERCICE RÉSOLU 10
Moyenne d'une série regroupée en classes

On reprend la répartition des 40 sacs d'arachide de l'exercice précédent. Calculer la masse moyenne d'un sac.

SOLUTION

On utilise les centres de classes et on ajoute une colonne $n_i c_i$:

Classe	Centre c_i	n_i	$n_i c_i$
[40; 48[	44	3	132
[48; 56[	52	5	260
[56; 64[	60	13	780
[64; 72[	68	13	884
[72; 80]	76	6	456
Total		40	2512

La masse moyenne est donc :

$$\bar{x} = \frac{2512}{40} = 62,8.$$

Contrôle : $62,8 \in [42; 78]$, le résultat est plausible. ✓

Conclusion : la masse moyenne d'un sac d'arachide est d'environ 62,8 kg.

11.3 Caractéristique de position : la médiane

MÉTHODE
Déterminer la médiane

1. Série discrète : ranger les N valeurs dans l'ordre croissant.

- Si N est impair, Me est la valeur de rang $\frac{N+1}{2}$.
 - Si N est pair, Me est la demi-somme des valeurs de rangs $\frac{N}{2}$ et $\frac{N}{2} + 1$.
2. Série en classes : repérer la **classe médiane**, première classe dont l'effectif cumulé croissant atteint ou dépasse $\frac{N}{2}$, puis appliquer l'**interpolation linéaire** (formule exigible au Probatoire) :

$$Me = b_i + a \times \frac{\frac{N}{2} - N_{i-1}}{n_i},$$

où b_i est la borne inférieure de la classe médiane, a son amplitude, N_{i-1} l'effectif cumulé croissant de la classe précédente et n_i l'effectif de la classe médiane.

3. Graphiquement : la médiane est l'abscisse du point du polygone des effectifs cumulés croissants d'ordonnée $\frac{N}{2}$. C'est aussi l'abscisse du point d'intersection des polygones des effectifs cumulés croissants et décroissants.

EXERCICE RÉSOLU 11 Médiane par interpolation linéaire

On reprend la série des 40 sacs d'arachide. Déterminer la médiane par interpolation linéaire, puis interpréter le résultat.

SOLUTION

Étape 1 : position de la médiane. $N = 40$, donc $\frac{N}{2} = 20$. On cherche la première classe dont l'E.C.C. atteint 20.

Étape 2 : classe médiane. D'après le tableau des E.C.C. : 3, 8, 21, 34, 40. Le premier E.C.C. supérieur ou égal à 20 est 21 : la classe médiane est [56; 64[.

Étape 3 : interpolation linéaire. Ici $b_i = 56$, $a = 8$, $N_{i-1} = 8$, $n_i = 13$:

$$Me = 56 + 8 \times \frac{20 - 8}{13} = 56 + 8 \times \frac{12}{13} = 56 + \frac{96}{13} \approx 56 + 7,3846 \approx 63,4.$$

Conclusion : la médiane vaut environ 63,4 kg. Cela signifie qu'environ la moitié des sacs pèse moins de 63,4 kg et l'autre moitié plus de 63,4 kg.

11.4 Caractéristiques de dispersion : variance et écart-type

MÉTHODE Calculer variance et écart-type

1. Calculer d'abord la moyenne $\bar{x}$.

2. Formule de définition (utile pour comprendre le sens) :

$$V = \frac{1}{N} \sum_i n_i (x_i - \bar{x})^2 \quad \text{puis} \quad \sigma = \sqrt{V}.$$

3. Formule de König-Huygens (souvent plus rapide, moins de risques d'erreurs) :

$$V = \frac{1}{N} \sum_i n_i x_i^2 - \bar{x}^2.$$

4. Pour une série en classes, remplacer x_i par le centre c_i (valeurs approchées).

5. Ajouter les colonnes $n_i x_i^2$ (ou $n_i (x_i - \bar{x})^2$) au tableau pour organiser les calculs.

6. Conclure : σ s'exprime dans la même unité que les données ; plus σ est grand, plus la série est dispersée autour de sa moyenne.

EXERCICE RÉSOLU 12

Variance et écart-type

Les notes de mathématiques de 5 élèves de Première A au premier devoir sont : 8 ; 10 ; 11 ; 14 ; 17. Calculer la moyenne, la variance et l'écart-type de cette série. Interpréter.

SOLUTION

Étape 1 : moyenne.

$$\bar{x} = \frac{8 + 10 + 11 + 14 + 17}{5} = \frac{60}{5} = 12.$$

Étape 2 : variance par la définition. On calcule les écarts à la moyenne :

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
8	-4	16
10	-2	4
11	-1	1
14	2	4
17	5	25
Total	0	50

$$V = \frac{50}{5} = 10.$$

Vérification par König-Huygens : $\sum x_i^2 = 64 + 100 + 121 + 196 + 289 = 770$, donc

$$V = \frac{770}{5} - 12^2 = 154 - 144 = 10. \checkmark$$

Étape 3 : écart-type.

$$\sigma = \sqrt{10} \approx 3,16.$$

Conclusion : la moyenne de la classe est 12 et l'écart-type vaut environ 3,2 points : les notes sont assez dispersées autour de la moyenne (de 8 à 17).

11.5 Représentations graphiques : histogramme et polygones des effectifs cumulés

MÉTHODE Histogramme et polygones cumulés

Histogramme (classes d'égales amplitudes) :

1. En abscisse : les bornes des classes, à échelle régulière ; en ordonnée : les effectifs (ou fréquences).
2. Tracer des rectangles juxtaposés (sans espace) dont la base est l'amplitude de la classe et la hauteur l'effectif n_i (ou la fréquence f_i).
3. Attention : si les classes n'ont pas la même amplitude, la hauteur du rectangle est la **densité** $d_i = \frac{n_i}{a_i}$ (effectif divisé par amplitude) ; l'aire du rectangle est alors proportionnelle à l'effectif.

Polygone des effectifs cumulés croissants :

1. Placer les points de coordonnées (borne supérieure de la classe ; E.C.C.), en ajoutant le point de départ ($b_0 ; 0$) où b_0 est la borne inférieure de la première classe.
2. Relier les points par des segments de droite.
3. Pour la médiane graphique : tracer la droite horizontale d'ordonnée $\frac{N}{2}$, lire l'abscisse du point d'intersection avec le polygone.

Polygone des effectifs cumulés décroissants :

1. Placer les points de coordonnées (borne inférieure de la classe ; E.C.D.), en ajoutant le point final ($b_{k+1} ; 0$) où b_{k+1} est la borne supérieure de la dernière classe.
2. Relier les points par des segments de droite.


Propriété : les deux polygones (croissant et décroissant) se coupent en un point d'abscisse égale à la médiane.

EXERCICE RÉSOLU 13 Histogramme et lecture graphique de la médiane

On reprend la série des 40 sacs d'arachide. Construire l'histogramme des effectifs et le polygone des effectifs cumulés croissants, puis retrouver graphiquement la médiane.


SOLUTION

Histogramme : on trace un rectangle par classe, de hauteur égale à l'effectif.



Histogramme des effectifs de la répartition des masses des 40 sacs.

Polygone des E.C.C. : on place les points (40; 0), (48; 3), (56; 8), (64; 21), (72; 34), (80; 40) et on les relie.



Polygone des effectifs cumulés croissants et détermination graphique de la médiane.

Lecture graphique : la droite d'ordonnée $\frac{N}{2} = 20$ coupe le polygone en un point d'abscisse comprise entre 56 et 64, très proche de 63,4 : on retrouve la médiane calculée par interpolation linéaire. ✓

Conclusion : l'histogramme montre que les masses se concentrent dans les classes [56; 64[et [64; 72[, et la médiane graphique confirme $Me \approx 63,4$ kg.

11.6 Interprétation et communication des résultats d'une enquête

MÉTHODE Comparer et interpréter deux séries statistiques

1. Comparer les moyennes (ou médianes) pour juger du niveau de chaque série.
2. Comparer les écarts-types pour juger de l'homogénéité (ou régularité) : le plus petit écart-type correspond à la série la plus régulière, la plus homogène.
3. Rédiger la conclusion en langage courant, adaptée au contexte de l'énoncé, sans jamais se contenter de donner les nombres.

Réflexe : une moyenne élevée avec un grand écart-type peut cacher de fortes inégalités ; toujours croiser les deux paramètres.

EXERCICE RÉSOLU 14 Comparaison de deux classes

Deux classes de Première A d'un lycée de Bafoussam ont passé le même devoir. Les résultats sont résumés ci-dessous :

	Moyenne	Écart-type
Première A1	11,5	4,2
Première A2	11,2	1,8

Le proviseur doit désigner la classe qui représentera le lycée à un concours inter-établissements où la régularité des copies est primordiale. Quelle classe conseiller ? Justifier.

SOLUTION

Comparaison des moyennes : $11,5 > 11,2$, donc la Première A1 a un niveau moyen très légèrement supérieur (écart de seulement 0,3 point, faible).

Comparaison des écarts-types : $1,8 < 4,2$, donc les notes de la Première A2 sont beaucoup moins dispersées autour de la moyenne : cette classe est nettement plus homogène. Dans la Première A1, l'écart-type de 4,2 traduit de fortes inégalités : d'excellentes copies côtoient des copies très faibles.

Conclusion : les moyennes étant quasi identiques, c'est le critère de régularité qui doit décider. On conseille au proviseur de désigner la Première A2, dont l'écart-type plus faible (1,8 contre 4,2) garantit des copies plus régulières.

11.7 Compléments utiles pour la Terminale

LESAVAIS-TU ? Vers la Terminale : coefficient de variation et boîte à moustaches

En Terminale, on approfondit l'analyse de la dispersion avec :

- Le coefficient de variation $CV = \frac{\sigma}{\bar{x}} \times 100$ (en %), qui permet de comparer la dispersion de deux séries de moyennes très différentes (ex : masses d'éléphants vs masses de souris).
- Les quartiles Q_1 (premier quartile, 25% des données en dessous) et Q_3 (troisième quartile, 75% des données en dessous), obtenus par interpolation linéaire aux rangs $N/4$ et $3N/4$.
- L'**écart interquartile** $EI = Q_3 - Q_1$, mesure de dispersion robuste (insensible aux valeurs extrêmes).
- La boîte à moustaches (box-plot) : représentation graphique synthétique utilisant Min , Q_1 , Me , Q_3 , Max , idéale pour comparer visuellement plusieurs séries.

Ces outils permettent une analyse bien plus fine que la seule variance, surtout en présence de valeurs aberrantes.

ATTENTION Les 5 erreurs qui coûtent des points au Probatoire

1. Oublier les effectifs dans la moyenne. La moyenne d'une série avec effectifs n'est pas $\frac{\sum x_i}{p}$ mais $\frac{\sum n_i x_i}{N}$. De même, pour des classes, on utilise les centres c_i , jamais les bornes.
2. Se tromper de rang pour la médiane. Pour N pair, la médiane est la demi-somme des valeurs de rangs $\frac{N}{2}$ et $\frac{N}{2} + 1$, et non la valeur de rang $\frac{N}{2}$. Et il faut avoir rangé la série dans l'ordre croissant avant toute recherche.
3. Confondre variance et écart-type. L'écart-type est $\sigma = \sqrt{V}$: oublier la racine carrée fait perdre le point de la question. La variance est toujours positive ; un résultat négatif signale une erreur de calcul (souvent dans König-Huygens : c'est $\frac{\sum n_i x_i^2}{N} - \bar{x}^2$, pas l'inverse).
4. Mal construire le tableau cumulé. Le dernier effectif cumulé croissant doit être égal à N et la somme des fréquences doit valoir 1 (ou 100 %) : ces deux vérifications doivent apparaître sur la copie.
5. Tracer un histogramme avec des rectangles espacés ou des hauteurs fausses. Les rectangles sont juxtaposés (le caractère est continu), les bornes sont placées en abscisse à échelle régulière, et pour des classes d'amplitudes inégales ce sont les aires qui sont proportionnelles aux effectifs (hauteur = densité). Ne pas oublier non plus la légende des axes, les unités et le titre du graphique.

12 EXERCICES

12.1 Je vérifie mes connaissances

EXERCICE 7 QCM : les bons réflexes

Pour chaque question, une seule réponse est correcte. Entoure la bonne lettre.

1. Une série statistique de 80 élèves est regroupée en classes $[0; 5[$, $[5; 10[$, $[10; 15[$, $[15; 20]$. Le centre de la classe $[10; 15[$ est :
a) 10 b) 12 c) 12,5 d) 15
2. L'effectif cumulé croissant de la classe $[5; 10[$ représente :
a) le nombre d'individus de la classe $[5; 10[$;
b) le nombre d'individus dont la valeur du caractère est strictement inférieure à 10 ;
c) le nombre d'individus dont la valeur du caractère est supérieure à 5 ;
d) la fréquence de la classe $[5; 10[$.
3. La médiane d'une série d'effectif total $N = 101$ est :
a) la valeur du 50^e individu ;
b) la valeur du 51^e individu ;
c) la moyenne des valeurs du 50^e et du 51^e individu ;
d) la valeur du 50,5^e individu.
4. Si tous les écarts à la moyenne sont nuls, alors :
a) la variance est égale à la moyenne ;
b) l'écart-type vaut 1 ;
c) la variance est nulle ;
d) la série n'existe pas.

EXERCICE 8 Vrai ou faux, en justifiant

Réponds par VRAI ou FAUX en justifiant chaque réponse par une phrase ou un contre-exemple.

1. Deux séries ayant la même moyenne ont nécessairement le même écart-type.
2. La somme des fréquences de toutes les classes d'une série est toujours égale à 1.

3. Dans un histogramme à classes d'égales amplitudes, les aires des rectangles sont proportionnelles aux effectifs.
4. La médiane d'une série peut être calculée par la formule $\bar{x} = \frac{\sum n_i x_i}{N}$.
5. Si on ajoute 3 à chaque valeur d'une série, la moyenne augmente de 3 mais l'écart-type ne change pas.

EXERCICE 9 Définitions et vocabulaire

1. Définis les termes suivants : **population**, **caractère**, **modalité**, **effectif cumulé croissant**.
2. Quelle différence fais-tu entre un caractère statistique discret et un caractère continu ? Donne un exemple de chaque, tiré de la vie scolaire.
3. Écris la formule de la moyenne d'une série regroupée en classes, en précisant la signification de chaque symbole utilisé.
4. Écris les deux formules de la variance (formule de définition et formule de König-Huygens) et précise celle qui est la plus pratique en calcul.

EXERCICE 10 Calculs directs

On a relevé le nombre de buts marqués par match lors d'un tournoi inter-établissements de Yaoundé :

Nombre de buts x_i	0	1	2	3	4
Nombre de matchs n_i	2	5	6	4	3

1. Détermine l'effectif total N .
2. Calcule la moyenne $\bar{x}$ de cette série.
3. Dresse le tableau des effectifs cumulés croissants et déduis-en la médiane.
4. Calcule la variance puis l'écart-type (arrondi au centième).

12.2 Je m'entraîne**EXERCICE 11 Regroupement en classes**

Voici les durées (en minutes) de 30 appels passés un soir depuis une cabine téléphonique de Douala :

2; 5; 8; 1; 12; 7; 3; 9; 15; 4; 6; 11; 2; 8; 10; 5; 13; 1; 7; 9; 3; 6; 14; 4; 8; 11; 2; 10; 5; 7.

1. Regroupe ces données en classes d'amplitude 4 en partant de 0 : $[0; 4[$, $[4; 8[$, etc.
2. Dresse le tableau complet : effectifs, fréquences (en %), effectifs cumulés croissants et décroissants.
3. Quel est le pourcentage d'appels ayant duré moins de 12 minutes?

EXERCICE 12 Moyenne, médiane et dispersion d'une série en classes

Une coopérative agricole de l'Ouest a pesé 50 sacs de maïs. Les masses (en kg) sont regroupées ainsi :

Masse (kg)	[45; 50[	[50; 55[	[55; 60[	[60; 65[	[65; 70[
Effectif n_i	6	12	18	10	4

1. Calcule les centres c_i des classes.
2. Calcule la masse moyenne d'un sac.
3. Détermine la classe médiane, puis calcule la médiane par interpolation linéaire.
4. Calcule la variance et l'écart-type (arrondis au centième). Interprète l'écart-type par une phrase.

EXERCICE 13 Comparaison de deux classes

Les notes de mathématiques de deux classes de Première A de 40 élèves chacune ont donné les résultats suivants :

Paramètre	Première A1	Première A2
Moyenne $\bar{x}$	10,4	10,4
Écart-type σ	1,8	4,6

1. Peut-on dire que les deux classes ont le même niveau? Justifie.
2. Laquelle des deux classes est la plus homogène? Explique le rôle de l'écart-type.
3. Le proviseur souhaite constituer une classe de renforcement avec les élèves les plus en difficulté. Quelle classe fournira vraisemblablement le plus d'élèves de très faible niveau? Pourquoi?

EXERCICE 14 Chasse aux erreurs

Un élève a construit le tableau suivant à partir d'une enquête sur les distances (en km) parcourues par 60 moto-taxis de Bafoussam :

Distance (km)	Effectif	Effectif cumulé croissant
[0 ; 20]	10	10
[20 ; 40]	18	30
[40 ; 60]	20	48
[60 ; 80]	12	62

Il affirme ensuite : « la variance vaut $\sigma^2 = \frac{1}{60} \sum n_i c_i^2 - \bar{x}$ ».

1. Repère et corrige toutes les erreurs de construction du tableau (bornes des classes, effectifs cumulés).
2. Corrige la formule de la variance écrite par l'élève.
3. Avec le tableau corrigé, calcule la moyenne et la médiane par interpolation linéaire.

12.3 Je me prépare au Probatoire**EXERCICE 15** Enquête CAMTEL — exercice type Probatoire

Une agence CAMTEL de Yaoundé a relevé le temps d'attente (en minutes) de 100 clients avant d'être servis. Les résultats sont consignés dans le tableau ci-dessous :

Temps d'attente (min)	[0 ; 10[	[10 ; 20[	[20 ; 30[	[30 ; 40[	[40 ; 50[
Effectif n_i	12	28	35	17	8

1. Reproduis et complète le tableau avec : les centres des classes, les fréquences, les effectifs cumulés croissants.
2. Calcule le temps d'attente moyen d'un client (arrondi au dixième de minute).
3. (a) Détermine la classe médiane.
(b) Calcule la médiane par interpolation linéaire (arrondie au dixième).
4. Calcule la variance puis l'écart-type de la série (arrondis au centième).
5. Construis l'histogramme des effectifs (unités : 1 cm pour 10 min en abscisse, 1 cm pour 5 clients en ordonnée).
6. (a) Construis le polygone des effectifs cumulés croissants.
(b) Détermine graphiquement la médiane et compare avec le résultat de la question 3.b).

7. Le chef d'agence affirme : « plus de la moitié des clients attendent moins de 25 minutes ». À l'aide du polygone des effectifs cumulés croissants, dis si cette affirmation est exacte.

EXERCICE 16 Récoltes de cacao dans le Centre

Un acheteur de cacao a mesuré la production annuelle (en tonnes) de 80 planteurs d'une localité de la région du Centre :

Production (t)	[0 ; 2[	[2 ; 4[	[4 ; 6[	[6 ; 8[	[8 ; 10[
Effectif n_i	8	20	a	18	6

où a désigne un effectif inconnu.

- Détermine la valeur de a .
- Construis le tableau des fréquences et des fréquences cumulées croissantes (en %).
- Calcule la production moyenne d'un planteur.
- (a) Détermine la médiane par interpolation linéaire.
(b) Interprète cette médiane par une phrase compréhensible par un non-spécialiste.
- Calcule la variance et l'écart-type (arrondis au centième).
- Un acheteur hésite entre cette localité et une autre où la production moyenne est de 4,8 tonnes avec un écart-type de 0,9 tonne. Dans quelle localité les productions sont-elles les plus homogènes ? Justifie et conclus sur le choix le plus sûr pour l'acheteur.

EXERCICE 17 Lecture graphique et rédaction d'un rapport

Dans le cadre de la semaine du livre, le club lecture d'un lycée de Garoua a mené une enquête sur le nombre de livres lus par trimestre par les élèves. Le polygone des effectifs cumulés croissants est donné ci-dessous : les points de coordonnées (0 ; 0), (2 ; 15), (4 ; 45), (6 ; 90), (8 ; 110) et (10 ; 120) sont reliés par des segments de droite.

- Reproduis le graphique (unités : 1 cm pour 2 livres en abscisse, 1 cm pour 10 élèves en ordonnée).
- (a) Détermine graphiquement la médiane de la série.
(b) Détermine graphiquement les quartiles Q_1 et Q_3 (rappel : Q_1 correspond à 25 % de l'effectif, Q_3 à 75 %).
- Reconstitue le tableau des effectifs par classes [0 ; 2[, [2 ; 4[, ..., [8 ; 10[.
- Vérifie par le calcul (interpolation linéaire) la valeur de la médiane trouvée graphique-

ment.

5. Calcule la moyenne et l'écart-type de la série (arrondis au centième).
6. Rédige une conclusion de cinq lignes environ, destinée au proviseur, présentant les résultats de l'enquête (niveau de lecture moyen, dispersion, proportion d'élèves lisant peu) et proposant une recommandation pour le club lecture.

13 CORRIGÉS DES EXERCICES

13.1 Corrigés des exercices d'application

CORRIGÉ Exercice 1 — QCM : les bons réflexes

1. c) 12,5. Le centre d'une classe $[a; b[$ est $\frac{a+b}{2}$. Ici $\frac{10+15}{2} = 12,5$.
2. b) le nombre d'individus dont la valeur du caractère est strictement inférieure à 10. L'effectif cumulé croissant d'une classe donne le nombre d'individus dont la valeur est strictement inférieure à la borne supérieure de cette classe.
3. b) la valeur du 51^e individu. Pour un effectif total impair $N = 101$, la médiane est la valeur de l'individu de rang $\frac{N+1}{2} = 51$.
4. c) la variance est nulle. Si tous les écarts à la moyenne sont nuls, alors chaque $x_i = \bar{x}$, donc $\sigma^2 = \frac{1}{N} \sum n_i (x_i - \bar{x})^2 = 0$.

CORRIGÉ Exercice 2 — Vrai ou faux, en justifiant

1. FAUX. Deux séries peuvent avoir la même moyenne mais des dispersions très différentes. Exemple : série A : $\{10, 10, 10\}$ (moyenne 10, $\sigma = 0$) ; série B : $\{0, 10, 20\}$ (moyenne 10, $\sigma \approx 8,16$).
2. VRAI. Par définition, la fréquence d'une classe est $f_i = \frac{n_i}{N}$. La somme des fréquences est $\sum f_i = \frac{\sum n_i}{N} = 1$ (ou 100%).
3. VRAI. Dans un histogramme à classes d'égales amplitudes, la largeur des rectangles est constante. L'aire d'un rectangle est largeur $\times$ hauteur. La hauteur est proportionnelle à l'effectif (ou à la fréquence), donc l'aire est proportionnelle à l'effectif.
4. FAUX. La formule $\bar{x} = \frac{\sum n_i x_i}{N}$ calcule la moyenne, pas la médiane. La médiane se détermine à partir des effectifs cumulés.
5. VRAI. L'ajout d'une constante c à toutes les valeurs décale la moyenne de c ($\overline{x+c} = \bar{x}+c$) mais ne modifie pas les écarts à la moyenne, donc la variance et l'écart-type restent inchangés.

CORRIGÉ Exercice 3 — Définitions et vocabulaire

- **Population** : ensemble des individus (ou objets) sur lesquels porte l'étude statistique.
 - **Caractère** : propriété qualitative ou quantitative observée sur chaque individu de la population.
 - **Modalité** : valeur que peut prendre le caractère (pour un caractère quantitatif discret) ou intervalle de valeurs (classe pour un caractère continu regroupé).
 - **Effectif cumulé croissant** : pour une modalité (ou une classe) donnée, somme des effectifs de cette modalité et de toutes celles qui la précèdent dans l'ordre croissant.
- Un **caractère discret** ne prend qu'un nombre fini ou dénombrable de valeurs isolées (ex. : nombre d'élèves par classe dans un établissement). Un **caractère continu** peut prendre toute valeur dans un intervalle de $\mathbb{R}$ (ex. : taille en cm des élèves de Première A).
- Pour une série regroupée en classes de centres c_i et d'effectifs n_i ($i = 1, \dots, k$), la moyenne est

$$\bar{x} = \frac{\sum_{i=1}^k n_i c_i}{N}, \quad N = \sum_{i=1}^k n_i.$$

c_i est le centre de la classe i (milieu de l'intervalle), n_i son effectif, N l'effectif total.

- Formule de définition : $\sigma^2 = \frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{x})^2$ (ou avec les centres c_i pour les classes).
 - Formule de König-Huygens : $\sigma^2 = \frac{1}{N} \sum_{i=1}^k n_i x_i^2 - \bar{x}^2$ (ou $\frac{\sum n_i c_i^2}{N} - \bar{x}^2$ pour les classes).

La formule de König-Huygens est plus pratique en calcul car elle évite de calculer chaque écart $(x_i - \bar{x})$.

CORRIGÉ Exercice 4 — Calculs directs

- Effectif total : $N = 2 + 5 + 6 + 4 + 3 = 20$ matchs.
- Moyenne :

$$\bar{x} = \frac{0 \times 2 + 1 \times 5 + 2 \times 6 + 3 \times 4 + 4 \times 3}{20} = \frac{0 + 5 + 12 + 12 + 12}{20} = \frac{41}{20} = 2,05 \text{ buts par match.}$$

- Tableau des effectifs cumulés croissants :

x_i	0	1	2	3	4
n_i	2	5	6	4	3
N_i (cumulé)	2	7	13	17	20

$N = 20$ (pair) $\Rightarrow$ la médiane est la moyenne des valeurs des 10^e et 11^e individus. Les deux se situent dans la modalité 2 (car $N_1 = 7 < 10, 11 \leq N_2 = 13$). Donc Médiane = 2 buts.

4. Variance (formule de König-Huygens) :

$$\sum n_i x_i^2 = 0^2 \times 2 + 1^2 \times 5 + 2^2 \times 6 + 3^2 \times 4 + 4^2 \times 3 = 0 + 5 + 24 + 36 + 48 = 113.$$

$$\bar{x}^2 = (2,05)^2 = 4,2025.$$

$$\sigma^2 = \frac{113}{20} - 4,2025 = 5,65 - 4,2025 = 1,4475.$$

Écart-type : $\sigma = \sqrt{1,4475} \approx 1,2031 \approx 1,20$ buts (arrondi au centième).

CORRIGÉ Exercice 5 — Regroupement en classes

1. Regroupement en classes d'amplitude 4 à partir de 0 :

Classe	Effectif n_i	Fréquence f_i (%)
[0 ; 4[	7	23,33
[4 ; 8[	10	33,33
[8 ; 12[	9	30,00
[12 ; 16[	4	13,33
Total	30	100

2. Tableau complet avec effectifs cumulés :

Classe	n_i	f_i (%)	N_i (croissant)	N'_i (décroissant)
[0 ; 4[	7	23,33	7	30
[4 ; 8[	10	33,33	17	23
[8 ; 12[	9	30,00	26	13
[12 ; 16[	4	13,33	30	4

3. Pourcentage d'appels < 12 min : classes [0 ; 4[, [4 ; 8[, [8 ; 12[. Effectif cumulé croissant à la fin de [8 ; 12[est 26. Pourcentage = $\frac{26}{30} \times 100 \approx 86,67\%$.

CORRIGÉ Exercice 6 — Moyenne, médiane et dispersion d'une série en classes

1. Centres des classes : $c_1 = \frac{45+50}{2} = 47,5$; $c_2 = 52,5$; $c_3 = 57,5$; $c_4 = 62,5$; $c_5 = 67,5$ (en kg).

2. Masse moyenne :

$$\bar{x} = \frac{6 \times 47,5 + 12 \times 52,5 + 18 \times 57,5 + 10 \times 62,5 + 4 \times 67,5}{50} = \frac{285 + 630 + 1035 + 625 + 270}{50} = \frac{2845}{50} = 56,9 \text{ kg}$$

3. Médiane : $N = 50$. Pour une série regroupée en classes, la médiane se détermine par interpolation au rang $N/2 = 25$. Effectifs cumulés : 6, 18, 36, 46, 50. La classe médiane est $[55; 60[$ (car $18 < 25 \leq 36$). Interpolation linéaire :

$$\text{Médiane} = 55 + \frac{25 - 18}{18} \times 5 = 55 + \frac{7}{18} \times 5 = 55 + \frac{35}{18} \approx 55 + 1,944 = 56,94 \text{ kg.}$$

4. Variance (König-Huygens) :

$$\sum n_i c_i^2 = 6 \times 2256,25 + 12 \times 2756,25 + 18 \times 3306,25 + 10 \times 3906,25 + 4 \times 4556,25 = 163412,5.$$

$$\frac{\sum n_i c_i^2}{N} = \frac{163412,5}{50} = 3268,25.$$

$$\sigma^2 = 3268,25 - (56,9)^2 = 3268,25 - 3237,61 = 30,64.$$

Écart-type : $\sigma = \sqrt{30,64} \approx 5,54 \text{ kg}$ (arrondi au centième). Interprétation : Les masses des sacs s'écartent en moyenne d'environ 5,5 kg de la masse moyenne 56,9 kg.

CORRIGÉ Exercice 7 — Comparaison de deux classes

- Non, on ne peut pas dire que les deux classes ont le même niveau. Bien que les moyennes soient identiques (10,4), les dispersions sont très différentes : l'écart-type de la classe A2 (4,6) est plus du double de celui de la classe A1 (1,8). La classe A2 est beaucoup plus hétérogène : elle compte à la fois des élèves très forts et des élèves très faibles, alors que la classe A1 est plus homogène autour de la moyenne.
- La classe Première A1 est la plus homogène. L'écart-type mesure la dispersion des notes autour de la moyenne : plus il est petit, plus les valeurs sont regroupées près de la moyenne.
- La classe Première A2 fournira vraisemblablement plus d'élèves de très faible niveau. Avec un écart-type plus grand, la distribution est plus étalée ; la queue de distribution vers les notes basses est plus fournie. En supposant une forme de distribution similaire (ex. approximativement normale), la proportion d'élèves en dessous d'un seuil bas (ex. 5) est plus grande pour un écart-type plus élevé.

CORRIGÉ Exercice 8 — Chasse aux erreurs

1. Erreurs du tableau :

- Les classes sont mal définies : elles se chevauchent aux bornes ($[0; 20]$ et $[20; 40]$ contiennent toutes deux la valeur 20). Il faut utiliser des intervalles semi-ouverts : $[0; 20[, [20; 40[, [40; 60[, [60; 80]$ (ou $[60; 80[$).
- Les effectifs cumulés croissants sont faux : $10 + 18 = 28$ (et non 30); $28 + 20 = 48$ (correct); $48 + 12 = 60$ (et non 62). Le total des effectifs est 60, le dernier cumulé doit être 60.

Tableau corrigé :

Distance (km)	Effectif	Effectif cumulé croissant
$[0; 20[$	10	10
$[20; 40[$	18	28
$[40; 60[$	20	48
$[60; 80]$	12	60

2. Formule de la variance corrigée :

$$\sigma^2 = \frac{1}{N} \sum n_i c_i^2 - \bar{x}^2 \quad (\text{formule de König-Huygens}).$$

L'élève a oublié le carré sur $\bar{x}$.3. Avec le tableau corrigé : Centres : $c_1 = 10, c_2 = 30, c_3 = 50, c_4 = 70$. Moyenne :

$$\bar{x} = \frac{10 \times 10 + 18 \times 30 + 20 \times 50 + 12 \times 70}{60} = \frac{100 + 540 + 1000 + 840}{60} = \frac{2480}{60} \approx 41,33 \text{ km.}$$

Médiane : $N = 60$, rangs 30 et 31. Effectifs cumulés : 10, 28, 48, 60. La classe médiane est $[40; 60[$ ($28 < 30,5 \leq 48$). Interpolation :

$$\text{Médiane} = 40 + \frac{30 - 28}{20} \times 20 = 40 + 2 = 42 \text{ km.}$$

CORRIGÉ Exercice 9 — Enquête CAMTEL — exercice type Probatoire

1. Tableau complété :

Temps (min)	Centre c_i	Effectif n_i	Fréquence f_i	Effectif cumulé croissant N_i
[0 ; 10[	5	12	0,12	12
[10 ; 20[	15	28	0,28	40
[20 ; 30[	25	35	0,35	75
[30 ; 40[	35	17	0,17	92
[40 ; 50[	45	8	0,08	100
Total		100	1	

2. Temps d'attente moyen :

$$\bar{x} = \frac{12 \times 5 + 28 \times 15 + 35 \times 25 + 17 \times 35 + 8 \times 45}{100} = \frac{60 + 420 + 875 + 595 + 360}{100} = \frac{2310}{100} = 23,1 \text{ min.}$$

3. (a) Classe médiane : $N/2 = 50$. Effectifs cumulés : 12, 40, 75, ... $\Rightarrow$ classe [20 ; 30[.

(b) Médiane par interpolation :

$$\text{Médiane} = 20 + \frac{50 - 40}{35} \times 10 = 20 + \frac{100}{35} \approx 20 + 2,857 = 22,9 \text{ min (au dixième).}$$

4. Variance et écart-type :

$$\sum n_i c_i^2 = 12 \times 25 + 28 \times 225 + 35 \times 625 + 17 \times 1225 + 8 \times 2025 = 65500.$$

$$\frac{\sum n_i c_i^2}{N} = 655.$$

$$\sigma^2 = 655 - (23,1)^2 = 655 - 533,61 = 121,39.$$

$$\sigma = \sqrt{121,39} \approx 11,02 \text{ min (au centième).}$$

5. Histogramme : abscisse 1 cm pour 10 min $\Rightarrow$ largeur des rectangles = 1 cm. Ordonnée 1 cm pour 5 clients $\Rightarrow$ hauteurs : $12/5 = 2,4$ cm ; $28/5 = 5,6$ cm ; $35/5 = 7$ cm ; $17/5 = 3,4$ cm ; $8/5 = 1,6$ cm.

6. (a) Polygone des effectifs cumulés croissants : points (0; 0), (10; 12), (20; 40), (30; 75), (40; 92), (50; 100) reliés par segments.

(b) Médiane graphique : abscisse du point d'ordonnée 50 sur le polygone. Entre (20; 40) et (30; 75), on trouve $x \approx 22,9$ min, cohérent avec le calcul.

7. Affirmation du chef : « plus de la moitié des clients attendent moins de 25 min ». Sur le polygone, à $x = 25$, l'ordonnée (effectif cumulé) est obtenue par interpolation entre (20; 40) et (30; 75) : $y = 40 + \frac{5}{10} \times 35 = 57,5$. Donc 57,5 clients sur 100 attendent moins de 25 min, soit $57,5\% > 50\%$. L'affirmation est exacte.

Barème indicatif (sur 20) : Tableau complété (3 pts) ; Moyenne (2 pts) ; Classe médiane + interpolation (3 pts) ; Variance + écart-type (3 pts) ; Histogramme (3 pts) ; Polygone + médiane graphique (3 pts) ; Interprétation affirmation (3 pts). Points de vigilance : Bien utiliser les centres des classes ; ne pas confondre effectifs et fréquences ; interpolation linéaire correcte (formule Médiane = $L + \frac{N/2 - F_{av}}{f_{med}} \times h$) ; sur le polygone, les abscisses sont les bornes supérieures des classes ; vérifier que la somme des effectifs = 100.

CORRIGÉ Exercice 10 — Récoltes de cacao dans le Centre

- Effectif total $N = 80 : 8 + 20 + a + 18 + 6 = 52 + a = 80 \Rightarrow a = 28$.
- Tableau des fréquences et fréquences cumulées croissantes (en %) :

Classe (t)	Effectif n_i	Fréquence f_i (%)	Fréquence cumulée croissante (%)
[0 ; 2[	8	10,0	10,0
[2 ; 4[	20	25,0	35,0
[4 ; 6[	28	35,0	70,0
[6 ; 8[	18	22,5	92,5
[8 ; 10[	6	7,5	100,0
Total	80	100	

- Production moyenne : centres 1, 3, 5, 7, 9.

$$\bar{x} = \frac{8 \times 1 + 20 \times 3 + 28 \times 5 + 18 \times 7 + 6 \times 9}{80} = \frac{8 + 60 + 140 + 126 + 54}{80} = \frac{388}{80} = 4,85 \text{ tonnes.}$$

- (a) Médiane : $N/2 = 40$. Effectifs cumulés : 8, 28, 56, ... $\Rightarrow$ classe médiane [4 ; 6[. Interpolation (avec les effectifs) :

$$\text{Médiane} = 4 + \frac{40 - 28}{28} \times 2 = 4 + \frac{12}{28} \times 2 = 4 + \frac{24}{28} = 4 + \frac{6}{7} \approx 4,857 \text{ tonnes.}$$

- (b) Interprétation : La moitié des planteurs de cette localité produisent moins de 4,86 tonnes de cacao par an, et l'autre moitié produit plus.

- Variance et écart-type :

$$\sum n_i c_i^2 = 8 \times 1 + 20 \times 9 + 28 \times 25 + 18 \times 49 + 6 \times 81 = 8 + 180 + 700 + 882 + 486 = 2256.$$

$$\frac{\sum n_i c_i^2}{N} = \frac{2256}{80} = 28,2.$$

$$\sigma^2 = 28,2 - (4,85)^2 = 28,2 - 23,5225 = 4,6775.$$

$$\sigma = \sqrt{4,6775} \approx 2,16 \text{ tonnes (au centième).}$$

- Comparaison : Localité 1 : $\bar{x} = 4,85$, $\sigma \approx 2,16$. Localité 2 : $\bar{x} = 4,8$, $\sigma = 0,9$. L'écart-type de la localité 2 est beaucoup plus petit, donc les productions y sont plus homogènes. Pour l'acheteur, la localité 2 est plus sûre : les quantités livrées sont plus prévisibles, moins de risque de fortes variations d'un planteur à l'autre.

CORRIGÉ Exercice 11 — Lecture graphique et rédaction d'un rapport

- Graphique : polygone des effectifs cumulés croissants passant par (0; 0), (2; 15), (4; 45), (6; 90), (8; 110), (10; 120). Unités : 1 cm pour 2 livres (abscisse), 1 cm pour 10 élèves (ordonnée).
- (a) Médiane graphique : $N = 120$, rang 60. Sur le polygone, l'ordonnée 60 se situe entre (4; 45) et (6; 90). Par interpolation : $x = 4 + \frac{60-45}{90-45} \times 2 = 4 + \frac{15}{45} \times 2 = 4 + \frac{2}{3} \approx 4,67$ livres.
- (b) Quartiles : Q_1 (rang 30) entre (2; 15) et (4; 45) : $x = 2 + \frac{30-15}{45-15} \times 2 = 2 + 1 = 3$ livres. Q_3 (rang 90) : point (6; 90) exactement $\Rightarrow Q_3 = 6$ livres.
- Tableau des effectifs par classes (différences des cumulés) :

Classe (livres)	Effectif n_i
[0; 2[	15
[2; 4[	30
[4; 6[	45
[6; 8[	20
[8; 10]	10
Total	120

- Vérification médiane par interpolation (classe [4; 6[) : $L = 4$, $F_{av} = 45$, $f_{med} = 45$, $h = 2$.

$$\text{Médiane} = 4 + \frac{60 - 45}{45} \times 2 = 4 + \frac{15}{45} \times 2 = 4 + \frac{2}{3} = 4,67 \text{ livres.}$$

- Moyenne et écart-type : centres 1, 3, 5, 7, 9.

$$\bar{x} = \frac{15 \times 1 + 30 \times 3 + 45 \times 5 + 20 \times 7 + 10 \times 9}{120} = \frac{15 + 90 + 225 + 140 + 90}{120} = \frac{560}{120} = \frac{14}{3} \approx 4,67 \text{ livres.}$$


$$\sum n_i c_i^2 = 15 \times 1 + 30 \times 9 + 45 \times 25 + 20 \times 49 + 10 \times 81 = 3200.$$

$$\sigma^2 = \frac{3200}{120} - \left(\frac{14}{3}\right)^2 = \frac{80}{3} - \frac{196}{9} = \frac{240 - 196}{9} = \frac{44}{9} \approx 4,89.$$

$$\sigma = \sqrt{\frac{44}{9}} = \frac{2}{3}\sqrt{11} \approx 2,21 \text{ livres (au centième).}$$

- Conclusion pour le proviseur : L'enquête montre que les élèves lisent en moyenne 4,67 livres par trimestre, avec un écart-type de 2,21 livres, ce qui indique une dispersion modérée. La médiane (4,67 livres) confirme que la moitié des élèves lit moins de 5 livres. Les quartiles $Q_1 = 3$ et $Q_3 = 6$ révèlent que 25% des élèves lisent au maximum 3 livres (lecteurs faibles) et 25% en lisent au moins 6 (bons lecteurs). Il est recommandé au club lecture de cibler prioritairement le quartile inférieur en proposant des animations (lectures à voix haute, défis lecture) et en diversifiant les ouvrages accessibles pour stimuler les élèves les plus en retrait.

14 FICHE BILAN



Carte mentale de la leçon NA06 : Statistiques (1ère A)

FICHE BILAN L'essentiel à connaître pour l'examen

Définitions clés

- **Population** : ensemble des individus étudiés (taille N).
- **Caractère statistique** : variable observée (quantitatif discret/continu, qualitatif).
- **Modalité** x_i : valeur prise par le caractère ; **Effectif** n_i : nombre d'individus pour x_i .
- **Fréquence** $f_i = \frac{n_i}{N}$; $\sum n_i = N$, $\sum f_i = 1$.
- **Classes d'égales amplitudes** : intervalles $[a_k; b_k[$ de même longueur $h = b_k - a_k$ (dernière classe fermée). **Modalité de classe** = centre $c_k = \frac{a_k + b_k}{2}$.

- **Effectifs cumulés croissants** $N_k = \sum_{i=1}^k n_i$; **décroissants** $N'_k = \sum_{i=k}^m n_i$. Idem pour fréquences F_k, F'_k .

Formules à connaître par cœur

Paramètre	Série simple (modalités x_i , effectifs n_i)	Série groupée (classes centres c_k , effectifs n_k)
Moyenne $\bar{x}$	$\bar{x} = \frac{\sum n_i x_i}{N}$	$\bar{x} \approx \frac{\sum n_k c_k}{N}$
Variance V (ou σ^2)	$V = \frac{\sum n_i (x_i - \bar{x})^2}{N} = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$	$V \approx \frac{\sum n_k c_k^2}{N} - \bar{x}^2$
Écart-type σ	$\sigma = \sqrt{V}$	$\sigma = \sqrt{V}$
Médiane M_e	Valeur centrale (ou moyenne des 2 centrales) si N pair/impair	Interpolation linéaire dans la classe médiane : $M_e = a + \frac{\frac{N}{2} - N_{\text{avant}}}{n_{\text{méd}}} \times h$

Méthodes express

1. Regrouper en classes : Amplitude $h \approx \frac{\text{Étendue}}{\text{Nb classes souhaité (5 à 15)}}$ → arrondir h à une valeur « propre » (1, 2, 5, 10, 20...). Définir la 1ère borne $a_1 \leq \min$. Construire le tableau.
2. Moyenne : Tableau auxiliaire ($x_i, n_i, n_i x_i, n_i x_i^2$) → Somme → Formules.
3. Médiane : Calculer $N/2$. Chercher la 1ère valeur où $N_k \geq N/2$ (croissant) ou tracer le polygone croissant → lire l'abscisse de l'ordonnée $N/2$.
4. Variance : Toujours utiliser Koenig-Huygens : $V = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$ (moins d'erreurs de calcul).
5. Histogramme : Axe des abscisses = modalités/classes (échelle réelle). Axe des ordonnées = **Densité** $d_k = \frac{n_k}{N \times h}$ (ou effectifs n_k si h constant). Aire du rectangle = Effectif (ou Fréquence).
6. Polygones cumulés : Points (x_i, N_i) croissant ou (x_i, N'_i) décroissant. Relier par segments. Médiane = abscisse du point d'ordonnée $N/2$.

À RETENIR

Checklist avant le Probatoire

- ☐ Je sais définir : population, caractère, modalité, effectif, fréquence, effectif total N .
- ☐ Je sais construire un tableau d'effectifs et de fréquences (croissantes et décroissantes) pour une série brute ou groupée.
- ☐ Je sais choisir une amplitude h « propre » et regrouper une série continue en classes d'égales amplitudes.
- ☐ Je sais calculer la moyenne $\bar{x}$ (série simple et groupée) et j'en connais les propriétés (translation, homothétie).

- ☐ Je sais déterminer la médiane M_e par le tableau des effectifs cumulés (formule d'interpolation pour classes) et par lecture graphique sur le polygone cumulé croissant.
- ☐ Je sais calculer la variance V et l'écart-type σ en utilisant exclusivement la formule de Koenig-Huygens ($V = \frac{\sum nx^2}{N} - \bar{x}^2$).
- ☐ Je sais construire un histogramme rigoureux : axes gradués, densité (si amplitudes inégales) ou effectifs (si égales), aires proportionnelles aux effectifs.
- ☐ Je sais tracer les polygones des effectifs cumulés (croissant et décroissant) et en lire la médiane (et les quartiles).
- ☐ Je sais interpréter : comparer deux séries via moyennes (niveau) et écarts-types (dispersion/homogénéité) dans un énoncé concret (notes, salaires, rendements agricoles...).
- ☐ Je vérifie toujours : $\sum n_i = N$, $\sum f_i = 1$, $V \geq 0$, médiane dans la classe médiane, somme des aires de l'histogramme = N (ou 1).
- ☐ Je soigne ma rédaction : phrases complètes, unités, conclusion interprétée (« La série B est plus homogène car $\sigma_B < \sigma_A$ »).

**Signé • OnBuch+**ÉQUIPE PÉDAGOGIQUE ONBUCH+
CONFORME AU PROGRAMME OFFICIEL MINESEC**OnBuch+**